强化学习

第 7 章

强化学习基础 · 动态规划 · 时序差分 · 策略梯度

著者
邓杭　杨耀东

教材
《大语言模型：训练、精调与对齐》

出版
清华大学出版社



本章目录

7.1 强化学习 第 3 页
MDP、回报、价值函数与贝尔曼方程

7.2 强化学习方法 第 31 页
三大类方法的全景与表 7.1

7.3 动态规划 第 36 页
策略评估、策略改进与 GPI

7.4 蒙特卡洛方法 第 47 页
用完整幕的平均回报估计价值

7.5 时序差分学习 第 59 页
TD、SARSA、Q 学习、DQN 与 TD(λ)

7.6 策略梯度方法 第 88 页
直接优化参数化策略：定理、证明与 REINFORCE

7.7 演员-评论家 第 109 页
演员更新策略、评论家评估价值：AC、TRPO、GAE 与 PPO

7.8 大语言模型的 MDP 描述 第 125 页
状态是词元序列，动作是下一个词元

7.9 小结 第 129 页
全章脉络：从 MDP 到三类求解方法

阅读建议 先建立 MDP 与回报的框架（7.1），再按动态规划、蒙特卡洛、TD、策略梯度、演员-评论家的顺序推进（7.2–7.6）。

7.1

强化学习

智能体在环境中试错，学习使长期累积奖励最大的策略；MDP 给出问题的数学形式，贝尔曼方程给出求解价值函数的递归工具。

本节内容

7.1.1 强化学习介绍

7.1.2 马尔可夫决策过程

7.1.3 强化学习关键概念

7.1.4 策略和价值函数

7.1.5 贝尔曼方程

语言模型的生成过程

大语言模型逐个词元地生成文本，每生成一个词元都改变后续可选的词元集合，这正是序贯决策。因此可以把生成过程视为马尔可夫决策过程，用强化学习优化语言模型。

有监督学习

依赖带标签的静态数据集，拟合已有数据模式。

优化目标是最小化与标签之间的损失，训练信号逐词元给定。

对应第 5 章的有监督微调。

强化学习

依赖一个目标（奖励函数），对模型自己生成的样本做优化。

奖励可以只在序列结束时给出，衡量整段输出的好坏。

对应第 8 章的 RLHF 与推理强化学习。

本章建立强化学习的知识体系：先把问题写成 MDP，再依次讲清基于价值、基于策略与演员-评论家三类求解方法。

智能体与环境的交互

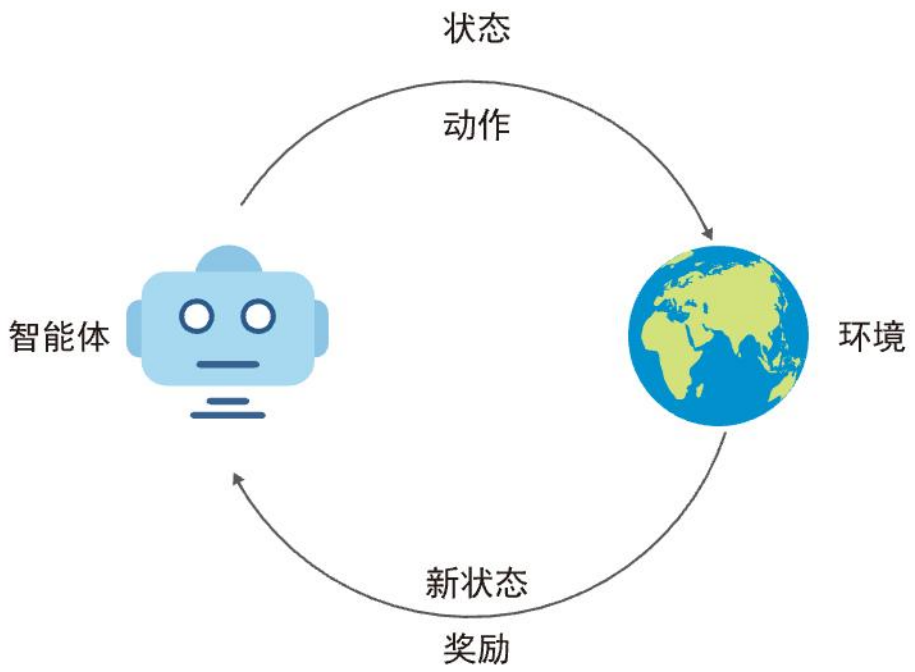


图 7.1　智能体与环境进行交互

- 每一步，智能体感知环境的状态 S_t，按策略选择动作 A_t。
- 环境响应动作，转移到新状态 S_{t+1}，并反馈奖励 R_{t+1}。
- 智能体依据奖励改进策略，指导后续的动作选择。

智能体可以是物理实体（机器人、自动驾驶汽车），也可以是软件实体（游戏 AI、交易算法）。

这条回路每转一圈产生一条四元组 $(S_t, A_t, R_{t+1}, S_{t+1})$，后续所有算法都从这样的数据里学习。

强化学习的问题定义

问题来源

复杂序贯决策

每个决策不仅影响即时结果，更会改变未来状态和长期回报，需要系统化的求解框架。

建模工具

马尔可夫决策过程

用状态、动作、状态转移概率、奖励函数和折扣因子形式化描述环境，是强化学习的理论基础。

求解对象

策略或价值函数

算法通过与环境的交互，学习策略或价值函数，而不是拟合静态数据集。

难点 环境动态具有随机性，要求最大化回报的期望；而当前决策会连锁影响未来，精确评估所有可能的决策序列会遭遇组合爆炸（维数灾难）。算法只能依靠有限次交互，学到一个能获得较高长期累积奖励的策略或价值函数。

本章安排：MDP 与关键要素（7.1.2–7.1.4）→ 贝尔曼方程（7.1.5）→ 方法分类（7.2）→ 动态规划、蒙特卡洛、时序差分（7.3–7.5）→ 策略梯度（7.6）→ 演员-评论家（7.7）→ 语言模型的 MDP 描述（7.8）。

马尔可夫链

马尔可夫链描述一个随机过程：系统的未来状态只依赖当前状态，与过去的历史状态无关。这一性质称为马尔可夫性质。

$$p(S_{t+1} \mid S_t) = p(S_{t+1} \mid S_1, S_2, \cdots, S_t) \tag{7-1}$$

状态集合 $\mathcal{S}$ 包含所有可能的状态，$p(s' \mid s)$ 为状态转移概率；对任意历史序列 $(S_1, S_2, \cdots, S_t)$，转移到 S_{t+1} 的概率只与 S_t 有关。

例 1

智能体的当前位置已经隐含了到达此处的历史路径，只需当前状态即可预测下一步转移。

例 2

预测明天的天气只需今天的天气状态，与前几天的天气历史无关。

有限状态空间的描述

$$\mathcal{P} = \begin{bmatrix} p_{11} & \cdots & p_{1n} \\ \vdots & \ddots & \vdots \\ p_{n1} & \cdots & p_{nn} \end{bmatrix} \tag{7-2}$$

共有 n 个状态，$\mathcal{P} \in \mathbb{R}^{n \times n}$；$p_{ij} = p(S_{t+1} = j \mid S_t = i)$ 表示从状态 i 转移到状态 j 的概率，矩阵每行之和为 1。

- **不可约**：从任意状态出发，经过有限步可以到达任意其他状态。
- **非周期**：状态没有固定的返回周期。
- 同时满足这两个条件时，状态转移分布收敛于唯一的稳态分布。

稳态分布是 7.6 节策略梯度定理的关键：目标函数的梯度只与状态被访问的频率有关，而与状态转移概率的具体形式无关。

矩阵性质

每行是一个状态出发的转移分布，行和为 1；矩阵不要求对称。

收敛条件

不可约 + 非周期，两个条件缺一不可，否则可能出现周期振荡或不唯一。

与 MDP 的关系

MDP 的转移还要以动作为条件，即 $p(s' \mid s, a)$，相当于每个动作一张矩阵。

马尔可夫决策过程

马尔可夫决策过程（MDP）是描述序列决策问题的数学模型，其目标是在随机环境中寻找最优策略，最大化从当前状态开始的期望累积折扣奖励。一个有限 MDP 由五元组 $\mathcal{M} = \langle \mathcal{S}, \mathcal{A}, P, R, \gamma \rangle$ 定义。

$\mathcal{S}$

有限的状态集合，t 时刻的状态记为 S_t。

$\mathcal{A}$

有限的动作集合，t 时刻的动作记为 A_t。

P

$p(s' \mid s, a) = \Pr(S_{t+1} = s' \mid S_t = s, A_t = a)$。

R

奖励函数，在状态 s 执行 a 转移到 s' 得到 $r(s, a, s')$。

γ

折扣因子 $\gamma \in [0, 1]$，把未来奖励折算为当前价值。

核心

状态转移概率刻画环境对动作的随机响应，是建模不确定性的核心。

确定性转移是随机性转移的特例，此时 $p(s' \mid s, a) \in \{0, 1\}$。例如网格环境中，若 $S_{(1,1)}$ 的左方可通行，则 $P(S_{(1,0)} \mid S_{(1,1)}, A_{\text{左}}) = 1$。

依据 《大语言模型：训练、精调与对齐》第 7.1.2 节（MDP 五元组）

MDP 与强化学习的关系

MDP 提供形式化框架

为强化学习问题提供严谨的数学描述，定义了状态、动作、转移、奖励和折扣等核心要素。

它回答“环境是什么样的”。

强化学习提供求解方法

通过智能体与环境的交互，学习最优策略以最大化累积奖励，其本质就是求解一个 MDP。

它回答“智能体怎样学到好行为”。

环境模型

状态、动作、转移、奖励、折扣

→

交互采样

策略 π 产生 $(S_t, A_t, R_{t+1}, S_{t+1})$

→

策略 / 价值函数

估计、改进、再采样

结论 MDP 是强化学习的理论基础，强化学习是解决 MDP 问题的实践方法学，两者共同构成处理序列决策问题的完整体系。

序列决策任务

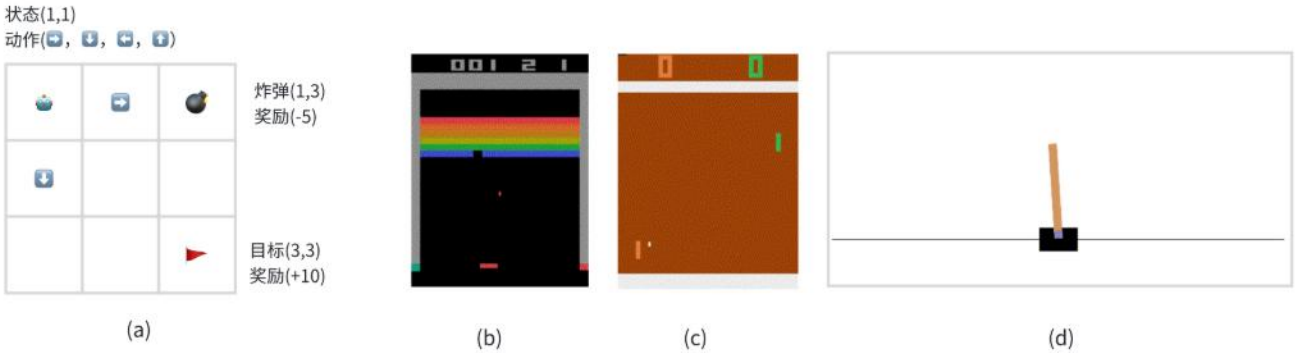


图 7.2　强化学习环境模型

(a)

网格世界：机器人移动到红旗位置，路径奖励和最大。

(b)

打砖块：消灭所有砖块。

(c)

乒乓球：动态对抗对手。

(d)

车杆：保持杆平衡更长时间。

图 (b)–(d) 的环境实现在 Gymnasium 主页（OpenAI Gym 的维护版本，openai/gym）可直接调用，车杆对应 `CartPole-v1`、打砖块对应 `ALE/Breakout-v5`。

智能体与环境

智能体

执行任务的实体

基于当前状态 $s \in \mathcal{S}$，按策略 π 决策动作 $a \in \mathcal{A}$，与环境交互后获得奖励。策略定义了智能体的决策规则。

环境

由五个要素定义

状态集 $\mathcal{S}$、动作集 $\mathcal{A}$、状态转移概率 $p(s' \mid s, a)$、奖励函数 $r(s, a)$ 与折扣因子 γ。

已知环境

$r(s, a)$ 与 $p(s' \mid s, a)$ 均明确，可用动态规划或启发式搜索求最优策略。

网格世界的转移是确定的：目标 $+10$，炸弹 $(1, 3)$ 得 -5，其他移动 -1；每个时刻只能上下左右移动一格。

未知环境

奖励函数或状态转移概率未知，需按策略交互试错学习。

打砖块、乒乓球等 Atari 游戏与车杆物理模型都属于此类，挑战更大。

状态与动作

状态 S_t

- 环境的状态集 $\mathcal{S}$ 包含所有可能的状态。
- 可以是离散的：网格环境的二维坐标，共 9 个状态。
- 也可以是连续的：车杆环境是 4 维向量（车位置、车速度、杆角度、杆角速度）。
- 连续状态数量无限，难以用表格完整记录。

动作 A_t

- 环境的动作集 $\mathcal{A}$ 包含所有可能的动作。
- 动作表示智能体的决策，状态则为决策提供信息依据。
- 离散动作：网格环境 $\{A_{左}, A_{右}, A_{上}, A_{下}\}$，车杆 $\{A_{左}, A_{右}\}$。
- 连续动作：驾驶场景的三维动作（油门、刹车、方向盘转角），可离散化处理。

> **对照** 状态是环境的输出、决策的输入；动作是策略的输出、环境的输入。二者维度的离散或连续，直接决定后续用表格型方法还是函数近似方法。

状态转移概率

$$p(s', r \mid s, a) = \Pr\left[S_{t+1} = s', R_{t+1} = r \mid S_t = s, A_t = a\right] \tag{7-3}$$

$$p(s' \mid s, a) = \Pr\left[S_{t+1} = s' \mid S_t = s, A_t = a\right] = \sum_{r \in \mathcal{R}} p(s', r \mid s, a) \tag{7-4}$$

状态转移由四元组 (s, a, s', r) 描述：在状态 s 选择动作 a 后，环境依概率 $p(s', r \mid s, a)$ 转移到 s' 并产生奖励 r；对 r 求和即得只含状态的转移概率。

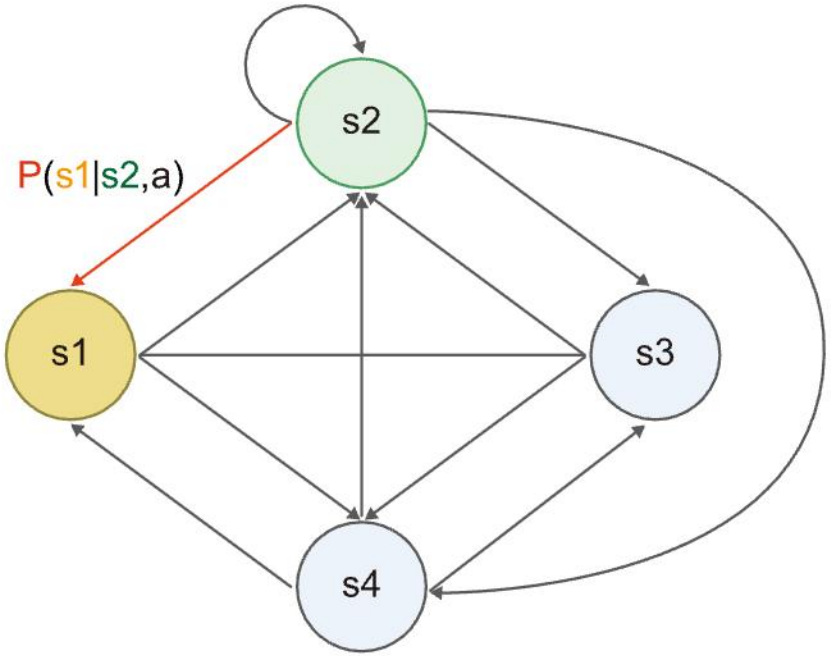


图 7.3　状态转移示意图

s_2 执行 a 后，可能转移到 s_1、s_3，也可能留在 s_2。

奖励函数

$$r(s,a)=\mathbb{E}\left[R_{t+1}\mid S_t=s,A_t=a\right]=\sum_{r\in\mathcal{R}} r\sum_{s'\in\mathcal{S}} p(s',r\mid s,a) \tag{7-5}$$

$r(s,a)$ 为标量，表示在状态 s 执行动作 a 后的期望即时奖励；时刻 t 获得的奖励记为随机变量 R_t。

- 奖励是环境给智能体的唯一评价信号，策略优化的目标由它定义。
- 同一动作在不同状态下可能获得不同奖励，因此奖励写成 (s,a) 的函数。
- 状态转移存在随机性时，对 s' 与 r 求期望，得到与转移无关的确定性标量。

奖励与回报不同：奖励是单步的即时信号，回报（7.1.3 节末）是折扣累积后的长期量。价值函数估计的正是回报的期望。

式 (7-3)–(7-5) 的数值实例

图 7.2(a) 的网格：状态 $s=(2,2)$、动作 $a=$ 右，打滑 10%。

s'	r	$p(s',r \mid s,a)$
(2,3)	−1	0.80
(1,2)	−1	0.10
(3,2)	−1	0.10

三项之和为 1：主方向 0.8、两个垂直方向各 0.1。奖励只由落点决定，因此每个后继只对应一个 r。

$$p(s' \mid s,a)=\sum_r p(s',r \mid s,a)$$

$$p((2,3) \mid s,a)=0.80$$

式 (7-4)：对 r 求和，三种后继各得 0.80 / 0.10 / 0.10。

$$\begin{aligned} r(s,a) &= \sum_r r \sum_{s'} p(s',r \mid s,a) \\ &= 1.00 \times (-1) \\ &= -1.00 \end{aligned}$$

式 (7-5)：奖励与落点无关地求和，得到一个确定性标量。

对照 同一套计算在 $s=(1,2)$ 向右时得到 $r=-4.20$：有 0.8 的概率直接撞进炸弹 $(1,3)$，把 -5 折进来。

代码 token-to-llm/src/rl/transition.py；式 (7-3)–(7-5)

幕

$$\tau = (S_1, A_1, R_2, S_2, A_2, R_3, \ldots, S_T) \tag{7-6}$$

幕（episode，或称轨迹）由离散时序 $t = 1, 2, \ldots, T$ 的状态、动作与奖励序列构成；S_T 为终止状态，R_{t+1} 表示执行 A_t 后获得的奖励。

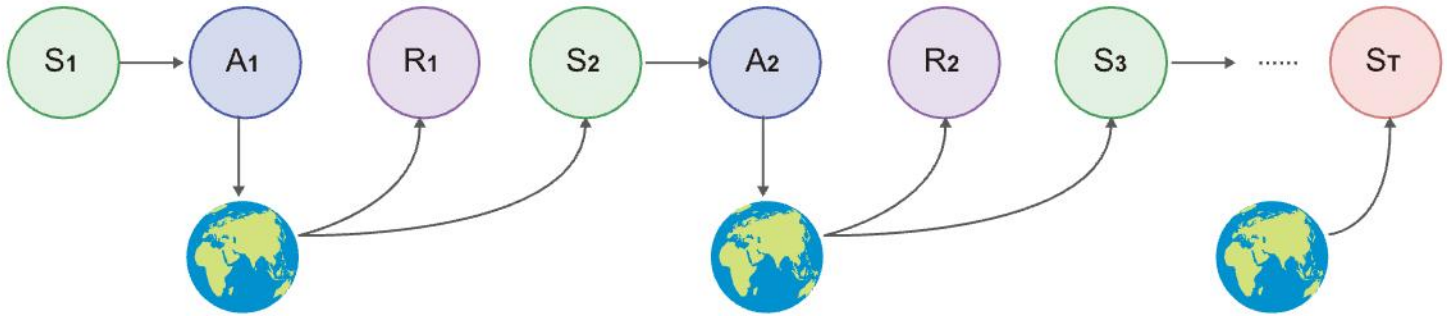


图 7.4　幕数据示例

- 奖励的下标比动作大 1：R_{t+1} 是执行 A_t 之后环境返回的信号。
- 分幕任务在 S_T 结束；连续任务没有终止状态，需要折扣因子保证回报收敛。

图 《大语言模型：训练、精调与对齐》图 7.4；式 (7-6)

回报

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \tag{7-7}$$

折扣因子 $\gamma \in [0,1]$ 调节未来奖励的权重（常取 $\gamma = 0.9$）；第 k 项奖励的系数为 γ^k，与求和式的下标 $t+k+1$ 一致。

作用一

反映未来的不确定性：越远的奖励越不可靠，权重越低。

作用二

保证无限时域下回报收敛：$\gamma < 1$ 时几何级数有界。

作用三

调节智能体的短视程度：$\gamma \to 0$ 只看即时奖励，$\gamma \to 1$ 更重视长期。

回报是对一条具体轨迹算出的标量；价值函数则是对所有可能轨迹取期望。

回报的递归关系

$$G_t = R_{t+1} + \gamma\left(R_{t+2} + \gamma R_{t+3} + \right. \tag{7-8}$$

$$G_t = R_{t+1} + \gamma G_{t+1} \tag{7-9}$$

把式 (7-7) 中从 R_{t+2} 起的部分提出公因子 γ，括号内正是 G_{t+1} 的定义。

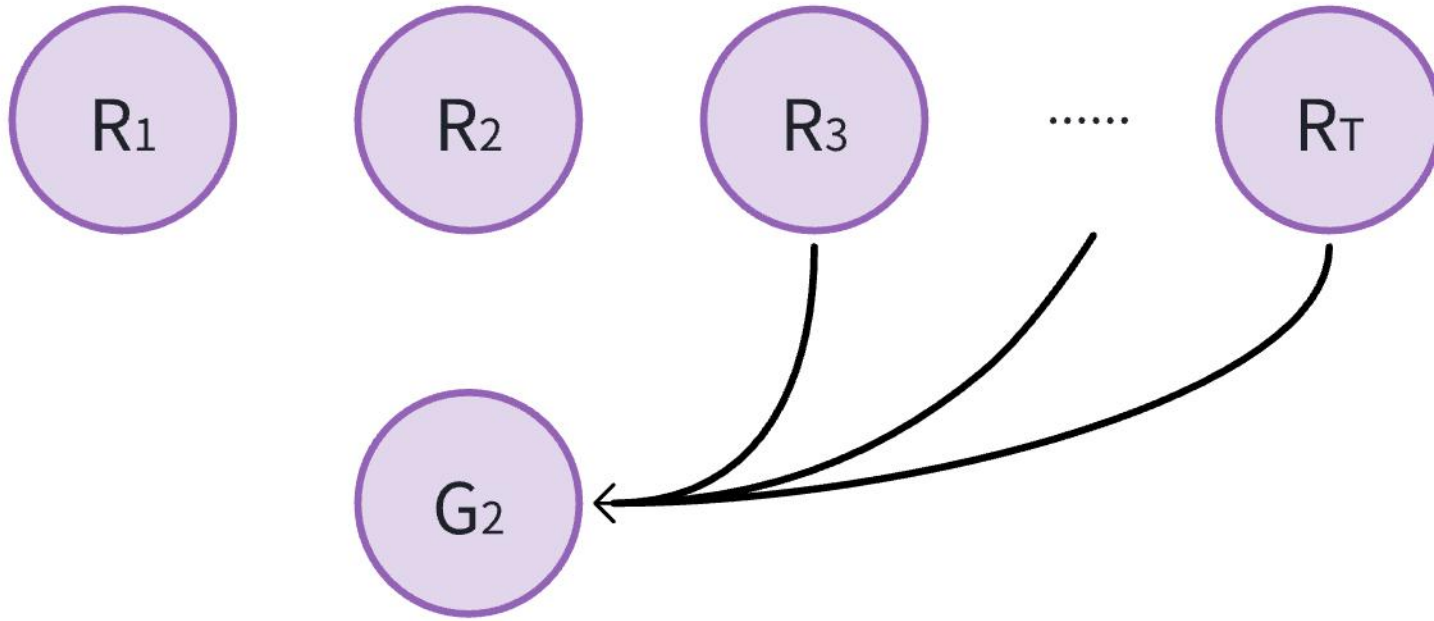


图 7.5　回报计算示意图

要点　式 (7-9) 是全部价值型算法的起点：当前回报 = 即时奖励 + 折扣后的下一回报。贝尔曼方程、时序差分与自举都建立在这一递推之上。

图　《大语言模型：训练、精调与对齐》图 7.5；式 (7-8)、(7-9)

策略

策略 π 定义了在状态 s 下选择动作的规则，可通过学习或搜索得到，目标是最大化长期累积奖励。

确定性策略

$\pi(s) = a$：在状态 s 下直接输出确定的动作 a。

实现简单、执行稳定；但若不加探索，容易漏掉更优动作。

随机性策略

$\pi(a \mid s) = \Pr\{A_t = a \mid S_t = s\}$：给出在状态 s 下选择动作 a 的概率。

记 $\pi(\cdot \mid s)$ 为状态 s 下动作的概率分布，天然带有探索性。



依据 《大语言模型：训练、精调与对齐》第 7.1.4 节（策略）

状态价值与动作价值

$$v_\pi(s) = \mathbb{E}_\pi\left[G_t \mid S_t = s\right] \tag{7-10}$$

状态价值函数：从状态 s 出发，在策略 π 下执行动作的累积奖励预测。多幕任务中统计全局状态价值，综合不同幕中 $S_t = s$ 的回报 G_t 的期望。

$$q_\pi(s, a) = \mathbb{E}_\pi\left[G_t \mid S_t = s, A_t = a\right] \tag{7-11}$$

动作价值函数：在状态 s 下执行动作 a 后，继续按策略 π 行动的累积奖励预测。

- $v_\pi(s)$ 评价“处在某个状态有多好”，$q_\pi(s, a)$ 评价“在某个状态做某个动作有多好”。
- 有了 $q_\pi(s, a)$，可直接用 $\arg\max_a q_\pi(s, a)$ 决策动作 a，无需知道环境模型。

依据 《大语言模型：训练、精调与对齐》第 7.1.4 节（式 (7-10)、(7-11)）

最优价值函数与最优策略

$$v_*(s) = \max_\pi v_\pi(s) \tag{7-12}$$

$$q_*(s,a) = \max_\pi q_\pi(s,a) \tag{7-13}$$

$$\pi_* = \arg\max_\pi v_\pi(s) \tag{7-14}$$

$$\pi_* = \arg\max_\pi q_\pi(s,a) \tag{7-15}$$

强化学习的目标是求解最优策略 π_*，以最大化长期累积奖励；最优策略达到最优价值：$v_{\pi_*}(s) = v_*(s)$，$q_{\pi_*}(s,a) = q_*(s,a)$。

- 最优策略通常需要极大计算资源，难以穷举所有状态转移。
- 小规模状态/动作集（表格型任务）可用动态规划求解；未知环境则依赖函数近似。
- 贝尔曼最优方程刻画最优价值函数必须满足的递归性质，见 7.1.5 节。

依据 《大语言模型：训练、精调与对齐》第 7.1.4 节（式 (7-12)–(7-15)）

贝尔曼方程

贝尔曼方程描述价值函数的递归结构，是计算、近似和学习价值函数的基础。先展开状态价值：

$$
\begin{aligned}
v_\pi(s) &= \mathbb{E}_\pi\left[G_t \mid S_t = s\right] \\
&= \sum_{a \in \mathcal{A}} \pi(a \mid s) \cdot \mathbb{E}_\pi\left[G_t \mid S_t = s, A_t = a\right] \\
&= \sum_{a \in \mathcal{A}} \pi(a \mid s) \cdot q_\pi(s, a)
\end{aligned}
$$

第一步按定义展开；第二步用全期望公式，对动作 a 按策略概率 $\pi(a \mid s)$ 加权；第三步代回动作价值函数的定义。

结论：状态价值等于该状态下各动作价值的策略加权平均。反过来，动作价值可由即时奖励与下一状态价值表示，这正是下面两页的推导。

第一步

按定义展开为对回报的期望，$v_\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s]$ 。

第二步

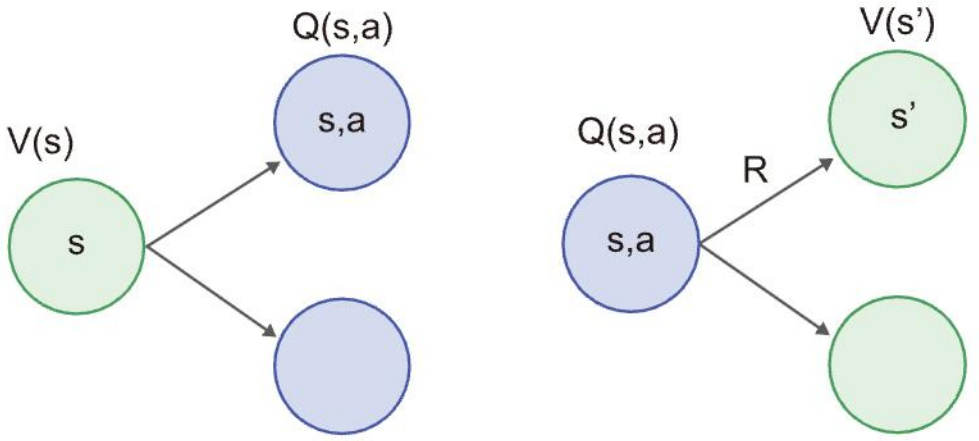
用全期望公式对动作分层，条件中多出 $A_t = a$，外层按 $\pi(a \mid s)$ 加权。

动作价值的展开

$$
\begin{aligned}
q_\pi(s,a) &= \mathbb{E}_\pi\left[G_t \mid S_t=s, A_t=a\right] \\
&= \mathbb{E}_\pi\left[\sum_{k=0}^{\infty}\gamma^k R_{t+k+1} \mid S_t=s, A_t=a\right] \\
&= \mathbb{E}_\pi\left[R_{t+1}+\gamma\sum_{k=0}^{\infty}\gamma^k R_{t+k+2} \mid S_t=s, A_t=a\right] \\
&= \mathbb{E}_\pi\left[R_{t+1} \mid S_t=s, A_t=a\right] + \gamma\,\mathbb{E}_\pi\left[G_{t+1} \mid S_t=s, A_t=a\right] \\
&= r(s,a) + \gamma\sum_{s'\in\mathcal{S}} p(s' \mid s,a)\cdot \mathbb{E}_\pi\left[G_{t+1} \mid S_{t+1}=s'\right] \\
&= r(s,a) + \gamma\sum_{s'\in\mathcal{S}} p(s' \mid s,a)\, v_\pi(s')
\end{aligned}
$$

① 回报写成级数、取出 $k=0$ 项；② 按期望的线性拆项，第一项即 $r(s,a)$，第二项对 s' 展开并用马尔可夫性质换条件；③ 按式 (7-10) 识别为 $v_\pi(s')$。结果 $q_\pi(s,a) = r(s,a)+\gamma\sum_{s'}p(s' \mid s,a)v_\pi(s')$ 与 $v_\pi(s)=\sum_a \pi(a \mid s)q_\pi(s,a)$ 联立即得贝尔曼期望方程。

状态价值与动作价值的转换



(a) 状态价值　　(b) 动作价值

图 7.6　贝尔曼 QV 转化

- $(s) \to (s,a)$：状态价值按策略对动作加权，$v_\pi(s) = \sum_a \pi(a \mid s) q_\pi(s,a)$。
- $(s,a) \to (s')$：动作价值经奖励与转移概率回连到下一状态，$q_\pi(s,a) = r(s,a) + \gamma \sum_{s'} p(s' \mid s,a) v_\pi(s')$。
- 两次代入即得贝尔曼期望方程的两种写法（下页）。

贝尔曼期望方程

$$v_\pi(s) = \sum_{a \in \mathcal{A}} \pi(a \mid s)\, q_\pi(s,a) \tag{7-16}$$

$$q_\pi(s,a) = r(s,a) + \gamma \sum_{s' \in \mathcal{S}} p(s' \mid s,a)\, v_\pi(s') \tag{7-17}$$

$$v_\pi(s) = \sum_{a \in \mathcal{A}} \pi(a \mid s) \left(r(s,a) + \gamma \sum_{s' \in \mathcal{S}} p(s' \mid s,a)\, v_\pi(s') \right) \tag{7-18}$$

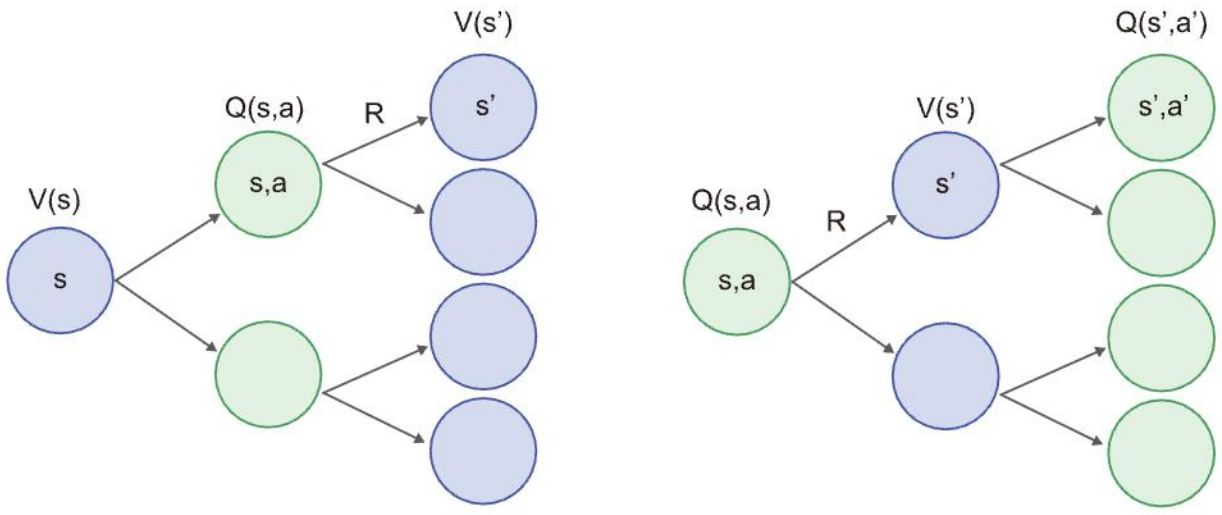
$$q_\pi(s,a) = r(s,a) + \gamma \sum_{s' \in \mathcal{S}} p(s' \mid s,a) \sum_{a' \in \mathcal{A}} \pi(a' \mid s')\, q_\pi(s',a') \tag{7-19}$$

式 (7-16) 把 (7-17) 代入；式 (7-19) 把 (7-16) 代入 (7-17)。$q_\pi(s,a)$ 可由下一状态动作 (s',a') 的 $q_\pi(s',a')$ 回溯计算，$v_\pi(s)$ 同理。

- 四个方程只含 v_π 与 q_π 两个未知函数，给定策略 π 后是线性方程组。
- “期望”来自两处：动作按 π 抽样，下一状态按 p 抽样。

依据 《大语言模型：训练、精调与对齐》第 7.1.5 节（式 (7-16)–(7-19)）

贝尔曼方程的一步回溯



(a) 状态价值　　(b) 动作价值

图 7.7　贝尔曼期望方程示意图

- (a) 状态 s 的价值经动作与奖励，连到下一状态 s' 的价值。
- (b) 动作 (s, a) 的价值经奖励连到 s'，再经策略展开为 (s', a') 的动作价值。
- 两条回溯路径分别对应式 (7-18) 与式 (7-19) 的嵌套求和。

贝尔曼最优方程

$$v_*(s) = \max_{a \in \mathcal{A}} q_*(s,a) \tag{7-20}$$

$$q_*(s,a) = r(s,a) + \gamma \sum_{s' \in \mathcal{S}} p(s' \mid s,a)\, v_*(s') \tag{7-21}$$

$$v_*(s) = \max_{a \in \mathcal{A}} \left(r(s,a) + \gamma \sum_{s' \in \mathcal{S}} p(s' \mid s,a)\, v_*(s') \right) \tag{7-22}$$

$$q_*(s,a) = r(s,a) + \gamma \sum_{s' \in \mathcal{S}} p(s' \mid s,a) \max_{a' \in \mathcal{A}} q_*(s',a') \tag{7-23}$$

与期望方程的唯一差别：对动作不再按 π 加权，而是取最大值。最优策略 $a_* \sim \arg\max_a q(s,a)$ 可直接给出最大回报，无需依赖特定策略。

当拥有完整环境模型（已知 $p(s' \mid s,a)$ 与 $r(s,a)$）时，可用动态规划求解最优价值（7.3 节）。实际中转移概率与奖励通常未知，于是转向采样方法（7.4、7.5）。

依据 《大语言模型：训练、精调与对齐》第 7.1.5 节（式 (7-20)–(7-23)）

期望方程与最优方程的对比

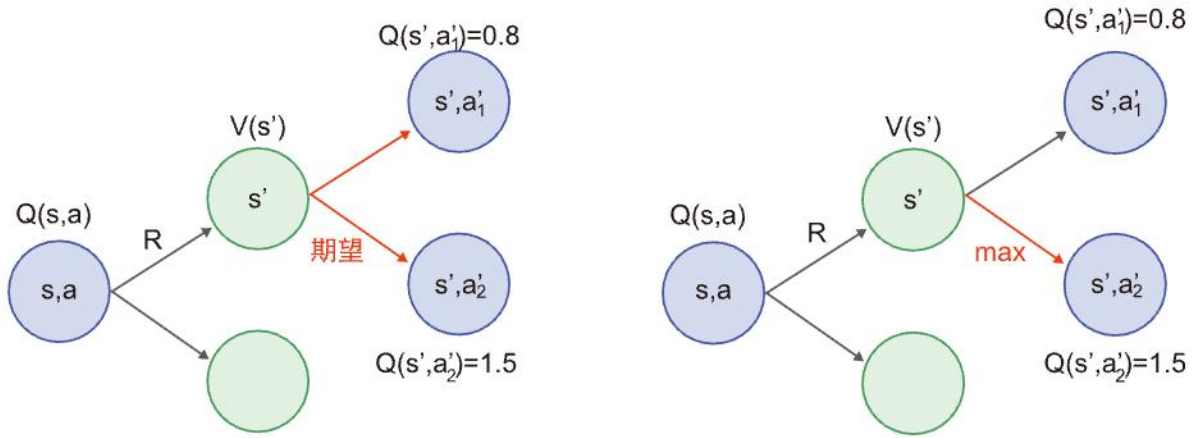


图 7.8　贝尔曼最优方程示意图

- (a) 对所有下一动作 $(s', a'_1), (s', a'_2)$ 按概率加权，得到期望价值。
- (b) 直接取 $Q(s', a')$ 的最大值，对应贪心动作选择，无需对所有动作积分。
- 核心特性：$v_*(s)$ 已包含未来最优回报的期望；基于 $q_*(s, a)$ 用 $\arg\max_a q_\pi(s, a)$ 选动作更直接，无需额外搜索。

贝尔曼方程的作用

结构

递归分解

把复杂的长远问题转化为“当前一步 + 未来多步”，价值函数的计算由此可迭代。

作用

从抽象到计算

把 MDP 的抽象定义转化为具体的计算目标，即价值函数的最大化。

地位

价值方法的基石

可精确求解、迭代估计和函数近似；基于价值的强化学习方法都以它为基础。

直接计算所有未来路径的奖励总和几乎不可行：时间步可能无限多，状态空间可能非常庞大。贝尔曼方程把这一步不可行的求和，换成了一次只依赖相邻状态的回溯。

下一节先给出方法分类（7.2），再按“模型已知 → 模型未知”的顺序展开：动态规划（7.3）、蒙特卡洛（7.4）、时序差分（7.5）、策略梯度（7.6）与演员-评论家（7.7）。

7.2

强化学习方法

本节内容

7.2 强化学习方法分类

按“学什么”划分三大类：学价值函数再据此选动作、直接学策略、以及把两者结合的演员-评论家。

强化学习方法分类

本书聚焦适用于未知环境的强化学习方法，分为三类。划分依据是“算法最终学到什么、又靠什么选动作”。

一 · 基于价值函数

学价值，再选动作

动态规划、蒙特卡洛方法、时序差分方法。估计 v_π 或 q_π，再用 $\arg\max_a q(s,a)$ 决策。

二 · 基于策略梯度

直接优化策略

对参数化策略 $\pi_\theta(a \mid s)$ 求梯度并做梯度上升，重点是策略梯度的数学推导。

三 · 演员-评论家

价值与策略融合

评论家估计价值、演员更新策略，如演员-评论家算法、TRPO 与 PPO。

环境已知	环境未知	状态连续
动态规划	蒙特卡洛 / 时序差分	策略梯度 / 演员-评论家

表 7.1 汇总本章涉及的全部方法及其特性；7.5.7 节总结基于价值的方法，7.7.4 节总结基于策略的方法。

表 7.1　强化学习方法分类及特性

类型	具体方法	说明
1. 动态规划	值迭代 / 策略迭代	迭代估计状态价值函数。
	广义策略迭代	在满足条件下收敛至最优策略。
2. 蒙特卡洛方法	状态价值估计	通过完整轨迹估计 $V(s)$。
	动作价值估计	估计动作值函数 $Q(s,a)$。
	同轨策略控制	基于当前策略采样更新。
3. 时序差分学习	表格型学习	适用于非分幕任务。
	SARSA	同轨策略，更新依赖 (S, A, R, S', A')。
	Q 学习	经典离轨策略算法。
	期望 SARSA	基于期望 Q 值更新，降低方差。
	DQN	神经网络扩展至连续状态空间。
	多步时序差分	结合蒙特卡洛与 TD 优点估计价值。

表 7.1 上半部分：基于价值函数的三类方法。同类型内的方法共用左侧的类型标签。

表 7.1　强化学习方法分类及特性（续）

类型	具体方法	说明
4. 策略梯度	策略梯度理论	直接优化策略。
	REINFORCE	蒙特卡洛策略梯度方法。
	离轨策略 REINFORCE	使用重要性采样的变体。
5. 演员-评论家	演员-评论家框架	演员更新策略，评论家评估价值。
	优势演员-评论家（A2C）	利用优势函数 $A(s,a)$ 减少方差。
	TRPO	KL 散度约束保证稳定性。
	PPO	目标函数裁剪简化约束。

表 7.1 下半部分：策略梯度与演员-评论家。五类方法依次在 7.3–7.7 展开。

基于价值与基于策略的方法

表 7.1 的五类方法，在本书中归为两条脉络来总结。理解这条分界，才能看清后面每一节在解决什么问题。

基于价值函数

动态规划、蒙特卡洛方法、时序差分学习，统一在 7.5.7 节总结。

先估计价值，再由价值导出策略；策略通常是隐式的（对 Q 取 $\arg\max$）。

难点：连续状态空间下表格无法存储，需要 DQN 之类的函数近似。

基于策略梯度

策略梯度与演员-评论家，统一在 7.7.4 节总结。

直接对策略参数求梯度；价值函数作为基线或评论家，用于降低方差。

难点：梯度估计的方差与每次更新的步长控制，TRPO 与 PPO 正是为此设计。

> **共同点** 两条脉络都建立在贝尔曼方程的递归结构上：价值方法直接用回溯更新价值，策略方法则把状态转移概率内化到稳态分布中，从而绕开对环境模型的建模。

依据 《大语言模型：训练、精调与对齐》第 7.2 节（表 7.1 后的归属说明）

7.3

动态规划

环境模型已知时，直接按贝尔曼方程迭代：先评估一个策略值多少，再据此改进策略，如此往复。

本节内容

7.3 动态规划

7.3.1 小结

动态规划方法

当环境模型已知时，可根据贝尔曼方程用动态规划（DP）评估价值函数并优化策略。在模型已知且计算资源无限的理想条件下，DP 能收敛到最优价值函数与最优策略。

已知模型

$p(s' \mid s, a)$ 与 $r(s, a)$

→

策略评估

迭代求 V_π

→

策略改进

贪心得到 π'

→

收敛

$\pi_* \to v_*$

- DP 通过交替进行**策略评估**与**策略改进**求解最优策略。
- 状态空间 $\mathcal{S}$ 与动作空间 $\mathcal{A}$ 规模过大时，DP 计算开销高。
- 实际中常改用非 DP 方法（蒙特卡洛法或时序差分学习）近似最优价值函数与策略。

依据 《大语言模型：训练、精调与对齐》第 7.3 节

策略评估

策略评估解决"预测"问题：若智能体始终遵循策略 π，它在状态 s 的期望累积回报是多少？给定 π 后，用大小为 $|\mathcal{S}|$ 的表格存 $V_\pi(s)$，迭代更新。

$$
\begin{aligned}
V_\pi(s) &= \mathbb{E}_\pi\left[G_t \mid S_t = s\right] && (7\text{-}24)\\
&= \mathbb{E}_\pi\left[R_{t+1} + \gamma G_{t+1} \mid S_t = s\right] && (7\text{-}25)\\
&= \mathbb{E}_\pi\left[R_{t+1} + \gamma V_\pi(S_{t+1}) \mid S_t = s\right] && (7\text{-}26)\\
&= \sum_a \pi(a \mid s) \sum_{s', r} p(s', r \mid s, a)\left(r + \gamma V_\pi(s')\right) && (7\text{-}27)
\end{aligned}
$$

式 (7-25) 用回报的递归式 (7-9)；式 (7-26) 用 V_π 替换下一回报的期望（自举）；式 (7-27) 把对动作与对 (s', r) 的期望都写成加权求和。

四步的作用各不相同：定义 → 递归 → 自举 → 加权求和。第 3 步最关键：把"未来所有奖励的期望"换成"下一状态的价值"，此后才能用表格迭代求解。

迭代策略评估

$$V_\pi(s) \leftarrow \sum_a \pi(a \mid s) \sum_{s', r} p(s', r \mid s, a)\,(r + \gamma V_\pi(s')) \tag{7-28}$$

用旧表算出右端，写回 $V_\pi(s)$。智能体按 $\pi(a \mid s)$ 选动作，环境按 $p(s', r \mid s, a)$ 转移到 s' 并返回 r；更新时对全部可能的 a 与 (s', r) 加权平均。

终止条件：$\max_{s \in \mathcal{S}} |V_{\text{old}}(s) - V_{\text{new}}(s)| < \theta$，其中 $\theta > 0$ 为预设阈值。实现时可维护新旧两个数组（新旧值分离），也可用单数组就地更新。该方法同样可扩展到动作价值 $Q(s, a)$ 的迭代评估。

初始化

$V(s)$ 任意，$V(S_T) = 0$

→

逐状态更新

式 (7-28)

→

求最大变化

$\Delta = \max |v - V(s)|$

→

判断

$\Delta < \theta$ 则停

θ 越小，评估越精确、迭代次数越多；实际中常在精度与耗时之间取折衷。新旧数组分离便于并行，单数组就地更新收敛更快。

依据 《大语言模型：训练、精调与对齐》第 7.3 节（式 (7-28)、算法 1）

算法 1　迭代策略评估算法

算法 1 迭代策略评估算法

输入: 待评估策略 π，状态转移函数 $p(s', r|s, a)$，折扣因子 γ，阈值 $\theta > 0$
输出: 状态价值函数 $V_\pi(s)$

1: 初始化 $V(s)$ 对所有 $s \in \mathcal{S}$，其中终止状态 S_T 满足 $V(S_T) = 0$
2: **repeat**
3: $\quad \Delta \leftarrow 0$
4: $\quad$ **for** 每个状态 $s \in \mathcal{S}$ **do**
5: $\quad\quad v \leftarrow V(s)$ ▷ 保存旧值
6: $\quad\quad V(s) \leftarrow \sum_a \pi(a|s) \sum_{s',r} p(s', r|s, a)\,(r + \gamma V(s'))$
7: $\quad\quad \Delta \leftarrow \max(\Delta, |v - V(s)|)$
8: $\quad$ **end for**
9: **until** $\Delta < \theta$

以网格环境为例：逐状态按式 (7-28) 更新 $V_\pi(s)$；第 5 步保存旧值，第 7 步用它衡量本轮更新幅度。

策略改进

得到 $V_\pi(s)$ 后，策略改进的目标是寻找更优策略 π'。对每个状态遍历所有可行动作，选使价值最大的动作。

$$\pi'(s) = \arg\max_{a \in \mathcal{A}} \sum_{s'} p(s' \mid s, a)\, V(s')$$

这是策略改进的直观形式：用状态价值 $V(s')$ 乘以转移概率，比较各动作的期望效果，取最大者。

环境存在随机状态转移时（$p(s' \mid s, a) < 1$），需考虑所有可能转移路径的期望价值。动态规划的标准设定中环境转移通常是确定性的，例如 $p(s' \mid s, a) = 1$。使用动作价值 $q_\pi(s, a)$ 的优势是**可直接选择最优动作**，其更新公式由贝尔曼方程导出：

$$q_\pi(s, a) = \mathbb{E}\left[R_{t+1} + \gamma v_\pi(S_{t+1}) \mid S_t = s, A_t = a\right] \tag{7-29}$$

$$= \sum_{s', r} p(s', r \mid s, a)\left(r + \gamma v_\pi(s')\right) \tag{7-30}$$

$$\pi'(s) = \arg\max_{a \in \mathcal{A}} q_\pi(s, a) \tag{7-31}$$

式 (7-31) 生成改进策略 π'；新策略满足策略改进定理，即 $\forall s : v_{\pi'}(s) \geqslant v_\pi(s)$。

依据 《大语言模型：训练、精调与对齐》第 7.3 节（式 (7-29)–(7-31)）

状态价值与动作价值的开销

用状态价值 $V_\pi(s)$

存储 $|\mathcal{S}|$ 个值，空间最省。

改进策略时要对每个动作重新做一次转移概率加权求和，才能比较动作优劣。

适合转移确定、动作数较少的网格类任务。

用动作价值 $q_\pi(s,a)$

存储 $|\mathcal{S}| \times |\mathcal{A}|$ 个值，空间开销为状态价值函数的 $|\mathcal{A}|$ 倍。

改进时直接取 $\arg\max_a q_\pi(s,a)$，无需再做期望，决策更直接。

后续的 SARSA、Q 学习都沿用动作价值这一表示。

> **选择** 动态规划在网格环境中，动作价值函数的空间开销是状态价值的 $|\mathcal{A}|$ 倍；换来的是策略改进时无需遍历转移概率。这是"存储换计算"的典型权衡。

为什么用 V 比较动作更麻烦

由 V：$\pi'(s) = \arg\max_a \sum_{s'} p(s' \mid s,a)\big[r(s,a) + \gamma V(s')\big]$

由 Q：$\pi'(s) = \arg\max_a Q(s,a)$

左边要多乘一层环境模型 $p(s' \mid s,a)$ 与 $r(s,a)$；右边只是一个查表取最大。

量	条目数	来源
$p(s' \mid s,a)$	324	须估计
$r(s,a)$	36	须估计
$V(s)$	9	可由样本估
$Q(s,a)$	36	可由样本估

实测：7 个非终止状态、4 个动作，场景取 `wind`（主方向 0.8，0.2 概率多下滑一格）。

12

由 V 每状态改进所需乘加

3

由 Q 每状态改进所需比较

转移模型稍有偏差，由 V 选出的动作就错。把 `wind` 误设为确定性转移后，7 个状态里有 **3 个**选错动作（(1,1)、(2,1)、(2,2)），平均 v 从 $+7.934$ 掉到 $+7.666$。

> **结论** V 缺动作维度，比较动作时只能"补一层模型"；Q 把动作写进下标，贪心改进不必知道环境怎么转移。

广义策略迭代

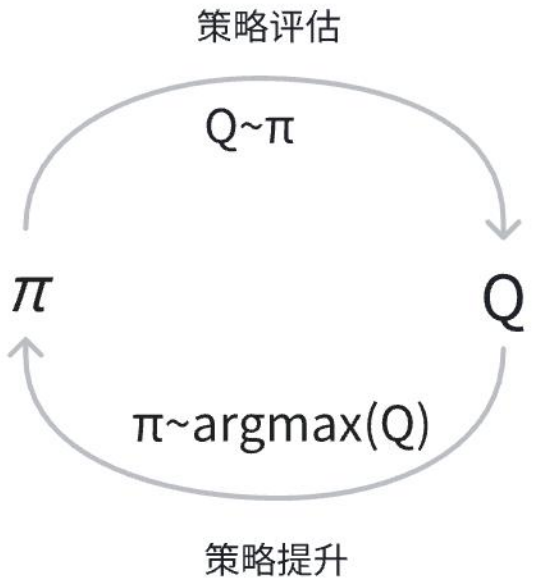


图 7.9　广义策略迭代

$$\pi_0 \xrightarrow{\text{评估}} v_{\pi_0} \xrightarrow{\text{改进}} \pi_1 \xrightarrow{\text{评估}} v_{\pi_1} \xrightarrow{\text{改进}} \cdots \xrightarrow{\text{改进}} \pi_* \xrightarrow{\text{评估}} v_* \tag{7-32}$$

广义策略迭代（GPI）交替进行策略评估与策略改进：一次评估把当前策略的价值估准，一次改进把策略推向更优，直到收敛到 π_* 与 v_*。

- 价值估计 v_{π_i} 逐步逼近当前策略 π_i 的真实价值，同时策略持续改进。
- GPI 不仅是动态规划的理论框架，也支撑蒙特卡洛法与时序差分法。
- 那些方法只能近似求解，但 GPI 框架仍保证其收敛到最优解附近。

策略改进定理

$$\pi'(s) = \arg\max_{a \in \mathcal{A}} q_\pi(s, a) \tag{7-33}$$

GPI 中的策略改进以贪心操作实现：对每个状态，取动作价值最大的动作作为新策略。

$$\begin{aligned} q_\pi\left(s, \pi'(s)\right) &= \max_{a \in \mathcal{A}} q_\pi(s, a) && (7\text{-}34) \\ &\geqslant q_\pi\left(s, \pi(s)\right) && (7\text{-}35) \\ &\geqslant v_\pi(s) && (7\text{-}36) \end{aligned}$$

式 (7-34) 由贪心选择直接得到；式 (7-35) 因为 $\pi(s)$ 也是可选项之一；式 (7-36) 因为按 π 对动作取期望不会超过其中最大的那个（$v_\pi(s) = \sum_a \pi(a \mid s) q_\pi(s, a) \leqslant \max_a q_\pi(s, a)$）。

三步连起来即 $q_\pi(s, \pi'(s)) \geqslant v_\pi(s)$，说明新策略在每个状态都不比旧策略差；反复应用即得策略改进定理 $\forall s : v_{\pi'}(s) \geqslant v_\pi(s)$。

依据 《大语言模型：训练、精调与对齐》第 7.3 节（式 (7-33)–(7-36)）

动态规划方法的总结

机制

递归求值

状态价值由即时奖励 r 与折扣后的下一状态价值 $\gamma v_\pi(s')$ 构成，这一迭代结构适用于所有状态的价值评估。

目的

评估为改进服务

策略评估的目标是为策略改进提供基础：通过状态价值函数推导出更优策略。

边界

依赖环境模型

环境未知时贝尔曼方程无法直接求解，需依赖经验数据估计期望回报，或采用模型学习方法。

动态规划把贝尔曼方程当成一份可以直接执行的“作业单”：只要知道 $p(s' \mid s, a)$ 与 $r(s, a)$，就能对每个状态反复代入、反复改进。

下一节起，模型不再已知。7.4 的蒙特卡洛用完整幕的回报替代期望，7.5 的时序差分进一步只用一步奖励加自举。

7.4

蒙特卡洛方法

本节内容

7.4.1 蒙特卡洛价值评估

7.4.2 试探性出发蒙特卡洛控制

7.4.3 非试探性出发蒙特卡洛控制

不再需要状态转移概率：采样足够多的完整幕，用状态的平均回报直接估计它的价值，再据此改进策略。

蒙特卡洛方法的基本思路

动态规划中的广义策略迭代需要已知状态转移概率。未知环境中，状态价值的估计可以通过回报的期望获得，即 $v_\pi(s) = \mathbb{E}\left[G_t \mid S_t = s\right]$。蒙特卡洛（MC）用采样实现这个期望。

从 S_1 出发
按策略 π 采样

→

N 幕完整数据
直到终止状态 S_T

→

算每幕的 G_t
从后向前折扣累加

→

求平均
作为 $v_\pi(s)$ 的估计

- MC 直接从幕数据学习，**无需对环境建模**。
- 为估计回报 G_t，必须采样完整的幕序列 $S_1, A_1, R_1, \ldots, S_T, A_T, R_T$，包含终止状态 S_T。
- "完整"是 MC 与后续时序差分方法最根本的分界：MC 要等到一幕结束才能更新。

依据 《大语言模型：训练、精调与对齐》第 7.4.1 节

折扣回报的平均估计

$$G_t = \sum_{k=0}^{T-t-1} \gamma^k R_{t+k+1} \tag{7-37}$$

与无限时域的式 (7-7) 相比，求和上限由 ∞ 改为 $T-t-1$：幕在 T 结束，此后的奖励不存在。

$$v_\pi(s) = \frac{\sum_{i=1}^{N} \sum_{t=1}^{T} \mathbb{I}\left[S_t^{(i)} = s\right] G_t^{(i)}}{\sum_{i=1}^{N} \sum_{t=1}^{T} \mathbb{I}\left[S_t^{(i)} = s\right]} \tag{7-38}$$

$\mathbb{I}[\cdot]$ 为二值指示函数，条件满足返回 1，否则返回 0；$S_t^{(i)}$ 是第 i 幕 t 时刻的状态。分子累加所有访问到 s 的回报，分母是访问次数，比值即平均回报。

在一幕数据中，状态 s 可能未被访问、访问一次或多次。式 (7-38) 把每次访问都计入，因此称为**每次访问蒙特卡洛估计**（Every-Visit MC）。

首次访问蒙特卡洛估计

若仅取每幕首次访问状态 s 的回报计算均值，则称为首次访问蒙特卡洛估计（First-Visit MC）。

$$v_\pi(s) = \frac{\sum_i^N \sum_{t=1}^T \mathbb{F}(s,t,i)\, G_t^{(i)}}{\sum_i^N \sum_{t=1}^T \mathbb{F}(s,t,i)} \tag{7-39}$$

$$\mathbb{F}(s,t,i) = \mathbb{I}\left[S_t^{(i)} = s \text{ 且 } \forall \tilde{t} < t,\ S_{\tilde{t}}^{(i)} \neq s\right] \tag{7-40}$$

$\mathbb{F}(s,t,i)$ 是首次访问函数：第 i 幕 t 时刻首次访问状态 s 时取 1，即此前所有时刻 $\tilde{t} < t$ 都没有访问过 s。

两式的结构完全相同，只把指示函数 $\mathbb{I}$ 换成首次访问函数 $\mathbb{F}$：分子分母同步变化，比值仍是“首次访问回报的均值”。

$\mathbb{I}$ 的作用

回答“这一刻是否在 s”：只做一次相等判断。

$\mathbb{F}$ 的作用

回答“这一刻是否是第一次在 s”：还要检查此前所有时刻。

依据 《大语言模型：训练、精调与对齐》第 7.4.1 节（式 (7-39)、(7-40)）

算法 2　首次访问型蒙特卡洛估计算法

算法 2 首次访问型蒙特卡洛估计算法

输入： 策略 π；状态集 $\mathcal{S}$；初始状态价值估计 $V(s)$（任意值）；空列表 $\hat{G}(s)$（$\forall s \in \mathcal{S}$）
输出： 状态价值函数估计 $V(s) \approx v_\pi(s)$

1: **for** 幕索引 $i = 1$ 到 N **do**
2:　　生成幕数据：$S_0, A_0, R_1, \ldots, S_{T-1}, A_{T-1}, R_T, S_T$　　▷ 终止状态 S_T
3:　　$G \leftarrow 0$　　▷ 初始化累积回报
4:　　**for** $t = T-1, T-2, \ldots, 0$ **do**　　▷ 反向遍历时刻
5:　　$G \leftarrow \gamma G + R_{t+1}$　　▷ 更新折扣回报
6:　　**if** 状态 S_t 未在 $S_0, S_1, \ldots, S_{t-1}$ 中出现 **then**　　▷ 首次访问检查
7:　　将 G 加入列表 $\hat{G}(S_t)$
8:　　$V(S_t) \leftarrow \text{average}(\hat{G}(S_t))$　　▷ 更新价值估计
9:　　**end if**
10:　　**end for**
11: **end for**

第 5 步从后向前递推：每退一步，先给已有回报乘 γ，再加上新的一步奖励，等价于式 (7-37) 的折扣累加。

首次访问与每次访问

首次访问

每个状态只使用其首次访问的回报。

各回报值相互独立，都是价值估计的独立同分布估计，**方差较低**。

适合对方差敏感的场景。

每次访问

一幕中多次访问同一状态时，每次都用其回报更新估计。

样本量更大，但同一状态的多次访问回报往往来自同一条轨迹、彼此相关，**方差可能更高**。

更注重样本效率。

> **权衡** 两种估计在幕数趋于无穷时都收敛到 $v_\pi(s)$；差别在于有限样本下的方差与样本效率。首次访问以丢弃重复访问为代价换取独立性，每次访问则相反。

动作价值的估计

同理，把“状态”换成“状态-动作对”，即得动作价值的首次访问蒙特卡洛估计。

$$q_\pi(s,a)=\frac{\sum_{i=1}^{N}\sum_{t=0}^{T-1}\mathbb{F}(s,a,t,i)\,G_t^{(i)}}{\sum_{i=1}^{N}\sum_{t=0}^{T-1}\mathbb{F}(s,a,t,i)} \tag{7-41}$$

$$\mathbb{F}(s,a,t,i)=\mathbb{I}\left[(S_t^{(i)},A_t^{(i)})=(s,a)\ \text{且}\ \forall \tilde{t}<t,\ (S_{\tilde{t}}^{(i)},A_{\tilde{t}}^{(i)})\neq(s,a)\right] \tag{7-42}$$

首次访问指示函数 $\mathbb{F}(s,a,t,i)$ 表示第 i 幕中状态-动作对 (s,a) 在时刻 t 首次被访问。求和上限为 $T-1$，因为终止状态之后不再有动作。

- 动作价值是控制问题的核心：有了 $q_\pi(s,a)$ 才能对策略做贪心改进。
- 状态价值只回答“站在哪里好”，动作价值还回答“该往哪走”。

依据 《大语言模型：训练、精调与对齐》第 7.4.1 节（式 (7-41)、(7-42)）

蒙特卡洛与动态规划的差别

蒙特卡洛

回报从终止时刻反向计算（回溯）。

对每个状态的价值估计**相互独立**，不依赖其他状态的估计。

通过采样通常获得**次优估计**，但对期望回报无偏。

动态规划

用奖励和下一时刻的价值估计更新当前价值，即**自举**。

需要已知环境模型，可找到全局最优解。

估计之间有依赖，误差会在状态之间传播。

> **要点** “是否自举”与“是否需要完整幕”是划分价值方法的两个坐标：MC 不自举、要完整幕；DP 自举、要模型；下一节的 TD 则自举、且只要一步数据。

逐幕交替的评估与改进

用蒙特卡洛方法得到更优的价值估计后，即可据此改进策略，实现广义策略迭代。与 7.3 节的 GPI 图（图 7.9）相同，只是“评估”改由采样完成。

采样一幕
按当前策略生成完整幕

→

策略评估
用观测回报更新 Q

→

策略改进
在该幕访问过的状态上贪心

→

再采样
用改进后的策略

- 采用逐幕交替的评估-改进流程：每幕结束后先评估，再改进，然后用改进后的策略采样新一幕。
- 试探性出发：从随机状态-动作对 (s, a) 开始采样，保证所有节点都能被访问。

评估

用这一幕的回报更新 $Q(S_t, A_t)$，只统计本幕首次访问的那一对。

改进

在同一遍反向遍历中直接改写 $\pi(S_t)$，无需等整幕评估完再统一改。

算法 3　试探性出发首次访问蒙特卡洛控制

算法 3 试探性出发首次访问蒙特卡洛控制

输入： 初始策略 $\pi(s) \in \mathcal{A}(s)$ $(\forall s \in \mathcal{S})$；动作价值估计 $Q(s,a)$（任意初始化）；空回报列表 $\hat{G}(s,a)$ $(\forall s,a)$
输出： 最优动作价值估计 $Q(s,a) \approx q_*(s,a)$

1: **loop**
2: 　随机选择初始状态 S_0 和动作 A_0　　▷ 试探性出发
3: 　生成幕数据：$S_0, A_0, R_1, S_1, A_1, \ldots, R_T, S_T$
4: 　$G \leftarrow 0$　　▷ 初始化累积回报
5: 　**for** $t = T-1, T-2, \ldots, 0$ **do**　　▷ 反向遍历
6: 　　$G \leftarrow \gamma G + R_{t+1}$　　▷ 更新折扣回报
7: 　　**if** 状态-动作对 (S_t, A_t) 未在 $(S_0, A_0), \ldots, (S_{t-1}, A_{t-1})$ 出现 **then**
8: 　　将 G 加入列表 $\hat{G}(S_t, A_t)$
9: 　　$Q(S_t, A_t) \leftarrow \text{average}(\hat{G}(S_t, A_t))$　　▷ 更新动作价值
10: 　　$\pi(S_t) \leftarrow \arg\max_a Q(S_t, a)$　　▷ 策略改进
11: 　　**end if**
12: 　**end for**
13: **end loop**

第 10 步把评估与改进放在同一遍反向遍历中完成：一处估计更新后，立即把该状态的策略改为贪心。

ε-贪心策略

试探性出发要求从任意状态-动作对出发，实际场景中往往不可行：机器人无法从任意状态启动；确定性策略下某些状态-动作对可能永远不被访问。

因此需要设计从固定状态出发、却能探索所有状态-动作对的采样方案。ϵ-贪心策略可平衡探索与利用：

$$\pi(a \mid s) = \begin{cases} 1 - \epsilon + \dfrac{\epsilon}{|\mathcal{A}(s)|} & \text{if } a = \arg\max_{a'} Q(s, a') \\ \dfrac{\epsilon}{|\mathcal{A}(s)|} & \text{otherwise} \end{cases} \tag{7-43}$$

以 $1-\epsilon$ 的概率选择当前最优动作（利用），以 ϵ 的概率在全部动作上均匀随机选择（探索）；最优动作本身也分到 $\epsilon/|\mathcal{A}(s)|$ 的份额。

两种情形

$a = \arg\max_{a'} Q(s, a')$ 时概率为 $1 - \epsilon + \epsilon/|\mathcal{A}(s)|$；其余动作各为 $\epsilon/|\mathcal{A}(s)|$。

归一检查

各类概率相加为 $1 - \epsilon + \epsilon = 1$，因此仍是一个合法的概率分布。

ε 的取值

较大的 ϵ，缓慢衰减

探索更充分，几乎所有状态-动作对都能被反复访问。

提高收敛的**可靠性**，但收敛速度变慢。

较小的 ϵ，快速衰减

更快把采样集中在当前最优动作附近。

可能加速收敛，但容易陷入**局部最优**。

> **做法** 实践中常让 ϵ 从较大值开始并逐步衰减：训练初期以探索为主，保证覆盖；后期以利用为主，让策略收敛。

ϵ-贪心是后续 SARSA、Q 学习、DQN 共用的行为策略，7.5 节会反复用到。

7.5

时序差分学习

不必等一幕结束：用“一步奖励 + 下一状态的当前估计”构造 TD 目标，边交互边更新价值。

本节内容

7.5.1 时序差分策略评估

7.5.2 SARSA：时序差分控制

7.5.3 Q 学习：离轨策略的时序差分控制

7.5.4 期望 SARSA

7.5.5 深度 Q 网络：DQN

7.5.6 多步时序差分

7.5.7 基于价值函数的强化学习方法总结

时序差分与蒙特卡洛的比较

时序差分（TD）学习与蒙特卡洛一样是无模型方法。区别在于：MC 必须从完整幕数据学习，要等一幕结束才能更新；TD 可以直接从不完整的幕数据学习，无需等待幕终止。

蒙特卡洛

依赖**真实回报** G_t，必须采样到终止状态 S_T。

回报是实际发生的，估计无偏，但方差较大。

只能用于分幕任务。

时序差分

采用**自举**：用当前价值估计 $V(S_{t+1})$ 构造目标，更新 $V(S_t)$。

只用一步数据即可更新，方差小，但引入偏差。

可用于非分幕的连续任务。

区别 MC 等到最后用真实回报算账，TD 每走一步就先按当前估计“预支”下一状态的价值，再据此修正当前估计。

TD(0) 更新

TD 学习的核心是用 TD 目标 $R_{t+1}+\gamma V(S_{t+1})$ 更新状态价值 $V(S_t)$，α 为步长。

$$V(S_t) \leftarrow (1-\alpha)V(S_t)+\alpha G_t \tag{7-44}$$

$$\leftarrow V(S_t)+\alpha\left(G_t-V(S_t)\right) \tag{7-45}$$

$$\leftarrow V(S_t)+\alpha\left(R_{t+1}+\gamma V(S_{t+1})-V(S_t)\right) \tag{7-46}$$

式 (7-44) 是旧估计与新目标的凸组合；式 (7-45) 把它改写成“旧值 + 步长 × 误差”的增量形式；式 (7-46) 把 MC 的完整回报 G_t 换成单步 TD 目标 $R_{t+1}+\gamma V(S_{t+1})$。

由于只依赖相邻时序的估计，该方法称为 $\mathrm{TD}(0)$。括号内的 $R_{t+1}+\gamma V(S_{t+1})-V(S_t)$ 即 TD 误差，是后续 SARSA、Q 学习与演员-评论家共用的核心量。

式 (7-44)

旧估计与新目标的凸组合，α 越小越保守。

式 (7-45)

改写成“旧值 + 步长 × 误差”，便于逐样本增量实现。

式 (7-46)

把 G_t 换成 TD 目标，只需一步数据即可更新。

依据 《大语言模型：训练、精调与对齐》第 7.5.1 节（式 (7-44)–(7-46)）

算法 4　表格型 TD(0) 策略评估

算法 4 表格型 TD(0) 策略评估

输入： 给定初始策略 π，对所有状态 S，初始价值 $V(S)$, 其中 $V(\text{终止状态}) = 0$，步长 $\alpha \in (0, 1]$, $\epsilon \in [0, 1]$
输出： 最优状态值函数 $V^*(s, a)$

1: **for** 每幕循环 **do**
2:　　初始化 S
3:　　**for** 对幕中的每一步循环 **do**
4:　　$A \leftarrow \pi(S)$
5:　　执行动作 A, 得到环境的奖励 R 和下一个状态 S'
6:　　$V(S) \leftarrow V(S) + \alpha(R + \gamma V(S') - V(S))$
7:　　$S \leftarrow S'$
8:　　**end for**
9:　　直到 S 是终止状态
10: **end for**

第 6 步就是式 (7-46)：每走一步立即更新，不必等整幕结束。这是策略评估算法，学到的是给定策略 π 的价值 $V_\pi(s)$。

TD 目标

在时序差分估计中，TD 目标 $R_{t+1} + \gamma V(S_{t+1})$ 替代了 MC 的完整回报 G_t，从而避免了完整回报的计算。

执行 A_t
观测 R_{t+1} 与 S_{t+1}

→

构造目标
$R_{t+1} + \gamma V(S_{t+1})$

→

算 TD 误差
目标 $- V(S_t)$

→

更新
$V(S_t) \mathrel{+}= \alpha \cdot \delta$

偏差

目标里含估计值 $V(S_{t+1})$，因此 TD 估计是有偏的。

方差

只用一步随机奖励，方差远小于 MC 的整条轨迹回报。

代价

偏差与方差的折衷程度，由后续的多步 TD 与 TD(λ) 显式调节。

与 MC 的对照：MC 用 G_t 作目标，无偏但方差大、必须等到幕终止；TD 用 $R_{t+1} + \gamma V(S_{t+1})$ 作目标，有偏但方差小、每步都能更新。这一取舍是 7.5.6 节多步 TD 的出发点。

SARSA 算法

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left(R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t) \right) \tag{7-47}$$

算法名称来自更新所用的五元组 $(S_t, A_t, R_{t+1}, S_{t+1}, A_{t+1})$ 的字母。在 S_t 按 π 选 A_t，转移到 S_{t+1} 得 R_{t+1}；若 S_{t+1} 非终止，再按同一策略选 A_{t+1}。

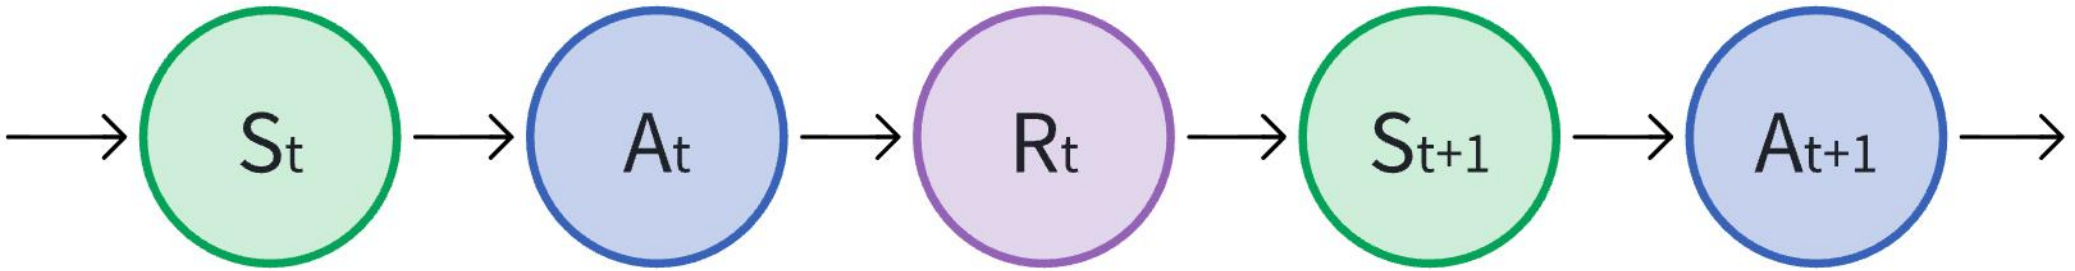


图 7.10　SARSA 五元组

- 与 TD(0) 唯一的区别：被估计与自举的对象从状态价值 V 换成动作价值 Q。
- 当前动作 A_t 与下一动作 A_{t+1} 都由**相同的行为策略**（ϵ-贪心）生成，因此 SARSA 是同轨策略算法。

五元组的读法：(S_t, A_t) 是"现在"，R_{t+1} 是"这一步的反馈"，(S_{t+1}, A_{t+1}) 是"下一步"。更新目标由后三者构成，这正是 TD 目标在动作价值上的写法。

算法 5　SARSA 时序差分控制算法

算法 5 SARSA 时序差分控制算法

输入： 对所有 s, a，任意初始动作价值 $Q(s,a)$，其中 $Q(S_T,\cdot)$ 终止状态为 0，步长 $\alpha \in (0,1]$，$\epsilon \in [1,0]$，收敛阈值 θ

输出： 最优状态值 $Q^*(s,a) \approx q_*$

1: **for** 每幕循环 **do**
2: 　初始状态 S
3: 　使用从 Q 价值函数得到的策略（如 ϵ -贪心），在 S 处选择动作 A
4: 　**for** 对幕中的每一步循环 **do**
5: 　　执行动作 A, 得到环境的奖励 R 和下一个状态 S'
6: 　　使用从 Q 得到的策略 (例如 ϵ-贪心)，在 S' 处选择 A'
7: 　　$Q(S_t,A_t) \leftarrow Q(S_t,A_t) + \alpha(R_{t+1} + \gamma Q(S_{t+1},A_{t+1}) - Q(S_t,A_t))$
8: 　　$S \leftarrow S'$; $A \leftarrow A'$
9: 　**end for**
10: 　直到 S 是终止状态
11: **end for**

第 3 步与第 6 步都用同一套 ϵ-贪心规则选动作；第 8 步把 (S', A') 滚动为下一步的 (S, A)，避免重复采样。

SARSA 的 GPI 框架

行为策略
ϵ-贪心，从当前 Q 导出

→

五元组
$(S_t, A_t, R_{t+1}, S_{t+1}, A_{t+1})$

→

TD 评估
式 (7-47) 更新 Q

→

策略改进
Q 变了，ϵ-贪心随之变

- SARSA 采用广义策略迭代框架：策略评估用 TD 方法，策略改进通过 ϵ-贪心平衡探索与利用。
- 改进不是显式重写策略表，而是隐含在"Q 更新后重新按 ϵ-贪心抽样"这一循环里。
- 同轨策略的含义：**采样用的策略与正在评估、改进的策略是同一个**。走到哪学到哪，学到的就是自己当前行为方式的价值。

评估

用 TD 目标 $R_{t+1} + \gamma Q(S_{t+1}, A_{t+1})$ 更新 $Q(S_t, A_t)$，只回溯一步。

改进

下一轮采样时按更新后的 Q 重新做 ϵ-贪心，策略随之变好。

同轨策略与离轨策略

同轨策略（On-Policy）

用于采样数据序列的策略，与待评估和改进的策略**相同**。

代表算法：SARSA。

学到的是“我这样带探索地走，值多少”。

离轨策略（Off-Policy）

采样策略（行为策略）与优化策略**不同**。

代表算法：Q 学习、DQN。

用独立的行为策略（历史策略或随机策略）探索不同轨迹，增强探索性。

> **动机** 引入离轨策略的主要原因，是让采样可以来自与目标策略不同的轨迹：既能保留探索带来的覆盖，又能直接朝最优策略学习。

Q 学习

Q 学习用 ϵ-贪婪策略采样，得到四元组 $(S_t, A_t, R_{t+1}, S_{t+1})$。其中 A_{t+1} 不由采样策略得到，而是直接取 S_{t+1} 下最大动作价值对应的动作，即 $\max_{a\in\mathcal{A}} Q(S_{t+1}, a)$。

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left(R_{t+1} + \gamma \max_{a\in\mathcal{A}} Q(S_{t+1}, a) - Q(S_t, A_t) \right) \tag{7-48}$$

$Q(S_t, A_t)$ 以最优动作价值估计 $\max_{a\in\mathcal{A}} Q(S_{t+1}, a)$ 为学习目标。相比 SARSA，Q 学习直接优化最优策略的价值函数，具有更优的收敛潜力。

- 离轨策略体现为：采样时用 ϵ-贪心（行为策略），优化目标用贪心（目标策略）。
- 因此能从任意行为策略生成的数据中学习最优策略，可以重用历史数据。

算法 6　Q 学习（离轨策略）下的 TD 控制算法

算法 6 Q-Learning（离轨策略）下的 TD 控制算法

输入： 对所有 s, a，任意初始动作价值 $Q(s,a)$，其中 $Q(S_T, \cdot)$ 终止状态为 0，步长 $\alpha \in (0,1]$，$\epsilon \in [0,1]$

输出： 最优状态值函数 $Q^*(s,a) \approx q_*$

for 每幕循环 **do**
  初始状态 S
  for 对幕中的每一步循环 **do**
    使用从 Q 得到的策略 (例如 ϵ-贪心)，在 S 处选择 A
    执行动作 A, 得到环境的奖励 R 和下一个状态 S'
    $Q(S,A) \leftarrow Q(S,A) + \alpha(R + \gamma \max_{a \in \mathcal{A}} Q(S',a) - Q(S,A))$
    $S \leftarrow S'$;
  end for
  直到 S 是终止状态
end for

与算法 5 对比：第 4 步仍用 ϵ-贪心选动作，但第 6 步的目标里出现的不是采样到的 A'，而是 $\max_a Q(S',a)$。

SARSA 与 Q 学习的区别

SARSA

同轨策略：行为策略与目标策略一致。

更新目标为实际采样动作 A_{t+1} 的价值 $Q(S_{t+1}, A_{t+1})$。

收敛至**当前策略**的动作价值函数 q_π。

Q 学习

离轨策略：行为策略与目标策略分离。

更新目标为 $\max_{a \in \mathcal{A}} Q(S_{t+1}, a)$，即 S_{t+1} 下的最优动作价值估计。

直接学习最优策略的动作价值 $Q^* \approx q_*$，并已证明收敛至 q_*。

直观差别 SARSA 用“下一步实际做了什么”来估计，Q 学习用“下一步最好能做什么”来估计。前者更保守，后者更激进。

期望 SARSA

期望 SARSA 结合了 SARSA 与 Q 学习的思想，核心改进是用期望值更新动作价值函数。

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left(R_{t+1} + \gamma \, \mathbb{E}_{A_{t+1} \sim \pi} \left[Q(S_{t+1}, A_{t+1}) \right] - Q(S_t, A_t) \right) \tag{7-49}$$

$$\leftarrow Q(S_t, A_t) + \alpha \left(R_{t+1} + \gamma \sum_{a \in \mathcal{A}} \pi(a \mid S_{t+1}) Q(S_{t+1}, a) - Q(S_t, A_t) \right) \tag{7-50}$$

式 (7-50) 把期望写成对全部动作的加权求和：权重是策略在 S_{t+1} 上选择各动作的概率。

比较三种目标：SARSA 取**实际采样动作**的 Q，Q 学习取**最大值** $\max_a Q$，期望 SARSA 取**按 π 加权的期望**。前者方差大，中者有最大化偏差，后者居中。

SARSA

$R_{t+1} + \gamma Q(S_{t+1}, A_{t+1})$

Q 学习

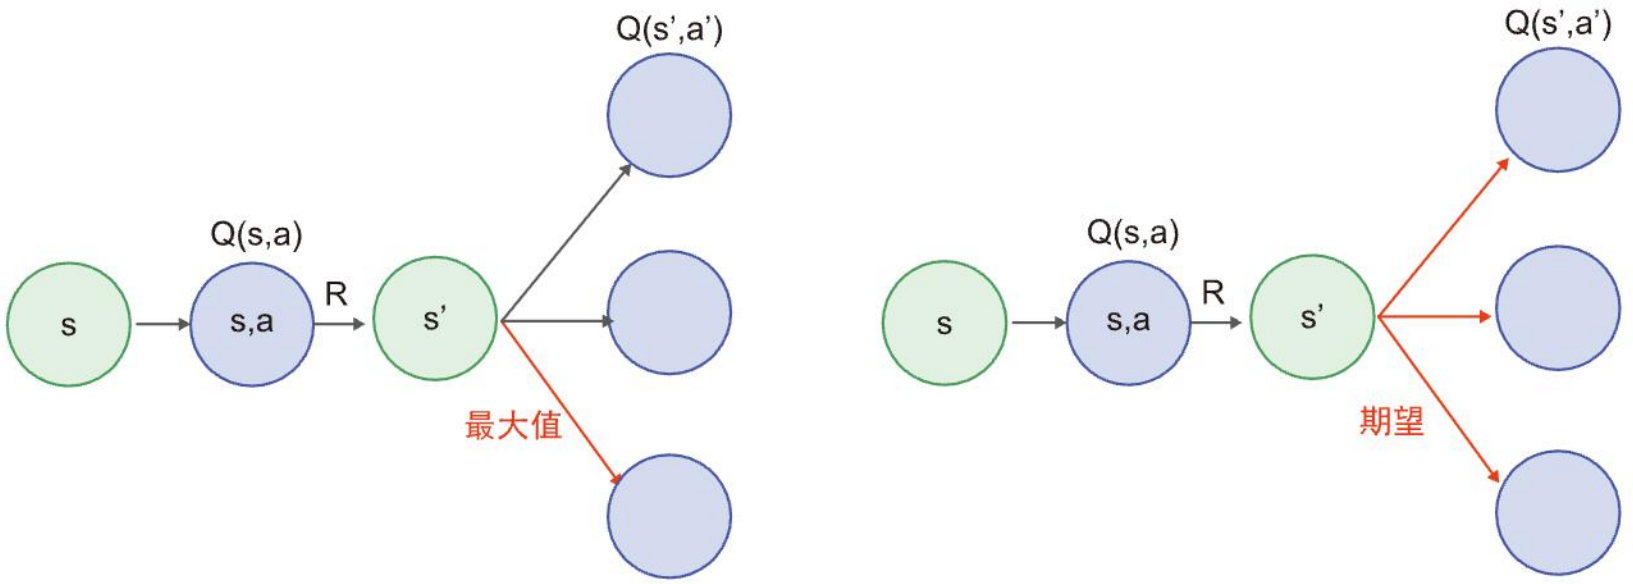
$R_{t+1} + \gamma \max_a Q(S_{t+1}, a)$

期望 SARSA

$R_{t+1} + \gamma \sum_a \pi(a \mid S_{t+1}) Q(S_{t+1}, a)$

依据 《大语言模型：训练、精调与对齐》第 7.5.4 节（式 (7-49)、(7-50)）

三种更新机制的对比



(a) Q 学习　　(b) 期望 SARSA

图 7.11　Q 学习与期望 SARSA 更新机制对比

- (a) 在 s' 的多个 $Q(s', a')$ 中取最大值，作为 $Q(s, a)$ 的更新目标。
- (b) 对 s' 下的各 $Q(s', a')$ 按策略概率取期望，目标更平滑。

期望 SARSA 的特点

- **显著降低方差**：对下一动作取期望，消除了“这一步恰好抽到哪个动作”带来的随机波动，提升学习稳定性。
- **避免最大化偏差**：Q 学习中的 $\max$ 会系统性地高估价值；期望形式的价值估计更接近真实期望。
- **减少过早收敛**：策略不易过早收敛到次优解。

策略归属

期望 SARSA 既可以是同轨策略，也可以是离轨策略，取决于期望所用的 π 是行为策略还是目标策略。

计算代价

由于期望基于当前 Q 函数与策略，其更新目标无偏且方差低于标准 SARSA；动作空间较大时，可用采样近似期望。

三种目标的对照可以写成一句话：SARSA 用“实际走的那一步”，Q 学习用“最好的一步”，期望 SARSA 用“平均的一步”。

何时选它

动作空间不大、希望更新平稳、不愿被单次采样的随机动作带偏时。

何时不用

动作空间极大、期望求和代价过高时，改用采样近似或直接回到 SARSA / Q 学习。

依据 《大语言模型：训练、精调与对齐》第 7.5.4 节

同轨策略与离轨策略的对比

同轨策略

行为策略与目标策略相同，如 SARSA。

在策略迭代框架下（如 ϵ-贪心）通常收敛到最优策略的**近似解**。

需要实时生成交互数据。

离轨策略

行为策略与目标策略不同，如 Q 学习。

优势：能重用历史数据、并行学习多个策略，探索更灵活。

缺点：估计方差较高，收敛速度通常较慢。

> **选择** 能否重用旧数据，是工程上最实际的差别：离线语料充足时倾向离轨方法，在线交互成本低、追求稳定时倾向同轨方法。

Q 网络

状态空间与动作空间非常大或连续时，用一张巨大的表格存 $Q(s,a)$ 需要巨大的存储资源。改用带参数的模型估计动作价值，即价值函数估计。

- 用参数为 θ 的模型计算动作价值，记为 $q(s,a;\theta)$，也称 "Q 网络"。
- 输入是状态 s，输出是每个动作的价值；输出节点数量等于动作空间大小 $|\mathcal{A}|$。
- 表格型方法每个状态单独存一行；网络则在状态之间共享参数，可泛化到未见过的状态。

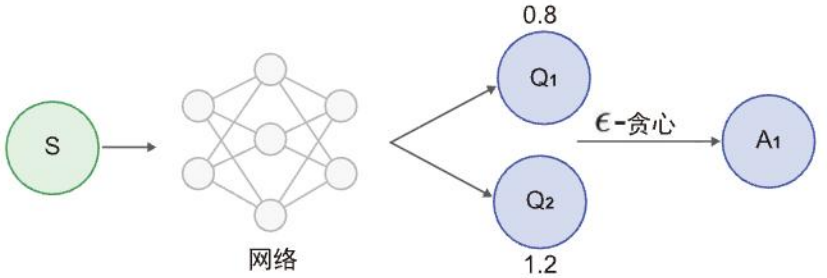


图 7.12　DQN 通过深度神经网络根据状态估计动作价值

DQN 的两项改进

用非线性函数估计动作价值并结合自举时，Q 学习会导致估计不稳定、有偏。深度 Q 网络（DQN）用两项改进使 Q 学习更稳定。

改进一

经验回放

数据收集时用 ϵ-贪心选动作；每个时间步的经验记为四元组 $e_t = (S_t, A_t, R_t, S_{t+1})$，存入经验回放缓冲区 $\mathcal{D} = \{e_1, e_2, \cdots, e_t\}$。

$\mathcal{D}$ 存储多个幕的经验，训练时从中随机采样。经验回放提高了数据效率，并平滑了数据分布。

改进二

目标网络周期性更新

估计的动作价值向目标动作价值优化。每隔参数 C 步，从深度 Q 网络复制参数 $\theta^- \leftarrow \theta$ 作为**目标 Q 网络**，并冻结其参数。

此改进避免了自举问题，提高训练稳定性，减少短期震荡。

两项改进分别针对“样本相关”与“目标漂移”两个不稳定来源：前者打散时间相关性，后者给自举目标一个固定的落点。

经验回放缓冲区

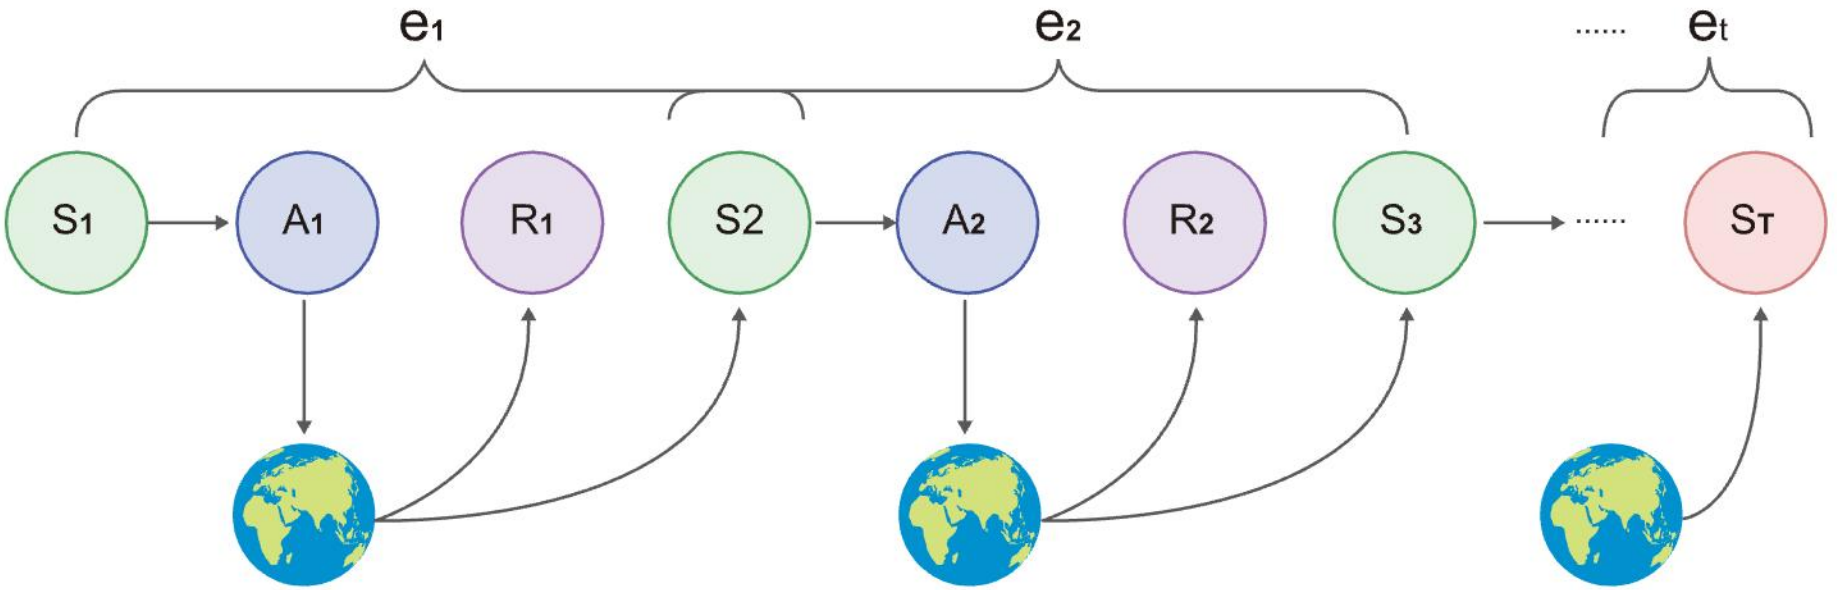


图 7.13　经验回放缓冲区存储时序差分数据

- 把一条轨迹上的 (S_t, A_t, R_t, S_{t+1}) 逐条压入缓冲区 $\mathcal{D}$，多条轨迹的经验混在一起存放。
- 训练时按均匀分布 $U(\mathcal{D})$ 随机采样小批量，而不是按时间顺序取用。
- 随机采样打破了相邻样本之间的强相关，使梯度方向更接近真实期望，也让同一批数据可以被反复使用。

DQN 的目标函数

$$\mathcal{L}(\theta) = \mathbb{E}_{(s,a,r,s')\sim U(\mathcal{D})}\left[\left(r + \gamma \max_{a'} q(s', a'; \theta^-) - q(s, a; \theta)\right)^2\right] \tag{7-51}$$

$U(\mathcal{D})$ 是经验回放缓冲区上的均匀分布；方括号内是“目标值 − 当前估计”的 TD 误差，外层取平方得到均方误差。

- 目标值中的 $\max_{a'} q(s', a'; \theta^-)$ 由**冻结的目标网络**给出，不参与当前步的梯度。
- $q(s, a; \theta)$ 由**在线 Q 网络**给出，梯度只对它回传。
- 用随机梯度下降更新 θ；参数更新达到 C 次时，执行 $\theta^- \leftarrow \theta$。

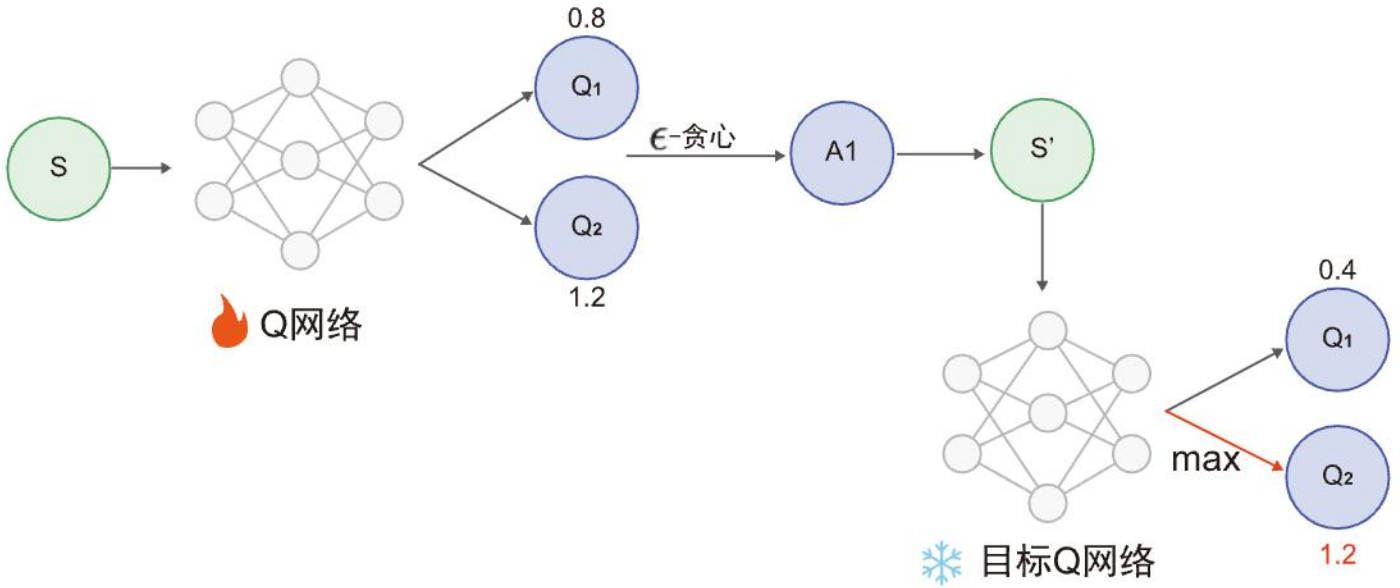


图 7.14　DQN 时序差分学习

图 《大语言模型：训练、精调与对齐》图 7.14；式 (7-51)

算法 7　DQN

算法 7 DQN

输入： 初始化 Q 网络 θ，并以 θ 初始化目标 Q 网络，步长 $\alpha \in (0,1]$, $\epsilon \in [1,0]$，学习率 β，目标 Q 网络延迟更新步数 C

输出： 优化的动作价值估计网络 θ_*

for 每幕循环 **do**
  初始化状态 S
  以 ϵ-贪心根据 $Q(S_t, A_t; \theta)$ 选择动作 A_t
  执行动作 A_t，下一个状态 S_{t+1} 和奖励 R
  将 (S_t, A_t, R_t, S_{t+1}) 放入到经验回放缓存里 D
  if $|\mathcal{D}| >$ d **then**
    for 从经验 $\mathcal{D}$ 均匀采样的集合 (s, a, r, s') **do**
      在线获取动作价值 $Q(s, a; \theta)$
      获取目标 Q 网络的动作价值 $\arg\max_{a'} Q(s', a'; \theta^-)$
      TD(0) 误差为 $\mathcal{L}(\theta) = \mathbb{E}_{(s,a,r,s') \sim U(\mathcal{D})}\left[\left(r + \gamma \max_{a'} Q(s', a'; \theta^-) - Q(s, a; \theta)\right)^2\right]$
      $\theta \leftarrow \theta + \beta \Delta \mathcal{L}(\theta)$
    end for
  end if
  if 参数更新次数 $\geqslant C$ **then**
    $\theta^- \leftarrow \theta$
  end if
end for

DQN 与 Q 学习的实现差别

交互

ϵ-贪心采集 (S, A, R, S')

→

入池

写入 $\mathcal{D}$

→

随机采样

小批量 (s, a, r, s')

→

算损失

式 (7-51)

→

更新

θ，每 C 步同步 θ^-

- 在环境交互的同时优化策略，学习与采样并行推进。
- 通过经验回放重用历史数据，提高采样效率，并充分利用离线收集的数据，工程效率更高。
- 代价是内存占用与一条"数据延迟"：策略更新用的是稍早的策略采到的数据。

与在线 Q 学习相比，DQN 把"采样—更新"拆成两个异步环节：环境交互持续往池里写，训练循环反复从池里读。这样同一份交互数据可以被多次使用，样本效率随之提高。

与 Q 学习相同

目标都是 $r + \gamma \max_{a'} Q(s', a')$，都靠 ϵ-贪心采样。

与 Q 学习不同

用网络代替表格，用回放池代替即时样本，用目标网络代替即时目标。

多步时序差分

单步 TD 只关注相邻状态的价值更新关系，价值估计可能存在较大方差。计算未来多步的累积奖励可以降低方差，这就是多步时序差分方法。

具体做法是追踪一条动作链，把单步 TD 学习扩展为多步回报：根据接下来的 n 步计算 $G_t^{(n)}$（$n = 1, \ldots, \infty$）。

表 7.2　多步价值估计方法

n	n 步回报 $G_t^{(n)}$	方法类型
$n = 1$	$G_t^{(1)} = R_{t+1} + \gamma v(S_{t+1})$	单步 TD 学习
$n = 2$	$G_t^{(2)} = R_{t+1} + \gamma R_{t+2} + \gamma^2 v(S_{t+2})$	2 步 TD 学习
$\vdots$	$\vdots$	$\vdots$
$n = n$	$G_t^{(n)} = \sum_{k=0}^{n-1} \gamma^k R_{t+k+1} + \gamma^n v(S_{t+n})$	n 步 TD 学习
$\vdots$	$\vdots$	$\vdots$
$n = \infty$	$G_t^{(\infty)} = \sum_{k=0}^{T-t-1} \gamma^k R_{t+k+1}$	蒙特卡洛（MC）估计

n 步时序差分的更新

$$v(S_t) \leftarrow v(S_t) + \alpha \left(G_t^{(n)} - v(S_t) \right) \tag{7-52}$$

广义的 n 步 TD 学习：把式 (7-46) 中的单步目标换成 n 步回报 $G_t^{(n)}$。$n = 1$ 退化为 TD(0)，$n = \infty$ 退化为 MC。

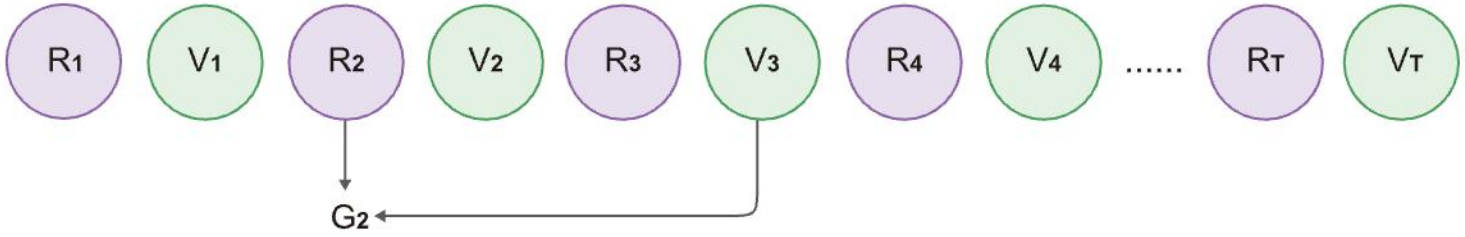


图 7.15　广义 n 步 TD 学习的价值函数更新

- $G_t^{(n)}$ 由 n 步真实奖励加上第 n 步处的价值估计组成，前段采样、后段自举。
- n 越大，自举越少、方差越大、偏差越小；n 越小则相反。
- $n = 1$ 时退化为式 (7-46) 的 TD(0)；n 取到幕末时退化为蒙特卡洛。

图中每个 R_i 都是实际观测到的奖励，末端的 V_T 则是估计值。所谓"多步"，就是让真实观测的那一段更长、让估计收尾的位置更靠后。

λ-回报

$G_t^{(n)}$ 提供了不同的精度-方差权衡，但如何确定最优的 n 是个关键问题。更好的方案是不固定 n，而是用指数衰减权重 λ^{n-1} 对不同步数的回报加权平均，$\lambda \in [0,1]$。

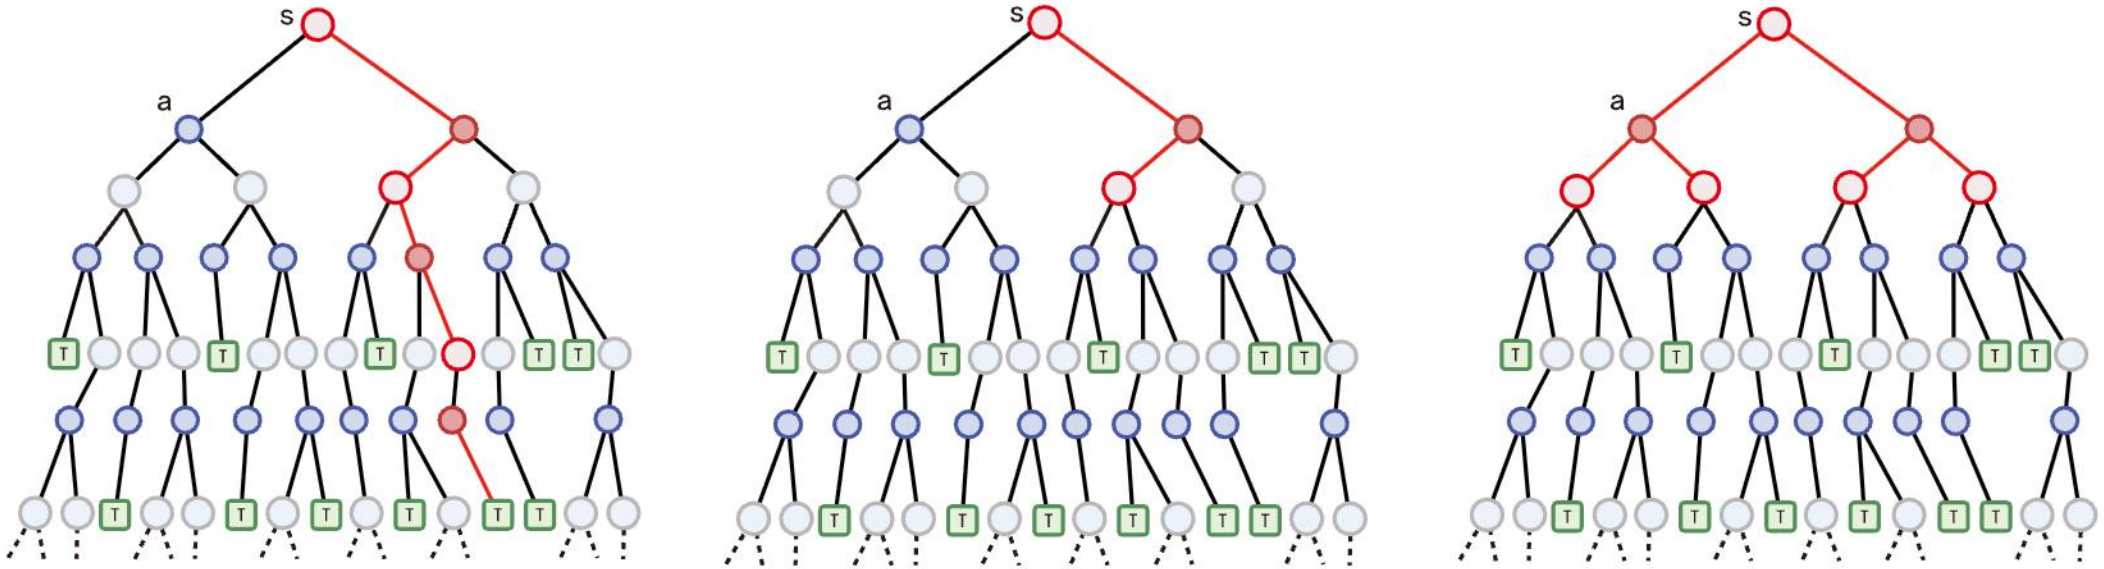
$$G_t^{\lambda} = (1-\lambda)\sum_{n=1}^{\infty} \lambda^{n-1} G_t^{(n)} \tag{7-53}$$

$(1-\lambda)$ 是归一化因子：因为 $\sum_{n=1}^{\infty} \lambda^{n-1} = \dfrac{1}{1-\lambda}$，乘上 $(1-\lambda)$ 后权重总和为 1。

- 未来奖励的不确定性更高，因此赋予较低权重；λ 控制衰减的快慢。
- 使用 λ-回报的 TD 学习方法称为 $\mathrm{TD}(\lambda)$：$\lambda = 0$ 退化为单步 TD，$\lambda = 1$ 退化为 MC。

依据 《大语言模型：训练、精调与对齐》第 7.5.6 节（式 (7-53)）

三种价值估计方法的对比



(a) 多步时序差分学习　(b) 单步时序差分学习　(c) 期望时序差分学习

图 7.16　多步时序差分学习价值估计方法对比

- (a) 沿动作链展开多步，末端用价值估计收尾；(b) 只展开一步；(c) 在每一步对动作取期望而非采样。
- 三者的共同点：都在“采样多深”与“从哪里开始自举”之间做不同取舍。

三种方法的共性

基于价值函数的强化学习方法，核心在于利用价值函数指导策略改进。它们有以下共性。

共性一

评估是改进的基础

准确的价值函数评估是决策出更优策略的关键；策略改进的目标在很大程度上依赖评估的准确性。

共性二

回溯更新机制

通过回溯实现：求解贝尔曼方程、时序差分更新（如 SARSA）或多步时序差分更新，都是利用后续状态或状态-动作对的价值来更新当前估计。

共性三

无模型方法的优势

MC 与 TD 不依赖对环境状态转移概率的显式建模，而是通过采样经验或迭代更新估计价值，规避对复杂环境模型的直接求解。

方法的四个区分维度

维度一

同轨与离轨

取决于采样策略与优化策略是否相同。Q 学习与 DQN 是典型离轨方法：目标策略是贪心策略，而采样用的是 ϵ-贪婪策略。

维度二

探索与利用的平衡

要在探索未知区域（ϵ-贪婪中的随机探索）与利用当前最优动作之间取得平衡；经验回放（DQN）有助于更充分地利用已有数据。

维度三

估计偏差

首次访问的 MC 对期望回报无偏；TD 方法（含 Q 学习与 SARSA）因自举而产生有偏估计。

维度四

估计方差

期望 SARSA 比 Q 学习更新更稳定、方差更低；多步 TD 结合短期采样回报与长期估计，在偏差与方差之间取得折衷。

GPI 框架与方法边界

广义策略迭代（GPI）框架为许多基于价值函数的方法提供了理论基础，保证了特定条件下的收敛性。

已知模型

DP 评估 + 改进迭代收敛到最优

表格 + 无模型

Q 学习在满足条件时收敛到 q_*

函数近似

DQN 扩展到高维连续状态

- 传统价值方法围绕表格型表示求解；DQN 等方法通过函数逼近，自然地处理高维连续状态空间。
- 值函数方法既可用于模型已知的场景，也适用于环境未知的场景（MC、TD、Q 学习）。
- 核心挑战：巨大的状态-动作空间、环境模型未知、采样效率，以及函数逼近下的稳定性。

蒙特卡洛树搜索（MCTS）在 AlphaGo 中的应用是强化学习发展史上的重要里程碑：它结合深度学习（价值函数与策略网络）与 MCTS，在模拟中反复利用学到的价值与策略做前向搜索，显著提升具体状态下的决策质量。

7.6

策略梯度方法

不再经由价值函数中转：把策略本身写成带参数的函数，直接对期望回报做梯度上升。

本节内容

7.6.1 策略梯度定理

7.6.2 策略梯度证明*

7.6.3 REINFORCE 策略梯度

7.6.4 离轨策略梯度

直接学习策略的动机

表格型方法受限于有限资源；DQN 虽可用参数化网络估计价值函数处理复杂问题，但仍依赖价值函数作为中介。策略梯度直接学习参数化的策略模型。

价值中介的路线

先估计 $v_\pi(s)$ 或 $q_\pi(s,a)$，再由价值导出动作。

状态或动作空间连续时，无限的状态-动作对使价值估计困难。

DQN 缓解了存储问题，但价值仍是必经环节。

直接优化策略

用参数 $\boldsymbol{\theta}$ 建模策略 $\pi_{\boldsymbol{\theta}}(a \mid s)$，直接优化它。

规避了价值估计的瓶颈，天然适合连续状态与未知环境动态。

代价是梯度估计的方差较大，需要技巧控制。

目标函数定义为初始状态 S_1 的期望回报（式 (7-54)）；更新方式是梯度上升（式 (7-55)）。本节其余内容都在回答“这个梯度怎么算”。

策略梯度的目标函数

使用参数 $\boldsymbol{\theta}$ 建模策略，记为 $\pi_{\boldsymbol{\theta}}(a \mid s)$，其目标函数定义为初始状态 S_1 的期望回报。

$$J(\boldsymbol{\theta}) = v_{\pi_{\boldsymbol{\theta}}}(S_1) = \mathbb{E}_{\pi_{\boldsymbol{\theta}}}\left[G_1\right] \tag{7-54}$$

S_1 为初始状态，G_1 是时刻 $t=1$ 的回报。目标是通过调整 $\boldsymbol{\theta}$ 最大化 $J(\boldsymbol{\theta})$，即最大化策略 $\pi_{\boldsymbol{\theta}}$ 下的期望回报。

$$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \alpha \nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta}) \tag{7-55}$$

梯度上升：沿目标函数增大的方向更新参数，α 为学习率。逐步优化 $\boldsymbol{\theta}$，使策略 $\pi_{\boldsymbol{\theta}}$ 生成最大的期望回报。

与价值方法的区别在于“被优化的对象”：这里参数直接作用在动作分布上，价值函数至多作为辅助量出现（如基线）。

式 (7-54)

$J(\boldsymbol{\theta})$ 只依赖初始状态 S_1 的期望回报，是对“整条轨迹好坏”的标量度量。

式 (7-55)

$abla_{\boldsymbol{\theta}} J$ 的估计是全部难点：它不能直接对采样求和求导，需要下页的定理。

依据 《大语言模型：训练、精调与对齐》第 7.6 节（式 (7-54)、(7-55)）

直接求导的困难

通过贝尔曼方程（式 (7-16)，折扣因子设为 1）展开 $J(\boldsymbol{\theta})$：

$$J(\boldsymbol{\theta}) = \sum_{a \in \mathcal{A}} \pi_{\boldsymbol{\theta}}(a \mid s)\, q_{\pi_{\boldsymbol{\theta}}}(s, a) \tag{7-56}$$

$$= \sum_{a \in \mathcal{A}} \pi_{\boldsymbol{\theta}}(a \mid s) \sum_{s' \in \mathcal{S}, r \in \mathcal{R}} p(s', r \mid s, a)\,(r + v_{\pi_{\boldsymbol{\theta}}}(s')) \tag{7-57}$$

动作空间 $\mathcal{A}$ 有限且离散；$\pi_{\boldsymbol{\theta}}(a \mid s)$ 是策略在状态 s 下选择动作 a 的概率。

- 对目标方程求导时，当 $p(s' \mid s, a)$ 未知，就难以计算 $\nabla_{\boldsymbol{\theta}} p(s', r \mid s, a)$。
- 而且展开式里 $v_{\pi_{\boldsymbol{\theta}}}(s')$ 本身也依赖 $\boldsymbol{\theta}$，逐层展开会无限递归。
- 策略梯度定理的作用：把梯度整理成一个**不含** ∇p 的形式。

依据 《大语言模型：训练、精调与对齐》第 7.6.1 节（式 (7-56)、(7-57)）

策略梯度定理

$$\nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta}) = \nabla_{\boldsymbol{\theta}} \sum_{a \in \mathcal{A}} \pi_{\boldsymbol{\theta}}(a \mid s) q_{\pi_{\boldsymbol{\theta}}}(s, a) \tag{7-58}$$

$$\propto \sum_{s \in \mathcal{S}} d_{\pi}(s) \sum_{a \in \mathcal{A}} q_{\pi_{\boldsymbol{\theta}}}(s, a) \nabla_{\boldsymbol{\theta}} \pi_{\boldsymbol{\theta}}(a \mid s) \tag{7-59}$$

$d_{\pi_{\boldsymbol{\theta}}}(s)$ 是策略 $\pi_{\boldsymbol{\theta}}$ 诱导的马尔可夫链的稳态分布。求梯度时，$\nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta})$ 依赖动作的选择（由 $\pi_{\boldsymbol{\theta}}$ 决定）与稳态分布 d_{π}（不直接由 $\pi_{\boldsymbol{\theta}}$ 决定）。

- 关键结论：目标梯度与状态转移方程无关。状态转移概率在长期中收敛为稳态分布，梯度只与目标优化方程成比例。
- 这正是"绕开环境模型"的来源：不需要知道 $p(s' \mid s, a)$，只要按策略采样就能估计这个期望。
- 下一节给出从式 (7-59) 到显式期望形式的完整推导。

"成正比"而非"相等"是这一步的要点：省掉的因子是 $\sum_s \eta(s)$，它与 $\boldsymbol{\theta}$ 无关，不影响梯度上升的方向。

依据 《大语言模型：训练、精调与对齐》第 7.6.1 节（式 (7-58)、(7-59)）

策略梯度推导（一）：对状态价值求导并展开

$$\nabla_{\boldsymbol{\theta}} v_{\pi_{\boldsymbol{\theta}}}(s) = \nabla_{\boldsymbol{\theta}} \Big(\sum_{a \in \mathcal{A}} \pi_{\boldsymbol{\theta}}(a \mid s) q_{\pi_{\boldsymbol{\theta}}}(s, a) \Big) \tag{7-60}$$

$$= \sum_{a \in \mathcal{A}} \Big(\nabla_{\boldsymbol{\theta}} \pi_{\boldsymbol{\theta}}(a \mid s) q_{\pi_{\boldsymbol{\theta}}}(s, a) + \pi_{\boldsymbol{\theta}}(a \mid s) \nabla_{\boldsymbol{\theta}} q_{\pi_{\boldsymbol{\theta}}}(s, a) \Big) \tag{7-61}$$

$$= \sum_{a \in \mathcal{A}} \Big(\nabla_{\boldsymbol{\theta}} \pi_{\boldsymbol{\theta}}(a \mid s) q_{\pi_{\boldsymbol{\theta}}}(s, a) + \pi_{\boldsymbol{\theta}}(a \mid s) \nabla_{\boldsymbol{\theta}} \sum_{s', r} p(s', r \mid s, a) \left(r + v_{\pi_{\boldsymbol{\theta}}}(s') \right) \Big) \tag{7-62}$$

$$= \sum_{a \in \mathcal{A}} \Big(\nabla_{\boldsymbol{\theta}} \pi_{\boldsymbol{\theta}}(a \mid s) q_{\pi_{\boldsymbol{\theta}}}(s, a) + \pi_{\boldsymbol{\theta}}(a \mid s) \sum_{s', r} p(s', r \mid s, a) \nabla_{\boldsymbol{\theta}} v_{\pi_{\boldsymbol{\theta}}}(s') \Big) \tag{7-63}$$

$$= \sum_{a \in \mathcal{A}} \Big(\nabla_{\boldsymbol{\theta}} \pi_{\boldsymbol{\theta}}(a \mid s) q_{\pi_{\boldsymbol{\theta}}}(s, a) + \pi_{\boldsymbol{\theta}}(a \mid s) \sum_{s'} p(s' \mid s, a) \nabla_{\boldsymbol{\theta}} v_{\pi_{\boldsymbol{\theta}}}(s') \Big) \tag{7-64}$$

式 (7-61) 用乘积法则拆两项；式 (7-62) 把第二项的 $q_{\pi_{\boldsymbol{\theta}}}$ 换成贝尔曼展开；式 (7-63) 中 r、p 不含 $\boldsymbol{\theta}$，梯度只落在 $v_{\pi_{\boldsymbol{\theta}}}(s')$；式 (7-64) 对 r 求和。至此 $\nabla v(s)$ 已写成 $\nabla v(s')$ 的加权和。

第一项 $\nabla_{\boldsymbol{\theta}} \pi \cdot q$

要保留的可采样部分。

第二项 $\pi \cdot \nabla_{\boldsymbol{\theta}} q$

展开后落回 $v(s')$。

递归成形

式 (7-64) 可再展开一步。

依据 《大语言模型：训练、精调与对齐》第 7.6.2 节（式 (7-60)–(7-64)）

策略梯度推导（二）：定义多步转移概率

$$
\begin{aligned}
k = 0: &\qquad \rho_{\pi_\theta}(s \to s, 0) = 1 \\
k = 1: &\qquad \rho_{\pi_\theta}(s \to s', 1) = \sum_a \pi_\theta(a \mid s)\, p(s' \mid s, a) \\
k \geqslant 1: &\quad \rho_{\pi_\theta}(s \to x, k+1) = \sum_{s'} \rho_{\pi_\theta}(s \to s', k)\, \rho_{\pi_\theta}(s' \to x, 1)
\end{aligned}
$$

三行的等号对齐。$\rho_{\pi_\theta}(s \to x, k)$ 为从 s 经 k 步转移到 x 的概率：$k=0$ 表示停留在自身；$k=1$ 是先按策略选动作、再按环境转移一步；递推式把"走 k 步到 s'，再走 1 步到 x"拼接起来。

为什么需要 ρ

式 (7-64) 只说了相邻两步的递归。要把递归解到无穷，必须把"走了几步、经过哪些状态"的随机性收进一个量。

有了 ρ，展开就变成对"目的地 x"与"步数 k"的纯求和拼接。

策略梯度推导（三）：递归展开到全轨迹

$$\nabla_{\boldsymbol{\theta}} v_{\pi_\theta}(s) = \phi(s) + \sum_{s'} \rho_{\pi_\theta}(s \to s', 1) \nabla_{\boldsymbol{\theta}} v_{\pi_\theta}(s') \tag{7-65}$$

$$= \phi(s) + \sum_{s'} \rho_{\pi_\theta}(s \to s', 1) \left[\phi(s') + \sum_{s''} \rho_{\pi_\theta}(s' \to s'', 1) \nabla_{\boldsymbol{\theta}} v_{\pi_\theta}(s'') \right] \tag{7-66}$$

$$= \phi(s) + \sum_{s'} \rho_{\pi_\theta}(s \to s', 1) \phi(s') + \sum_{s''} \rho_{\pi_\theta}(s \to s'', 2) \nabla_{\boldsymbol{\theta}} v_{\pi_\theta}(s'') \tag{7-67}$$

$$= \cdots \tag{7-68}$$

$$= \sum_{x \in \mathcal{S}} \sum_{k=0}^{\infty} \rho_{\pi_\theta}(s \to x, k) \phi(x) \tag{7-69}$$

记 $\phi(s)$ 为式 (7-64) 括号内的第一项，递归写成式 (7-65)。

式 (7-66)

把 $\nabla v(s')$ 再用式 (7-65) 展开一层。

式 (7-67)

用 ρ 的递推合并两步转移。

式 (7-69)

末项推到无穷远，只剩对状态与步数求和。

依据 《大语言模型：训练、精调与对齐》第 7.6.2 节（式 (7-65)–(7-69)）

策略梯度推导（四）：得到策略梯度定理

$$\nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta}) = \nabla_{\boldsymbol{\theta}} v^{\pi_\theta}(s_0) \tag{7-70}$$

$$= \sum_s \sum_{k=0}^{\infty} \rho_{\pi_\theta}(s_0 \to s, k)\, \phi(s) \tag{7-71}$$

$$= \sum_s \eta(s)\phi(s) \tag{7-72}$$

$$= \Big(\sum_s \eta(s)\Big) \sum_s \frac{\eta(s)}{\sum_s \eta(s)} \phi(s) \tag{7-73}$$

$$\propto \sum_s \frac{\eta(s)}{\sum_s \eta(s)} \phi(s) \tag{7-74}$$

$$= \sum_s d^{\pi}(s) \sum_a \nabla_{\boldsymbol{\theta}} \pi_{\boldsymbol{\theta}}(a \mid s) q^{\pi}(s, a) \tag{7-75}$$

$\eta(s)$ 是访问状态 s 的期望次数，$\sum_s \eta(s)$ 与 $\boldsymbol{\theta}$ 无关、是标量，故可按比例化简（式 (7-74)）；$d_\pi(s) = \eta(s) / \sum_s \eta(s)$ 是稳态分布。

- 式 (7-75) 把 $\phi(s)$ 代回，梯度只含 $\nabla_{\boldsymbol{\theta}} \pi_{\boldsymbol{\theta}}$ 与 q^{π}，对 $q_{\pi_\theta}(s, a)$ 的求导被完全去除。
- 环境转移概率 $p(s' \mid s, a)$ 不再出现——这正是策略梯度定理可以直接对参数优化期望回报的原因。

依据 《大语言模型：训练、精调与对齐》第 7.6.2 节（式 (7-70)–(7-75)）

从定理到样本梯度

蒙特卡洛策略梯度（REINFORCE）依赖蒙特卡洛方法采样分幕数据并更新策略参数 $\boldsymbol{\theta}$。根据策略梯度定理，样本梯度正比于实际梯度。

$$\nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta}) \propto \sum_{s \in \mathcal{S}} d_{\pi}(s) \sum_{a \in \mathcal{A}} q_{\pi}(s, a) \nabla_{\boldsymbol{\theta}} \pi_{\boldsymbol{\theta}}(a \mid s) \tag{7-76}$$

$$= \mathbb{E}_{\pi} \left[\sum_{a} q_{\pi}(S_t, a) \nabla_{\boldsymbol{\theta}} \pi_{\boldsymbol{\theta}}(a \mid S_t) \right] \tag{7-77}$$

式 (7-77) 把“对状态按稳态分布求和”识别为“对策略采样到的状态 S_t 取期望”。

式 (7-77) 里还没有显式的 $\pi_{\boldsymbol{\theta}}(a \mid S_t)$ 作为加权系数。下一步通过乘除同一个概率把它引入，才能把求和变成对采样动作的期望。

对数导数技巧

$$\nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta}) = \mathbb{E}_{\pi}\left[\sum_{a} q_{\pi}(S_t, a)\, \pi_{\boldsymbol{\theta}}(a \mid S_t) \frac{\nabla_{\boldsymbol{\theta}} \pi_{\boldsymbol{\theta}}(a \mid S_t)}{\pi_{\boldsymbol{\theta}}(a \mid S_t)}\right] \tag{7-78}$$

$$= \mathbb{E}_{\pi}\left[q_{\pi}(S_t, A_t) \frac{\nabla_{\boldsymbol{\theta}} \pi_{\boldsymbol{\theta}}(A_t \mid S_t)}{\pi_{\boldsymbol{\theta}}(A_t \mid S_t)}\right] \tag{7-79}$$

$$= \mathbb{E}_{\pi}\left[q_{\pi}(S_t, A_t) \nabla_{\boldsymbol{\theta}} \ln \pi_{\boldsymbol{\theta}}(A_t \mid S_t)\right] \tag{7-80}$$

$$= \mathbb{E}_{\pi}\left[G_t \nabla_{\boldsymbol{\theta}} \ln \pi_{\boldsymbol{\theta}}(A_t \mid S_t)\right] \tag{7-81}$$

式 (7-78)：对求和项乘除 $\pi_{\boldsymbol{\theta}}(a \mid S_t)$，得到按策略概率加权的形式；式 (7-79)：加权后求和即为对采样动作 A_t 的期望；式 (7-80)：用 $\nabla \ln x = \nabla x / x$；式 (7-81)：用 $\mathbb{E}_{\pi}\left[G_t \mid S_t, A_t\right] = q_{\pi}(S_t, A_t)$。

四步的核心是同一个技巧：把“对动作求和”改写为“按概率采样再求期望”。改写之后，梯度只剩下 $\ln \pi$ 的导数与回报的乘积，两者都能从一条轨迹直接算出。

依据 《大语言模型：训练、精调与对齐》第 7.6.3 节（式 (7-78)–(7-81)）

参数更新式

$$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \alpha\, G \nabla_{\boldsymbol{\theta}} \ln \pi_{\boldsymbol{\theta}}(A_t \mid S_t) \tag{7-82}$$

其中 G 可从真实采样轨迹中估计。由于 G 依赖完整轨迹，REINFORCE 必须采样完整幕。伪代码中的更新式还含折扣因子 γ^t（上述推导对应特例 $\gamma = 1$）。

- 梯度方向由 $\nabla_{\boldsymbol{\theta}} \ln \pi_{\boldsymbol{\theta}}(A_t \mid S_t)$ 给出，幅度由回报 G 加权。
- 直观看：回报高，就提高该动作在同样状态下被选中的概率；回报低则降低。
- 对整个幕反向遍历，每一步都用从该时刻起累积的 G 更新一次。

$abla_{\boldsymbol{\theta}} \ln \pi_{\boldsymbol{\theta}}(A_t \mid S_t)$ 指向"让该动作概率增大"的参数方向；乘上 G 后，回报为正则强化、为负则抑制。若回报全为正，所有动作都会被强化，这时就需要基线。

依据 《大语言模型：训练、精调与对齐》第 7.6.3 节（式 (7-82)）

算法 8　REINFORCE 策略梯度算法

算法 8 REINFORCE 策略梯度算法

输入： 给定含参数 $\boldsymbol{\theta}$ 的策略模型 $\pi_{\boldsymbol{\theta}}(a|s)$，学习率 α，折扣因子 γ
输出： 最优策略 $\pi(a|s;\boldsymbol{\theta}_*)$ 的参数 $\boldsymbol{\theta}_*$ 模型

1: **for** 每一幕 **do**
2: 　　以 $\pi(a|s;\boldsymbol{\theta})$，生成幕序列 $S_0, A_0, R_0, \ldots, S_T, A_T, R_T$
3: 　　**for** 对幕中的每一步循环,$t = \{T, T-1, \cdots, 1, 0\}$ **do**
4: 　　　　$G \leftarrow \sum_{k=t+1}^{T} \gamma^{k-t-1} R_k$
5: 　　　　$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \alpha\gamma^t G \nabla \ln \pi(A_t|S_t;\boldsymbol{\theta})$
6: 　　**end for**
7: **end for**

第 2 步采样一整幕；第 4 步从后向前累加折扣回报；第 5 步是式 (7-82) 的带折扣版本，更新幅度额外乘上 γ^t，越早的动作权重越低。

基线的引入

更通用的 REINFORCE 通过减去基线（baseline）降低策略梯度的方差，同时保证梯度估计的无偏性。例如采用优势函数 $A(s,a)=q_\pi(s,a)-v_\pi(s)$ 替代回报。

$$\nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta}) \propto \sum_{s\in\mathcal{S}} d_\pi(s) \sum_{a\in\mathcal{A}} \left(q_\pi(s,a)-b(s)\right) \nabla_{\boldsymbol{\theta}} \pi_{\boldsymbol{\theta}}(a\mid s) \tag{7-83}$$

$b(s)$ 为基线函数（任意函数）。

$$\sum_{a\in\mathcal{A}} b(s)\nabla_{\boldsymbol{\theta}}\pi_{\boldsymbol{\theta}}(a\mid s) = b(s)\nabla_{\boldsymbol{\theta}} \sum_{a\in\mathcal{A}} \pi_{\boldsymbol{\theta}}(a\mid s) = b(s)\nabla_{\boldsymbol{\theta}} 1 = 0 \tag{7-84}$$

式 (7-84) 说明 $b(s)$ 的期望贡献恒为零：概率之和恒为 1，其梯度为零。因此减去基线不改变梯度的期望，只改变方差。

三步都很短，但逻辑链完整：把 $b(s)$ 提到求和号外 → 概率之和恒为 1 → 常数的梯度为零。正因如此，基线可以取任意函数，不必保证精确。

依据 《大语言模型：训练、精调与对齐》第 7.6.3 节（式 (7-83)、(7-84)）

优势函数

用参数 $\boldsymbol{W}$ 估计状态价值 $\hat{v}(s;\boldsymbol{W})$ 作为基线。基于 $v_\pi(s)=\sum_a \pi_{\boldsymbol{\theta}}(a\mid s)q_\pi(s,a)$，优势函数 $A(s,a)=q_\pi(s,a)-v_\pi(s)$ 量化了动作 a 相对于平均水平的优势。

$$\nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta}) = \mathbb{E}_\pi\left[\left(q_\pi(S_t,A_t)-\hat{v}(S_t;\boldsymbol{W})\right)\nabla_{\boldsymbol{\theta}}\ln\pi_{\boldsymbol{\theta}}(A_t\mid S_t)\right] \tag{7-85}$$

$$= \mathbb{E}_\pi\left[\left(G_t-\hat{v}(S_t;\boldsymbol{W})\right)\nabla_{\boldsymbol{\theta}}\ln\pi_{\boldsymbol{\theta}}(A_t\mid S_t)\right] \tag{7-86}$$

式 (7-86) 用采样回报 G_t 替代 q_π：G_t 是 q_π 的无偏样本。括号内即优势的估计，正值表示该动作优于平均水平。

若某动作的回报高于状态的平均价值，就提高它的概率；低于平均值则降低。基线把"绝对好坏"变成"相对好坏"，方差显著下降。

式 (7-85)

用动作价值 q_π 减基线：理论上精确，但 q_π 未知，需要估计。

式 (7-86)

用采样回报 G_t 减基线：可直接计算，是算法 9 采用的实现形式。

依据 《大语言模型：训练、精调与对齐》第 7.6.3 节（式 (7-85)、(7-86)）

算法 9　带基线的 REINFORCE 策略梯度算法

算法 9 带基线的 REINFORCE 策略梯度算法

输入： 给定含参数 $\boldsymbol{\theta}$ 的策略模型 $\pi(a|s;\boldsymbol{\theta})$，学习率 $\beta^{\boldsymbol{\theta}}$，给定参数 W 的状态价值函数 $v(s;\boldsymbol{W})$, 学习率 $\beta^{\boldsymbol{W}}$，折扣因子 γ

输出： 最优策略 $\pi(a|s;\boldsymbol{\theta}_*)$ 的参数 $\boldsymbol{\theta}_*$ 模型，状态价值模型 $v(s;\boldsymbol{W}_*)$

for 每一幕 **do**
  以 $\pi(a|s;\boldsymbol{\theta})$，生成幕序列 $S_0, A_0, R_0, \ldots, S_T, A_T, R_T$
  for 对幕中的每一步循环,$t = \{T, T-1, \cdots, 1, 0\}$ **do**
    $G \leftarrow \sum_{k=t+1}^{T} \gamma^{k-t-1} R_k$
    $\delta \leftarrow G - v(S_t;\boldsymbol{W})$
    $\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \beta^{\boldsymbol{\theta}} \gamma^t \delta \nabla \ln \pi(A_t|S_t;\boldsymbol{\theta})$
    $\boldsymbol{W} \leftarrow \boldsymbol{W} + \beta^{\boldsymbol{W}} \delta \nabla V(S_t;\boldsymbol{W})$
  end for
end for

第 5 步用同一个 δ 同时驱动两条更新：第 6 步调整策略（演员），第 7 步调整基线（价值模型）。这已经是演员-评论家的雏形。

离轨策略梯度

REINFORCE 属于同轨方法，训练样本必须从目标策略 π_{θ} 中采样。离轨策略梯度方法放宽了这一限制。

优势一

重用历史数据

无需采样完整轨迹，可重复利用历史幕数据（经验回放），提高采样效率。

优势二

增强探索

通过行为策略 $\beta(a \mid s)$ 收集样本，采样分布与目标策略解耦，探索更灵活。

代价是引入了分布不匹配：样本来自 β，而目标函数评估的是 π_{θ}。解决办法是用重要性采样比 $\dfrac{\pi_{\theta}(a \mid s)}{\beta(a \mid s)}$ 做偏差校正。

依据 《大语言模型：训练、精调与对齐》第 7.6.4 节

重要性采样推导

$$J(\boldsymbol{\theta}) = \sum_{s\in\mathcal{S}} d^{\beta}(s) \sum_{a\in\mathcal{A}} q_{\pi}(s,a)\pi_{\boldsymbol{\theta}}(a \mid s) = \mathbb{E}_{s\sim d^{\beta}}\left[\sum_{a\in\mathcal{A}} q_{\pi}(s,a)\pi_{\boldsymbol{\theta}}(a \mid s)\right] \tag{7-87}$$

$$\nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta}) = \nabla_{\boldsymbol{\theta}} \mathbb{E}_{s\sim d^{\beta}}\left[\sum_{a} q_{\pi}(s,a)\pi_{\boldsymbol{\theta}}(a \mid s)\right] \tag{7-88}$$

$$= \mathbb{E}_{s\sim d^{\beta}}\left[\sum_{a} \left(q_{\pi}(s,a)\nabla_{\boldsymbol{\theta}}\pi_{\boldsymbol{\theta}}(a \mid s) + \pi_{\boldsymbol{\theta}}(a \mid s)\nabla_{\boldsymbol{\theta}} q_{\pi}(s,a)\right)\right] \tag{7-89}$$

$$= \mathbb{E}_{s\sim d^{\beta}}\left[\sum_{a} q_{\pi}(s,a)\nabla_{\boldsymbol{\theta}}\pi_{\boldsymbol{\theta}}(a \mid s)\right] \tag{7-90}$$

$d^{\beta}(s)$ 是行为策略 β 的稳态分布。式 (7-88) 对状态分布取期望，d^{β} 与 $\boldsymbol{\theta}$ 无关，梯度只作用于内层；式 (7-89) 用乘积法则；式 (7-90) 忽略对 $\nabla_{\boldsymbol{\theta}} q_{\pi}(s,a)$ 的求导项。

依据 《大语言模型：训练、精调与对齐》第 7.6.4 节（式 (7-87)–(7-90)）

离轨梯度的形式

$$= \mathbb{E}_{s\sim d^{\beta}}\left[\sum_{a}\beta(a\mid s)\frac{\pi_{\boldsymbol{\theta}}(a\mid s)}{\beta(a\mid s)}q_{\pi}(s,a)\frac{\nabla_{\boldsymbol{\theta}}\pi_{\boldsymbol{\theta}}(a\mid s)}{\pi_{\boldsymbol{\theta}}(a\mid s)}\right] \tag{7-91}$$

$$= \mathbb{E}_{\beta}\left[\frac{\pi_{\boldsymbol{\theta}}(A_t\mid S_t)}{\beta(A_t\mid S_t)}q_{\pi}(S_t,A_t)\nabla_{\boldsymbol{\theta}}\ln\pi_{\boldsymbol{\theta}}(A_t\mid S_t)\right] \tag{7-92}$$

式 (7-91) 在求和项里乘除 $\beta(a\mid s)$：乘以它得到“按行为策略采样的概率”，除以它得到重要性权重；再乘除 $\pi_{\boldsymbol{\theta}}$ 得到对数导数的形式。式 (7-92) 把求和识别为对行为策略样本的期望。

其中忽略了红色项（$\nabla_{\boldsymbol{\theta}}q_{\pi}(s,a)$）：该项难以计算，且理论证明忽略后仍能收敛。最终形式引入重要性采样比 $\dfrac{\pi_{\boldsymbol{\theta}}(a\mid s)}{\beta(a\mid s)}$，通过重要性权重调整实现离轨策略梯度。

比值的含义

大于 1：该动作在目标策略下更可能，样本权重放大；小于 1 则缩小。

代价

比值可能很大，导致方差升高；策略差距越大，估计越不稳定。

期望的下标是怎么变的

式 (7-91) 的期望只写 $s \sim d^{\beta}$，动作在求和号里；式 (7-92) 的期望写成 $\mathbb{E}_{\beta}$。下标变了，因为"对一个概率分布求和"本来就可以写成"对该分布的期望"。

$$\mathbb{E}_{a\sim\beta(\cdot|s)}\big[f(s,a)\big] = \sum_{a} \beta(a \mid s)\, f(s,a)$$

$$\mathbb{E}_{s\sim d^{\beta}}\Big[\sum_{a} \beta(a \mid s) f(s,a)\Big] = \mathbb{E}_{s\sim d^{\beta},\, a\sim\beta(\cdot|s)}\big[f(s,a)\big] = \mathbb{E}_{\beta}\big[f(S_t, A_t)\big]$$

左边先按 d^{β} 抽状态、再对动作求和；右边把"抽状态 + 抽动作"合并成一次联合采样。$\mathbb{E}_{\beta}$ 的下标 β 同时代表状态分布 d^{β} 与动作分布 $\beta(a \mid s)$，即行为策略诱导的 (S_t, A_t) 联合分布。

第一步：补一个 β/β

$\sum_a \beta(a \mid s) \cdot \dfrac{\pi_{\boldsymbol{\theta}}(a \mid s)}{\beta(a \mid s)} f(s,a)$，值不变，但出现了"对 β 求和"的形状。

第二步：识别成期望

对 a 的求和按上式合并进 $\mathbb{E}_{\beta}$，求和号消失。

第三步：写成样本均值

一条由 β 采出的轨迹，就给出 $\mathbb{E}_{\beta}$ 的一个无偏估计。

依据 《大语言模型：训练、精调与对齐》第 7.6.4 节（式 (7-91)、(7-92) 的期望形式）

算法 10　离轨的 REINFORCE 策略梯度算法

算法 10 离轨的 REINFORCE 策略梯度算法

输入： 给定含参数 $\boldsymbol{\theta}$ 的策略模型 $\pi_{\boldsymbol{\theta}}(a|s)$，学习率 α，将观测策略模型 $\beta(a|s)$ 以参数 $\boldsymbol{\theta}$ 初始化。
输出： 最优策略 $\pi_{\boldsymbol{\theta}_*}(a|s)$ 的参数 $\boldsymbol{\theta}_*$ 模型

for 每一幕 **do**
  以 $\beta(a|s)$，生成幕序列 $\tau = S_0, A_0, R_0, \ldots, S_T, A_T, R_T$
  $\mathcal{T} \leftarrow \tau$
  for $\mathcal{T}$ 取出幕 τ **do**
    for 对幕 τ 中的每一步循环,$t = \{T-1, T-2, \cdots, 1, 0\}$ **do**
      $G \leftarrow \sum_{k=t+1}^{T} \gamma^{k-t-1} R_k$
      $\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \alpha\gamma^t q_{\pi_{\boldsymbol{\theta}}}(s,a) \frac{\pi_{\boldsymbol{\theta}}(a|s)}{\beta(a|s)} \nabla \ln \pi_{\boldsymbol{\theta}}(A_t|S_t)$
    end for
  end for
end for

与算法 8 的差别集中在第 2 步与第 7 步：数据由行为策略 β 生成，更新时乘上重要性采样比，把"按 β 采样的期望"校正为"按 $\pi_{\boldsymbol{\theta}}$ 的期望"。

7.7

演员-评论家

本节内容

7.7.1 演员-评论家算法
7.7.2 信赖域策略优化
7.7.3 近端策略优化
7.7.4 策略梯度类方法小结

策略梯度给出方向，价值函数给出尺度：演员按评论家的 TD 误差更新策略，评论家持续评估价值。

演员-评论家的两个组件

策略梯度方法包含两个核心组件：策略模型与价值函数。带基线的 REINFORCE 用价值函数估计作基线降低方差，此时可改用时序差分改进价值估计。当策略梯度方法同时建模策略模型与价值模型时，称为演员-评论家方法（AC）。

评论家 Critic

评估价值

更新价值函数参数 $\boldsymbol{W}$，估计动作价值 $q(s,a;\boldsymbol{W})$ 或状态价值 $v(s;\boldsymbol{W})$。

用最小化 TD 误差 δ_t^2 更新价值参数。

演员 Actor

更新策略

基于评论家给出的时序差分误差，更新策略参数 $\boldsymbol{\theta}$。

用 $\beta^{\boldsymbol{\theta}}$ 与 $\beta^{\boldsymbol{W}}$ 两个独立学习率分别更新。

与 REINFORCE 的差别：那里用完整回报 G_t 作权重，这里换成单步 TD 误差 δ_t，更新可以逐步进行，方差也更低。

从基线到时序差分误差

$$\nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta}) = \mathbb{E}_{\pi}\big[\,(G_t - v(s;\boldsymbol{W}))\,\nabla_{\boldsymbol{\theta}} \ln \pi(A_t \mid S_t;\boldsymbol{\theta})\big] \tag{7-93}$$

$$= \mathbb{E}_{\pi}\big[\,(R_{t+1} + \gamma v(S_{t+1};\boldsymbol{W}) - v(S_t;\boldsymbol{W}))\,\nabla_{\boldsymbol{\theta}} \ln \pi(A_t \mid S_t;\boldsymbol{\theta})\big] \tag{7-94}$$

$$= \mathbb{E}_{\pi}\big[\delta_t \nabla_{\boldsymbol{\theta}} \ln \pi(A_t \mid S_t;\boldsymbol{\theta})\big] \tag{7-95}$$

式 (7-94)：把 G_t 换成单步 TD 目标 $R_{t+1} + \gamma v(S_{t+1};\boldsymbol{W})$；式 (7-95)：括号内即 TD 误差 $\delta_t = R_{t+1} + \gamma v(S_{t+1};\boldsymbol{W}) - v(S_t;\boldsymbol{W})$。

式 (7-93)

回报减基线，权重覆盖整幕。

式 (7-94)

用一步自举替代回报，权重只看一步。

式 (7-95)

写成 δ_t，演员与评论家共用。

- $\delta_t > 0$ 说明这一步比预期好，提高该动作概率；$\delta_t < 0$ 则降低。
- 用自举替代采样回报，仍保持"相对优势"的含义，但不再需要等一幕结束。

依据 《大语言模型：训练、精调与对齐》第 7.7.1 节（式 (7-93)–(7-95)）

算法 11　演员-评论家算法

算法 11 “演员-评论家” 算法

输入： 给定含参数 $\boldsymbol{\theta}$ 的策略模型 $\pi(a|s;\boldsymbol{\theta})$，学习率 $\beta^{\boldsymbol{\theta}}$，给定参数 W 的状态价值函数 $v(s,W)$, 学习率 $\beta^{\boldsymbol{W}}$，折扣因子 γ

输出： 最优策略 $\pi(a|s;\boldsymbol{\theta}_*)$ 的参数 $\boldsymbol{\theta}_*$ 模型，状态价值模型 $v(s;\boldsymbol{W}_*)$

for 每一幕 **do**
  初始化状态 S
  $I \leftarrow 1$
  for 对幕中的每一步循环,$t = \{T-1, T-2, \cdots, 1, 0\}$ **do**
    $A_t \sim \pi(\cdot|S_t;\boldsymbol{\theta})$,
    执行动作 A_t，得到奖励 R 并跳转到下一个状态 S_{t+1}
    $\delta \leftarrow R + \gamma v(S_{t+1};\boldsymbol{W}) - v(S_t;\boldsymbol{W})$
    $\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \beta^{\boldsymbol{\theta}} I \delta \nabla \ln \pi(A_t|S_t;\boldsymbol{\theta})$
    $\boldsymbol{W} \leftarrow \boldsymbol{W} + \beta^{\boldsymbol{W}} \delta \nabla v(S_t;\boldsymbol{W})$
    $I \leftarrow \gamma I$
    $S \leftarrow S'$
  end for
end for

第 7 步算 TD 误差；第 8、9 步用同一个 δ 分别更新演员与评论家；第 10 步的 I 是折扣累计因子，用于给早期动作合适的权重。

演员与评论家的更新

采样

$A_t \sim \pi(\cdot \mid S_t; \boldsymbol{\theta})$

→

评论家

算 $\delta_t = R + \gamma v(S_{t+1}) - v(S_t)$

→

演员

$\boldsymbol{\theta} \mathrel{+}= \beta^{\boldsymbol{\theta}} \delta_t \nabla \ln \pi$

→

评论家更新

$\boldsymbol{W} \mathrel{+}= \beta^{\boldsymbol{W}} \delta_t \nabla v$

演员的目标

最大化累积奖励：沿 $\nabla_{\boldsymbol{\theta}} \ln \pi$ 的方向，按 δ_t 调整动作概率。

评论家的目标

最小化时序差分误差 δ_t^2：让 $v(s; \boldsymbol{W})$ 更准确地预测实际回报。

两者共用同一个 δ_t，但更新方向不同：演员做梯度上升，评论家做梯度下降。学习率分开设置，是因为两个模型的尺度与收敛速度不同。

依据 《大语言模型：训练、精调与对齐》第 7.7.1 节

TRPO 算法

为提升策略梯度训练的稳定性，需要避免在单个训练步中对策略做过大调整。信赖域策略优化（TRPO）采用 KL 散度约束每次迭代的策略更新幅度。

在离轨强化学习设置中，行为策略 β 收集轨迹数据，目标策略 π 被优化。目标函数涉及状态访问分布与动作优势函数；当训练数据分布与目标策略的状态分布存在差异时，通过重要性采样进行偏差校正。

$$J(\boldsymbol{\theta}) = \sum_{s\in\mathcal{S}} \rho^{\pi_{\boldsymbol{\theta}_{\text{old}}}} \sum_{a\in\mathcal{A}} \left(\pi_{\boldsymbol{\theta}}(a \mid s) \hat{A}_{\boldsymbol{\theta}_{\text{old}}}(s,a) \right) \tag{7-96}$$

$$= \sum_{s\in\mathcal{S}} \rho^{\pi_{\boldsymbol{\theta}_{\text{old}}}} \sum_{a\in\mathcal{A}} \left(\beta(a \mid s) \frac{\pi_{\boldsymbol{\theta}}(a \mid s)}{\beta(a \mid s)} \hat{A}_{\boldsymbol{\theta}_{\text{old}}}(s,a) \right) \tag{7-97}$$

$$= \mathbb{E}_{s\sim\rho^{\pi_{\boldsymbol{\theta}_{\text{old}}}}, a\sim\beta} \left[\frac{\pi_{\boldsymbol{\theta}}(a \mid s)}{\beta(a \mid s)} \hat{A}_{\boldsymbol{\theta}_{\text{old}}}(s,a) \right] \tag{7-98}$$

$\boldsymbol{\theta}_{\text{old}}$ 是更新前的策略参数，$\rho^{\pi_{\boldsymbol{\theta}_{\text{old}}}}$ 是旧策略的状态访问分布，$\beta(a \mid s)$ 是收集轨迹的行为策略。式 (7-97) 乘除 β 完成重要性采样。

注意我们使用估计的优势函数 $\hat{A}_{\boldsymbol{\theta}_{\text{old}}}(s,a)$ 替代真实优势 $A(s,a)$，因为真实奖励未知；估计值由 GAE 给出，通过减少方差提升稳定性。

TRPO 的目标函数

在 TRPO 的在线算法中，数据由当前策略 $\pi_{\boldsymbol{\theta}_{\text{old}}}$ 收集，因此优化函数简化为：

$$J(\boldsymbol{\theta}) = \mathbb{E}_{s\sim\rho^{\pi_{\boldsymbol{\theta}_{\text{old}}}},a\sim\pi_{\boldsymbol{\theta}_{\text{old}}}}\left[\frac{\pi_{\boldsymbol{\theta}}(a\mid s)}{\pi_{\boldsymbol{\theta}_{\text{old}}}(a\mid s)}\hat{A}_{\boldsymbol{\theta}_{\text{old}}}(s,a)\right] \tag{7-99}$$

$$\text{s.t.}\quad \mathbb{E}_{s\sim\rho^{\pi_{\boldsymbol{\theta}_{\text{old}}}}}\left[D_{\text{KL}}\left(\pi_{\boldsymbol{\theta}_{\text{old}}}(\cdot\mid s)\,\|\,\pi_{\boldsymbol{\theta}}(\cdot\mid s)\right)\right]\leqslant\delta \tag{7-100}$$

式 (7-99) 把式 (7-98) 中的行为策略 β 换成旧策略 $\pi_{\boldsymbol{\theta}_{\text{old}}}$；式 (7-100) 的信赖域约束要求新旧策略之间的 KL 散度期望值小于阈值 δ，确保策略更新落在信赖域内。

- 使用估计的优势函数 $\hat{A}_{\boldsymbol{\theta}_{\text{old}}}(s,a)$ 替代真实优势 $A(s,a)$，因为真实奖励未知。
- 估计的优势函数采用 GAE，通过减少方差提升稳定性（见下页）。
- KL 约束把"一步走多远"变成可以显式控制的量，这是 TRPO 稳定性的来源。

代价是求解复杂：带约束的优化需要二阶信息或共轭梯度，实现成本高。下一节 PPO 用裁剪把同一件事做得更简单。

广义优势估计（GAE）

广义优势估计（GAE）是一种基于时序差分误差的优势函数估计方法：利用旧策略的价值函数 V 计算 TD 误差，再通过 λ-加权回溯得到每个时刻的优势估计。

$$A(S_t, A_t) = q_\pi(S_t, A_t) - v_\pi(S_t) \tag{7-101}$$

$$\delta_t = R_t + \gamma v_\pi(S_{t+1}) - v_\pi(S_t) \tag{7-102}$$

$$A_t^{\mathrm{GAE}} = \sum_{l=0}^{\infty} (\gamma\lambda)^l \delta_{t+l} \tag{7-103}$$

$$A_t^{\mathrm{GAE}} = \delta_t + (\gamma\lambda)\delta_{t+1} + (\gamma\lambda)^2\delta_{t+2} + \dots \tag{7-104}$$

式 (7-101) 是优势函数的定义；式 (7-102) 把它等价表示为 TD 误差的形式；式 (7-103) 对无穷多步 TD 误差做指数衰减加权。

式 (7-104) 只是把求和展开写开，便于看出权重是一个等比数列：δ_t 的系数为 1，δ_{t+1} 的系数为 $\gamma\lambda$，依此类推。

GAE 的递推形式

$$A_t^{\mathrm{GAE}} = \delta_t + \gamma\lambda\left(\delta_{t+1} + \gamma\lambda\delta_{t+2} + \dots\right) \tag{7-105}$$

$$A_t^{\mathrm{GAE}} = \delta_t + \gamma\lambda A_{t+1}^{\mathrm{GAE}} \tag{7-106}$$

式 (7-105) 从式 (7-104) 提出公因子 $\gamma\lambda$；括号内正是 A_{t+1}^{GAE} 的定义。$\lambda \in [0,1]$ 是 GAE 的超参数，控制不同步长 TD 误差的权重。

$\lambda = 0$

$\hat{A}_t^{\mathrm{GAE}} = \delta_t$，退化为单步 TD 误差。

高偏差、低方差。

$\lambda = 1$

退化为蒙特卡洛估计 $\hat{A}_t^{\mathrm{GAE}} = \sum_{l=0}^{\infty}\gamma^l\left(R_{t+l} + \gamma V(s_{t+l+1}) - V(s_{t+l})\right)$。

低偏差、高方差。

参数 λ 通过指数衰减加权机制，在不同步长 TD 误差的贡献之间取得平衡；它用于更新价值函数，目标是最小化新价值函数与 GAE 的均方误差。

PPO 算法

TRPO 通过 KL 散度约束策略更新幅度；近端策略优化（PPO）采用目标函数裁剪机制实现相似的约束效果。核心思想是通过限制策略更新幅度稳定训练，裁剪操作可有效约束策略参数的变化范围。

$$r_t(\boldsymbol{\theta}) = \frac{\pi_{\boldsymbol{\theta}}(a_t \mid s_t)}{\pi_{\boldsymbol{\theta}_{\text{old}}}(a_t \mid s_t)} \tag{7-107}$$

新旧策略的比率：$r_t = 1$ 表示策略未变；r_t 偏离 1 越远，说明这一步更新越大。

$$J^{\text{TRPO}}(\boldsymbol{\theta}) = \mathbb{E}_{s\sim\rho^{\pi_{\boldsymbol{\theta}_{\text{old}}}}, a\sim\pi_{\boldsymbol{\theta}_{\text{old}}}} \left[r_t(\boldsymbol{\theta}) \hat{A}_{\boldsymbol{\theta}_{\text{old}}}(s,a) \right] \tag{7-108}$$

TRPO 的优化目标。若直接最大化它而无约束，策略比率 $r_t(\boldsymbol{\theta})$ 可能出现极端值，导致参数更新不稳定。

依据 《大语言模型：训练、精调与对齐》第 7.7.3 节（式 (7-107)、(7-108)）

PPO 的裁剪目标

$$J^{\mathrm{CLIP}}(\boldsymbol{\theta}) = \mathbb{E}\left[\min\left(r_t(\boldsymbol{\theta})\hat{A}_{\boldsymbol{\theta}_{\mathrm{old}}}(s,a),\ \mathtt{clip}\left(r_t(\boldsymbol{\theta}), 1-\epsilon, 1+\epsilon\right)\hat{A}_{\boldsymbol{\theta}_{\mathrm{old}}}(s,a)\right)\right] \tag{7-109}$$

裁剪函数把比率限制在 $[1-\epsilon, 1+\epsilon]$ 内，ϵ 为超参数；外层取原始值与截断值的**最小值**。

$\hat{A} > 0$

目标函数限制策略改进的**上限**：比率超过 $1+\epsilon$ 后收益不再增加。

$\hat{A} < 0$

目标函数限制策略恶化的**下限**：比率低于 $1-\epsilon$ 后惩罚不再加重。

取最小值的效果：策略朝好的方向走，超过信赖域就不再给奖励；朝坏的方向走，超过界限也不再额外惩罚。于是更新被"夹"在一个小区间内。

裁剪机制的作用

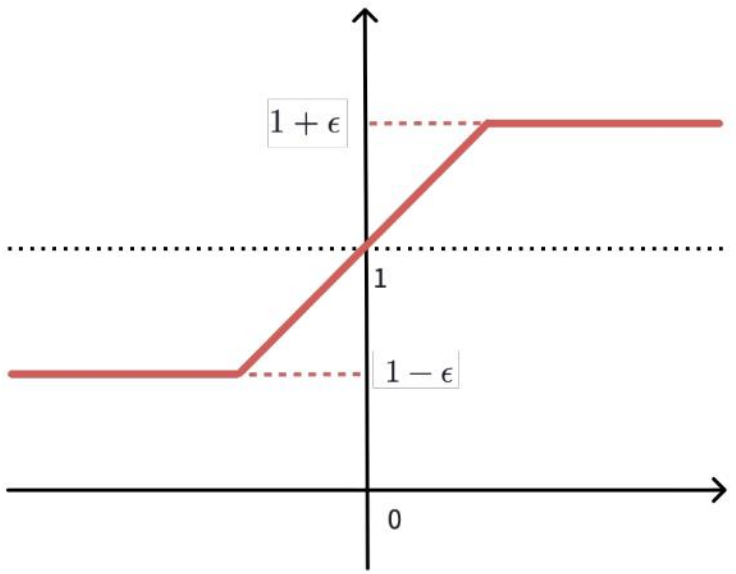


图 7.17　PPO 目标函数裁剪机制示意图

- 横轴是策略比率 r_t，纵轴是目标函数中的那一项。
- $\hat{A} > 0$ 时，$r_t > 1+\epsilon$ 后曲线转为水平：再增大比率也不会提高目标。
- $\hat{A} < 0$ 时，$r_t < 1-\epsilon$ 后曲线同样转为水平：再减小比率也不会降低目标。
- 通过取原始值与截断值的最小值，PPO 避免了因过度追求高回报而导致的策略突变。

算法 12　PPO-Clip 算法

算法 12 PPO-Clip 算法

输入： 初始策略参数 $\boldsymbol{\theta}$，价值函数参数 $\boldsymbol{W}$，裁剪参数 ϵ，折扣因子 γ，GAE 参数 λ，策略更新轮次 K，小批量大小 M，目标 KL 散度 δ，策略学习率 $\beta^{\boldsymbol{\theta}}$，价值学习率 $\beta^{\boldsymbol{W}}$，熵系数 c_2

输出： 优化后的策略参数 $\boldsymbol{\theta}_*$，价值函数参数 $\boldsymbol{W}_*$。

for 迭代 $i = 0, 1, 2, \cdots$ **do**
  用策略 $\pi_{\boldsymbol{\theta}}$ 收集轨迹集 $\mathcal{D}_i = \{(S_t, A_t, R_t, S_{t+1})\}$
  使用当前价值网络计算：$V_{\text{old}}(S_t) \leftarrow V(S_t; \boldsymbol{W})$　▷ 保存旧价值函数快照
  若 S_t 为终止状态，则令 $V_{\text{old}}(S_t) \leftarrow 0$
  初始化 $\hat{A}_T = 0$
  for $t = T-1, T-2, \cdots, 0$ **do**　▷ GAE 计算
    $\delta_t \leftarrow R_t + \gamma V_{\text{old}}(S_{t+1}) - V_{\text{old}}(S_t)$
    $\hat{A}_t \leftarrow \delta_t + \gamma\lambda \hat{A}_{t+1}$
  end for
  $\boldsymbol{\theta}_{\text{old}} \leftarrow \boldsymbol{\theta}$　▷ 保存旧策略参数
  for 更新轮次 $k = 1$ **to** K **do**　▷ 多轮策略更新
    将 $\mathcal{D}_i$ 随机划分为小批量 $\{\mathcal{D}'_1, \mathcal{D}'_2, \cdots\}$
    for 每个小批量 $\mathcal{D}'_m$ **do**
      计算概率比：$r_t(\boldsymbol{\theta}) = \frac{\pi_{\boldsymbol{\theta}}(A_t|S_t)}{\pi_{\boldsymbol{\theta}_{\text{old}}}(A_t|S_t)}$
      计算裁剪目标：$\mathcal{L}_t^{\text{CLIP}} = \min\left(r_t(\boldsymbol{\theta})\hat{A}_t, \texttt{clip}(r_t(\boldsymbol{\theta}), 1-\epsilon, 1+\epsilon)\hat{A}_t\right)$
      计算目标回报：$\hat{R}_t \leftarrow \hat{A}_t + V_{\text{old}}(s_t)$　▷ 固定目标值
      计算价值损失：$\mathcal{L}_t^{\text{VF}} = \left(V(S_t; \boldsymbol{W}) - \hat{R}_t\right)^2$
      计算策略熵：$\mathcal{H}_t = -\sum_a \pi_{\boldsymbol{\theta}}(a|S_t) \log \pi_{\boldsymbol{\theta}}(a|S_t)$
      计算小批量平均梯度并更新策略和价值网络参数
      更新策略：$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \beta^{\boldsymbol{\theta}} \nabla_{\boldsymbol{\theta}} \mathbb{E}[\mathcal{L}_t^{\text{CLIP}} + c_2 \mathcal{H}_t]$
      更新价值函数：$\boldsymbol{W} \leftarrow \boldsymbol{W} - \beta^{\boldsymbol{W}} \nabla_{\boldsymbol{W}} \mathbb{E}[\mathcal{L}_t^{\text{VF}}]$
    end for
    if $\text{KL}[\pi_{\boldsymbol{\theta}_{\text{old}}} || \pi_{\boldsymbol{\theta}}] > 1.5\delta$ **then**
      break
    end if
  end for
end for

PPO 的三个设计要点

要点一

多轮策略更新

对同一批经验执行多次更新（通常 $K = 3 \sim 10$ 次），显著提升样本利用效率，并确保训练稳定。

多次小幅更新能控制策略变化幅度，避免参数剧烈跳变导致策略崩溃。

要点二

熵正则项

$\mathcal{H}_t = -\sum_a \pi_{\boldsymbol{\theta}}(a \mid S_t) \log \pi_{\boldsymbol{\theta}}(a \mid S_t)$ 是策略分布的香农熵。

以系数 $c_2 \approx 0.01$ 正向激励，防止策略过早收敛到局部最优，维持探索能力。

要点三

价值函数损失

目标回报 $\hat{R}_t = \hat{A}_t + v_{\pi_{\text{old}}}(s; \boldsymbol{W})$：旧价值提供稳定基准，GAE 优势给出修正。

价值网络通过最小化 $\mathcal{L}_t^{\text{VF}} = (v_\pi(s; \boldsymbol{W}) - \hat{R}_t)^2$ 逼近真实价值。

三项设计分别对应“用足数据”“别停止探索”“给演员一个稳定的参照系”。再配合裁剪与提前停止，构成 PPO 的稳定性组合。

熵正则与价值损失

熵正则项

策略趋于确定性（某动作概率 $\to 1$）时熵值趋近 0；均匀分布时熵值最大。

主动增加随机性，驱使智能体持续探索潜在的高回报动作；训练初期尤其能避免陷入动作空间死角。

同时抑制策略网络输出过度尖锐的概率分布，维持动作选择的灵活性。

价值函数损失

$\hat{R}_t$ 实质是状态-动作对 (S_t, A_t) 的折扣累积回报估计值，作为 $v(s; \boldsymbol{W})$ 的学习目标。

右侧 $v_{\pi_{\text{old}}}(s; \boldsymbol{W})$ 是旧策略下状态 s_t 的基准价值估计，提供稳定预期。

左侧 $\hat{A}_t$ 是 GAE 算出的修正优势，量化特定动作相对平均水平的超额收益。

> **配套** 价值函数逐步逼近真实状态价值后，反过来为策略更新提供低方差的优势估计基准——这正是 PPO 中“评论家”的作用。

策略梯度框架的小结

策略梯度方法在连续状态问题中具有天然优势，且支持策略直接优化，在机器人控制、优化决策等领域应用广泛。其推导把状态转移概率内化至状态稳态分布，规避了随机转移建模的复杂性。

价值估计

基线、AC 评论家、GAE

策略更新

$\nabla_{\theta} \ln \pi \cdot \hat{A}$

稳定性控制

重要性采样、clip、KL

稳定训练

演员-评论家架构

- 采用无偏低方差的 GAE 优化价值估计。
- 在策略梯度中引入重要性采样与 `clip` 等技巧提升稳定性。
- 在演员-评论家架构中，价值估计方法始终发挥核心作用。

7.8

大语言模型的 MDP 描述

本节内容

7.8　大语言模型的 MDP 描述

把语言模型看成策略智能体：状态是已生成的前缀，动作是下一个词元，转移由拼接确定。

语言模型的 MDP 描述

大语言模型的环境可建模为 MDP，于是可以利用强化学习方法训练。四个要素与语言模型的生成过程一一对应。

状态 $S_t \in \mathcal{S}$

离散词元序列 $\boldsymbol{x}_{:t} = (x_1, x_2, \cdots, x_t)$，即已生成的前缀。

动作 $A_t \in \mathcal{A}$

$\mathcal{A} = \mathcal{V}$（$\mathcal{V}$ 为词表空间），即选择下一个词元。

状态转移

确定性的：拼接 $\boldsymbol{x}_{:t}$ 与 A_t 得 $S_{t+1} \leftarrow (\boldsymbol{x}_{:t}, A_t)$，序列长度变为 $t+1$。

奖励 R_t

由环境任务决定。在 RLHF 中，R_t 仅在终局状态 <EOS> 输出非零奖励分数，其他时刻 $R_t = 0$。

因此这是一棵"确定转移、稀疏终点奖励"的树：每个状态的分支数等于词表大小，只有走到结尾才结算。

语言模型作为策略模型

$$A_t \sim \pi_{\boldsymbol{\theta}}(\cdot \mid S_t) = \pi_{\boldsymbol{\theta}}(\cdot \mid \boldsymbol{x}_{:t})$$

$$S_{t+1} \leftarrow (\boldsymbol{x}_{:t},\, A_t) = \boldsymbol{x}_{:t+1}$$

状态 S_t 就是已生成的词元前缀 $\boldsymbol{x}_{:t}$；策略输出下一个词元的分布，采样得到 A_t，再把它拼到序列尾部，得到确定的下一个状态 S_{t+1}。

MDP 要素	语言模型中的对应物
状态 S_t	词元前缀 $\boldsymbol{x}_{:t} = (x_1, \ldots, x_t)$
动作 A_t	下一个词元，$\mathcal{A} = \mathcal{V}$
策略 $\pi_{\boldsymbol{\theta}}$	Softmax 输出的下一个词元分布
转移 $p(s' \mid s, a)$	确定性的拼接，$p = 1$
奖励 R_t	仅 $t = T$ 时由任务给出，其余为 0

一步生成：以「今天天气」为前缀，采样出「真」。

$$\pi_{\boldsymbol{\theta}}(\cdot \mid \text{今天天气}) = [\text{真} : 0.42,\ \text{不} : 0.31,\ \text{很} : 0.18,\ \cdots]$$

$$A_t = \text{真} \quad (\text{按 } 0.42 \text{ 采样})$$

$$S_{t+1} = (\text{今天天气},\ \text{真})$$

分布是策略，采样是执行动作，拼接是转移。$|\mathcal{A}|$ 等于词表大小，通常三万到十几万。

要点 动作空间等于词表、转移完全确定、奖励只在终止处——这三点决定了语言模型上的强化学习是“大树 + 稀疏终点奖励”。

动作空间极大

$|\mathcal{A}|$ 等于词表大小，$\arg\max$ 与全动作求和都不可行，只能采样。

转移完全确定

环境模型 $p(s' \mid s, a)$ 已知且为 1，难点全在策略与奖励，不在探索环境。

奖励稀疏

只有生成到终止符才有分数，G_t 要靠整条序列算出来，天然适合策略梯度。

依据 《大语言模型：训练、精调与对齐》第 7.8 节

从本章到第 8 章

范式一

基于人类反馈的强化学习

用人类偏好训练奖励模型，再以 PPO 等算法优化语言模型策略。

对应本章 7.6、7.7 的策略梯度与演员-评论家方法。

范式二

基于推理的强化学习

以可验证的答案正确性等信号作为奖励，强化模型的推理过程。

奖励稀疏、序列长，对采样效率与稳定性要求更高。

本章解决“算法是什么”，第 8 章解决“怎么用到语言模型上”。本章的 MDP 描述是两章之间的接口。

再往后看：指令微调中的 PPO（如 Instruct-GPT）正是把 7.7.3 节的裁剪目标直接作用在语言模型的词元分布上。

7.9 小结

本节内容

7.9 全章回顾

强化学习在 MDP 框架下定义问题，以最大化累积奖励为目标；价值方法、策略梯度与演员-评论家构成完整的求解体系。

本章结构

问题定义

MDP 与贝尔曼方程

状态、动作、转移、奖励、折扣构成五元组；贝尔曼方程把长期回报拆成“一步 + 下一状态价值”的递归。

7.1

基于价值

DP、MC、TD

模型已知用 DP；模型未知时 MC 用完整幕回报，TD 用一步奖励加自举；GPI 贯穿评估与改进。

7.3–7.5

基于策略

策略梯度与 AC

直接优化参数化策略；策略梯度定理绕开转移概率，GAE 降方差，TRPO 与 PPO 控制更新幅度。

7.6–7.7

- 表格型场景下，策略评估与策略改进交替进行，可用动态规划、蒙特卡洛估计与时序差分方法做策略优化。
- 模型未知或状态空间复杂时，用参数化模型（如 DQN）估计价值函数。
- 策略梯度定理支持通过梯度上升直接更新参数化策略；REINFORCE、演员-评论家、TRPO 与 PPO 都围绕稳定性设计。

依据 《大语言模型：训练、精调与对齐》第 7.9 节

语言模型作为策略智能体

语言模型可以在 MDP 框架下建模为一个策略智能体：通过调整其预测分布（即策略）来生成动作（词元），从而在特定任务场景中学习以获取更高的累积奖励。

前缀 $x_{:t}$

状态

下一个词元

动作，概率由 π_θ 给出

拼接

确定转移

终局奖励

整段输出的评分

> **实例** 在大语言模型领域，Instruct-GPT 利用 PPO 算法对语言模型进行微调，显著提升了模型在指令理解、安全性以及自然语言处理能力等方面的表现。这充分表明强化学习已成为优化语言模型的重要手段。

下一章将展开两类范式：基于人类反馈的强化学习，与基于推理的强化学习。

思考题与实践题

1 说明马尔可夫性质的含义，并解释为什么它能把序贯决策问题的历史压缩为当前状态。

2 从回报的递归式 $G_t = R_{t+1} + \gamma G_{t+1}$ 出发，推导贝尔曼期望方程，并指出"自举"在哪一步出现。

3 比较蒙特卡洛与时序差分：二者分别需要多少数据才能更新一次价值估计，偏差与方差各有什么特点。

4 写出 SARSA 与 Q 学习的更新式，说明同轨策略与离轨策略的差别，并解释为什么 Q 学习能收敛到 q_*。

5 DQN 的经验回放与目标网络分别解决了什么不稳定问题？若去掉其中之一，训练会出现什么现象？

6 推导 REINFORCE 的样本梯度，说明 $\nabla_\theta \ln \pi_\theta$ 的作用，以及基线为何不改变梯度的期望。

7 比较 TRPO 的 KL 约束与 PPO 的裁剪目标：二者都在限制策略更新幅度，实现方式与代价有何不同。

8 把语言模型的生成过程写成 MDP，指出状态、动作、转移与奖励，并说明 RLHF 中奖励为何只在 <EOS> 处非零。

本章算法的代码实现

每个算法一个文件、一个类，3×3 网格世界讲表格型方法，CartPole-v1 讲需要神经网络的方法。

文件	算法	教材位置	环境
dp.py	策略评估、策略改进、策略迭代、值迭代	7.3 节	网格（已知模型）
mc.py	首次访问 MC 估计、试探性出发 MC 控制	7.4 节	网格
td.py	表格型 TD(0) 策略评估	7.5.1 节	网格
sarsa.py	SARSA、期望 SARSA	7.5.2 节	网格
q_learning.py	Q 学习	7.5.3 节	网格
td_lambda.py	n 步回报、λ-回报、TD(λ)	7.5.4 节	网格
dqn.py	DQN：经验回放 + 目标网络	7.5.5 节	CartPole-v1
pg.py	REINFORCE、带基线、离轨策略	7.6.3 节	CartPole-v1
actor_critic.py	演员-评论家	7.7.1 节	CartPole-v1
gae.py	广义优势估计（纯函数，讲计算过程）	7.8.2 节	—
ppo.py	PPO-Clip，内部实现 GAE	7.7.3 节	CartPole-v1

配套 envs/grid_world.py 提供 deterministic / slip / wind 三种转移场景，bellman.py、transition.py、why_v_is_harder.py 给出本章各式的数值实例。每个文件都可 python 文件名.py 独立运行。