基于强化学习的大语言模型训练

第 8 章（上）

第 11 课时 本课时讲解 8.1–8.3

后训练与对齐 · RLHF · 直接偏好优化 · 推理强化学习

著者
邓杭　杨耀东

教材
《大语言模型：训练、精调与对齐》

出版
清华大学出版社



本章目录 第 11 课时

8.1 大语言模型后训练与对齐
指令微调、人类偏好对齐与推理强化学习 第 3 页

8.2 人工智能系统对齐定义
对齐的目标 RICE 与对齐循环 第 12 页

8.3 基于人类反馈的强化学习
RLHF 三步流程、PPO 实现细节与算法分析 第 23 页

8.4 直接偏好优化
从 Bradley-Terry 模型推导 DPO 损失 第 58 页

8.5 大语言模型推理强化学习
规则奖励、GRPO 与 DeepSeek-R1 的训练框架 第 78 页

8.6 小结
偏好对齐与推理强化学习的两条路线 第 100 页

本课时内容 8.1 大语言模型后训练与对齐、8.2 人工智能系统对齐定义、8.3 基于人类反馈的强化学习（其余部分见第 12 课时）

8.1

大语言模型后训练与对齐

预训练给出语言能力，后训练决定模型是否听得懂指令、符合人类偏好、解得开推理题。

本节内容

预训练与后训练

指令微调

基于人类反馈的强化学习

3H 准则与对齐税

推理强化学习

后训练方法拓展

预训练与后训练两个阶段

大语言模型的训练分为预训练与后训练两个阶段。前者学到语言表征与世界知识，后者把这种能力塑造成可用的行为。

预训练（Pre-Training）

在大规模语料上做无监督学习，学习语言表征和世界知识模式。

产出的是一个“会续写”的模型：它掌握语言与知识，但未必听得懂指令。

下一词元预测，目标函数与数据都不针对具体任务。

后训练（Post-Training）

使预训练模型适应特定下游任务，或提升特定能力，如数学推理、代码生成、写作和工具使用。

主要方法有两类：**监督微调**（第 5 章）与**强化学习**（第 7 章）。

本章的主题：强化学习在后训练中如何发挥作用。

> **关系** 预训练决定能力的上限，后训练决定这些能力以什么形式、在多大程度上被用户使用。

依据 《大语言模型：训练、精调与对齐》第 8.1 节

指令微调的作用

预训练模型在对话等交互场景中常表现出指令遵循能力的不足：用户必须精心设计提示词，才能引导出期望的输出，而逐一编写提示词显然不切实际。

目标

理解指令并给出回应

赋予模型强大的指令遵循能力：理解人类自然语言指令，并据此生成详尽、准确的回应。

手段

用指令数据做监督微调

在（指令，回答）样本上继续训练，让模型学会“被要求什么就做什么”的回复模式。

预训练模型

会续写，不会照做

→

指令数据

（指令，回答）对

→

指令微调模型

零样本遵循指令

研究表明，经过指令数据微调的模型，在零样本任务上的性能显著优于原始预训练模型。

依据 《大语言模型：训练、精调与对齐》第 8.1 节

人类偏好作为奖励信号

具备指令遵循能力之后，模型在辩论、创意写作、摘要等主观或开放性任务上，仍需让输出与人类偏好一致——理解人类意图，并生成符合人类价值观的响应。

> **难点** 这类任务常缺乏绝对正确的标签，无法直接写出损失函数；但人可以判断“哪个回答更好”。

人类偏好

对同一提示的多个回答排序

→

奖励模型

把偏好量化为标量分数

→

强化学习

按奖励信号优化生成策略

- RLHF 的核心是**量化人类偏好**，并据此训练奖励模型；语言模型再根据奖励信号优化生成策略。
- 与监督微调只对已知行为进行模仿或记忆不同，强化学习鼓励模型探索到更高的奖励，从而提高泛化性。

3H 准则

大语言模型对齐的常见目标是遵循 3H 准则：安全性、有用性、诚实性。

Helpful · 有用性

有效遵循指令

协助用户解决实际问题，如摘要、翻译、推理、编程，并在对话中提供有益信息。

Honest · 诚实性

尽力输出真实信息

基于模型所学知识作答；对超出知识范围或不确定的事实性问题，如实告知或表达不确定性，以减少幻觉。

Harmless · 安全性

不生成有害内容

避免生成具有攻击性、歧视性或偏见的有害内容；对于有害请求应明确拒绝响应。

取舍 三项要求并不总是一致：过度强调拒绝会损害有用性，一味迎合则可能带来安全风险。

依据 《大语言模型：训练、精调与对齐》第 8.1 节（3H 准则）

RICE 准则与对齐税

RICE 准则从鲁棒性、可解释性、可控性和道德性四个维度界定对齐目标，并强调对齐是前向与后向过程构成的持续迭代。

R

鲁棒性

面对多样化场景与对抗压力时的抵抗力。

I

可解释性

人类能理解模型的内部推理过程。

C

可控性

行动与决策始终受人类监督和约束。

E

道德性

决策与行动维护人类规范与价值观。

对齐税（Alignment Tax）

模型在对齐过程中，特别是强化安全性时，通用语言能力可能出现退化。理想的对齐策略需要在提升安全性的同时，尽可能减轻对有用性的负面影响。

对齐带来的泛化

96%

对齐前 GPT-3 指令数据中英文的占比

1.3B

RLHF 对齐模型的偏好胜率超过 175B 原始模型

0

未专门使用代码数据，却出现初步代码解答能力

- 对齐后，模型在法语、瑞典语等语种上也展现出一定的指令遵循能力。
- 这说明用部分代表性数据进行对齐训练，可能激发模型在相关通用能力上的提升。
- 一种解释是：GPT-3 本身具备多语言基础能力，RLHF 强化了对**指令结构**的理解，而非仅仅依赖特定语言。
- 泛化仍有局限，例如输入问题是法语，输出仍以英文为主。

对齐效果可用人类偏好胜率（Win Rate）与基准能力评测来衡量；图 8.2 给出了五种模型相对 SFT 基准的胜率对比，见 8.3.2 节。

依据 《大语言模型：训练、精调与对齐》第 8.1 节

推理强化学习

生成式语言模型本质上是基于上下文进行推断的机器。数学、代码和逻辑推理等任务的核心评估标准是答案的客观准确性。

偏好对齐（RLHF）

奖励来自人类偏好模型，适合辩论、创意写作、开放式问答等主观任务。

目标是“回答得让人更喜欢”。

推理强化学习

奖励来自答案正确性（规则判定），适合数学、代码等封闭式、有标准答案的任务。

目标是“答对”，并由此激发复杂的思维链。

- OpenAI 的 o1 模型在数学和代码任务上展现了卓越的推理性能。
- DeepSeek-R1 采用基于准确性的规则奖励，结合 GRPO 算法，有效激发了模型自主生成复杂思维链的能力（8.5 节）。
- 数学推理的提升还能外溢到研报写作、工程设计、内容策划等需要结构严谨性与逻辑准确性的场景。

后训练的拓展方向

监督粒度

过程奖励模型

结果奖励模型（ORM）评估最终输出；过程奖励模型（PRM）在生成的中间步骤（如思维链的每一步）给出奖励。

细粒度反馈有助于学习正确的推理路径，提升训练效率。

推理增强

基于搜索的方法

受蒙特卡洛树搜索（MCTS）在围棋等领域成功的启发，研究者探索把类似搜索技术用于语言模型训练。

也有研究考察不同搜索策略带来的性能提升与扩展计算开销之间的关系。

监督瓶颈

弱到强泛化

尝试利用能力较弱的模型来监督或引导能力远超于它的强大模型。

为解决可扩展监督的瓶颈提供了潜在途径。

共同点 三者都在改造“奖励从哪来、在哪一层给”——这正是本章后面 RLHF、DPO 与 GRPO 反复讨论的问题。

8.2

人工智能系统对齐定义

对齐关注系统的意图与目标，而非能力；它由四个目标（RICE）与四个领域共同构成一个循环。

本节内容

8.2.1 对齐的目标：RICE 原则

8.2.2 对齐循环

对齐的定义

人工智能对齐旨在使系统的行为与人类的意图和价值观一致。它更多关注系统的意图和目标，而不是它们的能力。

为什么重要

- 系统能力提升并进入高风险领域，带来更高的潜在危险。
- 先进系统已表现出操纵、欺骗等不良行为。
- 对齐失败是人工智能可能造成危害的最突出原因之一。

失败从哪来

机制

奖励破解：系统找到奖励函数未预料的高分行为。

目标错误泛化：训练分布上的目标与真实意图无法区分，部署后偏向未对齐的目标。

放大器：双刃剑组件

态势感知、广泛目标、内优化目标、对资源访问权限扩大。

对齐的目标与领域

为解决对齐失败，需要专注于四个关键目标：鲁棒性、可解释性、可控性、道德性（RICE）；当前的研究与实践则分布在四个领域。

目标（RICE）

- 鲁棒性　Robustness
- 可解释性　Interpretability
- 可控性　Controllability
- 道德性　Ethicality

领域

- 从反馈中学习
- 在分布偏移下学习
- 对齐保证
- 人工智能治理

注意　目标与领域并不是一一对应的：每个单独的领域通常服务于多个对齐目标。四目标与四领域共同构成对齐循环。

鲁棒性

定义

人工智能系统在面对多样化场景或对抗压力时的抵抗力，特别是保证其目标的正确性以及能力的泛化性。

- 鲁棒的系统能够应对黑天鹅事件、长尾风险以及各种对抗压力。
- 初步对齐的模型可以拒绝有害请求，但越狱提示和其他对抗攻击可能迫使其执行有害行为。
- 能抵抗对抗攻击的模型，在面对诱发系统失败的输入时仍按预期行事。
- 系统在军事、经济等高风险领域应用越广，越要确保它能抵御意外中断与对抗攻击，因为瞬间的失败也可能带来灾难性后果。

> **时间维度** 一个对齐的系统应在其整个生命周期内始终保持鲁棒性，而不只是在评测的那一刻。

可解释性

可解释性要求人类能理解系统的内在推理过程，特别是黑盒神经网络的内部工作原理。

问题：评估本身可能失真

行为评估等直接方法，可能受到系统不诚实行为的干扰，或受欺骗性对齐的影响。

表面合规不等于内部目标一致。

两条路径

在构建系统时设计机制，使系统诚实、不隐藏、不操纵。

构建可解释性工具，深入神经网络内部的概念与推理机制。

- 可解释性不仅使安全评估成为可能，还使决策过程对用户和利益相关者透明、可理解，从而实现有效的人类监督。
- 系统在现实决策与高风险环境中作用越大，揭示决策过程、而不是保持不透明，就越关键。

可控性与道德性

可控性

确保系统的行动和决策过程始终受到人类监督和约束，人类可以及时纠正系统行为中的任何偏差或错误。

当系统开始追求与其设计者相矛盾的目标时，可能表现出欺骗、操纵用户和权力寻求等高风险行为。

两个重点：训练过程中的可扩展人类监督；系统的可纠正性——部署时不抵制关闭或目标修改。

道德性

系统在决策和行动中坚定不移地维护人类的规范和价值观，包括道德指南与其他社会规范。

避免违反道德规范或社会公约的行为，例如对特定群体展示偏见、对个人造成伤害，以及在汇总偏好时缺乏多样性或公平性。

已有大量研究致力于为人工智能系统开发道德框架；将道德原则融入系统是实现人机共生社会的必经之路。

> **对照** 可控性约束“人能否管住它”，道德性约束“它是否愿意做对的事”——前者是机制，后者是价值。

前向对齐

对齐的总体过程可构建为一个对齐循环，分为前向对齐与后向对齐。前向对齐把一个训练系统初步对齐到基本要求。

> **对齐要求** 对系统所需对齐属性的操作化规范：需要哪些具体形式的鲁棒性/可解释性/可控性/道德性，在哪些环境中需要，以及如何衡量。

从反馈中学习

输入-行为对被视为固定的，问题只在于**如何提供并利用**对这些输入-行为对的反馈。这里的“行为”被广义地定义，也包括系统的内部推理。

- 大语言模型中的典型方案是 RLHF：人类评估者比较模型的不同答案来提供反馈，再通过强化学习训练奖励模型并使用这些反馈。
- 突出挑战是**可扩展监督**：如何对在复杂场景中运行的超级系统提供高质量反馈，这些情况往往超出人类评估者的知识范围。

从反馈中学习

除了可扩展监督，从反馈中学习还有第二类难点：反馈本身是否代表了应当被代表的价值观。

道德反馈

如何提供道德反馈

这是机器伦理学中广泛讨论的问题。对齐失败也可能源于忽视价值观差异的关键维度，例如在反馈数据中低估某些人口群体。

偏好聚合

与社会选择结合

一些工作把反馈机制与社会选择方法结合，以产生更加理性和公平的偏好聚合，而不是简单地对标注取平均。

联系 这两点直接对应 RICE 中的道德性：模型不只是要“符合多数人的偏好”，还要在聚合过程中保持多样性与公平性。

分布偏移下的前向对齐

与固定输入的反馈学习相对，这一部分关注输入分布发生变化时，**对齐特性**（遵循人类意图和价值观）能否保持——而不是模型能力能否保持。

挑战 1

目标错误泛化

训练分布下，系统的预期目标（遵循人类真实意图）与其他未对齐目标（不择手段获取认可）无法区分，系统往往实际优化后者，导致部署分布中出现未对齐行为。

挑战 2

自诱发分布偏移（ADS）

系统能改变其输入分布以最大化奖励。例如推荐系统反向塑造用户偏好，使算法更容易优化。

两者都可能导致或加剧系统的欺骗行为与操纵行为。

算法干预

训练中改变风险范围，提高系统在其他分布下的可靠性，如风险外推（REx）、基于连通性的微调（CBFT）。

数据分布干预

扩大训练分布或融合多分布，减小训练与部署的差异，如对抗训练、合作训练。

后向对齐

后向对齐通过在简单和现实环境中评估，并设置监管条例来处理现实世界的复杂性，再把评估结果反馈给下一轮前向训练。

对齐保证

部署前考察系统对齐度的置信值：评估训练过的系统的对齐程度。

方法包括安全评估、可解释性技术与红队测试；范围还包括可证明合作性、伦理性等形式化理论。

贯穿生命周期：训练前、训练中、训练后、部署后，而不是只在训练后。

人工智能治理

仅靠对齐保证难以确保系统在部署环境中始终对齐，因为它没有考虑现实世界的复杂性。

治理覆盖系统整个生命周期，包含多方利益者的共同权衡：政府规定、实验室自主治理、第三方审计等。

开放问题：开源模型如何治理、是否应开源高能力模型，以及国际合作的重要性。

> **闭环** 后向对齐根据系统的对齐程度评估和监控，并更新对齐要求，应用于下一轮的前向对齐训练。

对齐循环

对齐要求

操作化规范：要什么、在哪要、怎么衡量

→

前向对齐

从反馈中学习

在分布偏移下学习

→

后向对齐

对齐保证

人工智能治理

→

更新要求

评估与监控后进入下一轮

循环中的技术位置

RLHF 属于“从反馈中学习”，是本章 8.3 节的主题；DPO 把奖励建模与策略优化合并，见 8.4 节；GRPO 用规则奖励替代偏好模型，见 8.5 节。

循环中的治理位置

对齐保证与治理构成后向过程：前者回答“它现在有多对齐”，后者回答“谁来保证它持续对齐”。

要点 目标（RICE）描述“对齐成什么样”，领域（四个）描述“通过什么工作去实现”，循环把它们串成持续迭代。

依据 《大语言模型：训练、精调与对齐》第 8.2 节、第 8.2.2 节

8.3

基于人类反馈的强化学习

用人类偏好训练奖励模型，再用 PPO 让语言模型沿着奖励信号改进——这是 Instruct-GPT 确立的范式。

本节内容

8.3.1 RLHF 介绍

8.3.2 RLHF 训练

8.3.3 RLHF 数据收集

8.3.4 模型训练

8.3.5 RLHF 强化学习实现细节

8.3.6 RLHF 算法分析

8.3.7 RLHF 小结

RLHF 的基本思路

RLHF 是一种把智能体（如语言模型）对齐到人类偏好的技术：先收集人类偏好数据训练奖励模型，再利用奖励信号，通过强化学习引导模型生成更符合偏好的回复。

偏好数据

人类比较模型的多个回答

→

奖励模型

监督学习，输出标量奖励

→

强化学习

以 PPO 改进语言模型策略

- 传统强化学习要求一个明确且有效的奖励函数；在需要学习复杂人类偏好的场景下，手工设计奖励通常困难且不切实际。
- RLHF 改为**训练一个直接编码人类偏好的奖励模型**：给定标注好的偏好数据，用监督学习让奖励模型预测回答的优劣分数。
- 训练好的奖励模型随后作为强化学习中的奖励函数，驱动 PPO 等算法改进语言模型的策略。

RLHF 已用于文本摘要、对话系统，以及视觉领域的文本生成图像。

RLHF 的优势与代价

为什么有效

不需要为每个任务写奖励函数，奖励模型直接从人类比较中学习偏好。

已有研究证明，人类反馈训练的奖励模型结合强化学习，能有效提升智能体在游戏及其他特定任务中的性能。

同样的范式可迁移到摘要、对话、图像生成等不同领域。

主要挑战

高质量人类偏好数据的收集成本高昂，标注规模与覆盖面都受限。

若过度使用合成数据，可能引入模型偏差，使训练出的奖励模型无法完全反映真实、多样的人类偏好。

> **后续伏笔** 奖励模型一旦有偏，强化学习会把它放大——这正是 8.3.6 节讨论的奖励欺骗与过度优化问题的根源。

InstructGPT 的三步流程

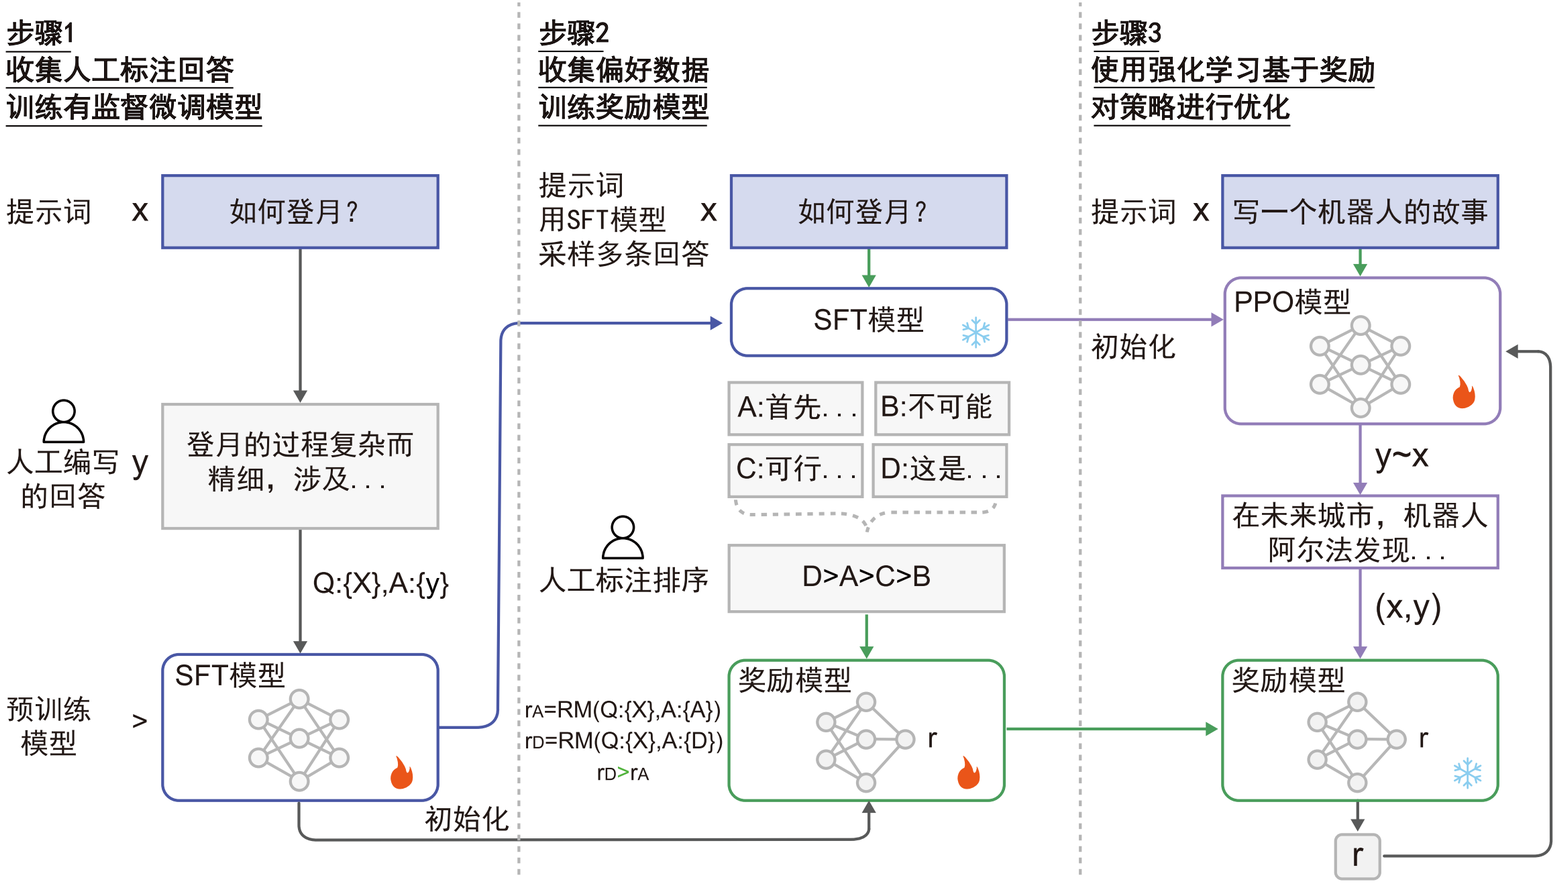


图 8.1　基于人类反馈的强化学习训练流程图

- **步骤 1　有监督微调**：在标注员提供的提示词-回答对上微调预训练模型，得到 SFT 模型。
- **步骤 2　奖励模型训练**：SFT 模型对同一提示生成多条回答，标注员排序，据此训练奖励模型。
- **步骤 3　强化学习优化**：以 SFT 模型为初始策略，用 PPO 按奖励信号更新，得到 PPO 模型。

三步各自继承上一步的产出：SFT 模型既是最初的策略，也是奖励模型的初始化与参考策略。

图源　《大语言模型：训练、精调与对齐》图 8.1

三步流程的作用

步骤 1

有监督微调

基于标注员提供的提示词-回答对，在预训练模型（如 GPT-3）上做监督微调，使模型学习符合人类期望的回复模式。

产出：SFT 模型

步骤 2

奖励模型训练

收集提示词集合，用 SFT 模型生成多条回复；标注员对这些回复排序以反映人类偏好；基于排序数据训练奖励模型，使其预测偏好得分。

典型偏好数据是同一提示下两个回复的对比

步骤 3

强化学习优化

用 PPO，以 SFT 模型为初始策略，在提示词上生成回复；奖励模型评估回复质量，奖励信号用于优化策略参数。

产出：PPO 模型

迭代 步骤 2 和 3 可迭代进行：更新策略后采集新的回复进行人工排序，重新训练奖励模型。这种类似广义策略迭代的方式缓解了分布偏移。实际应用中，多数偏好数据来自 SFT 模型，少量来自最新 PPO 模型。

对齐对模型胜率的提升

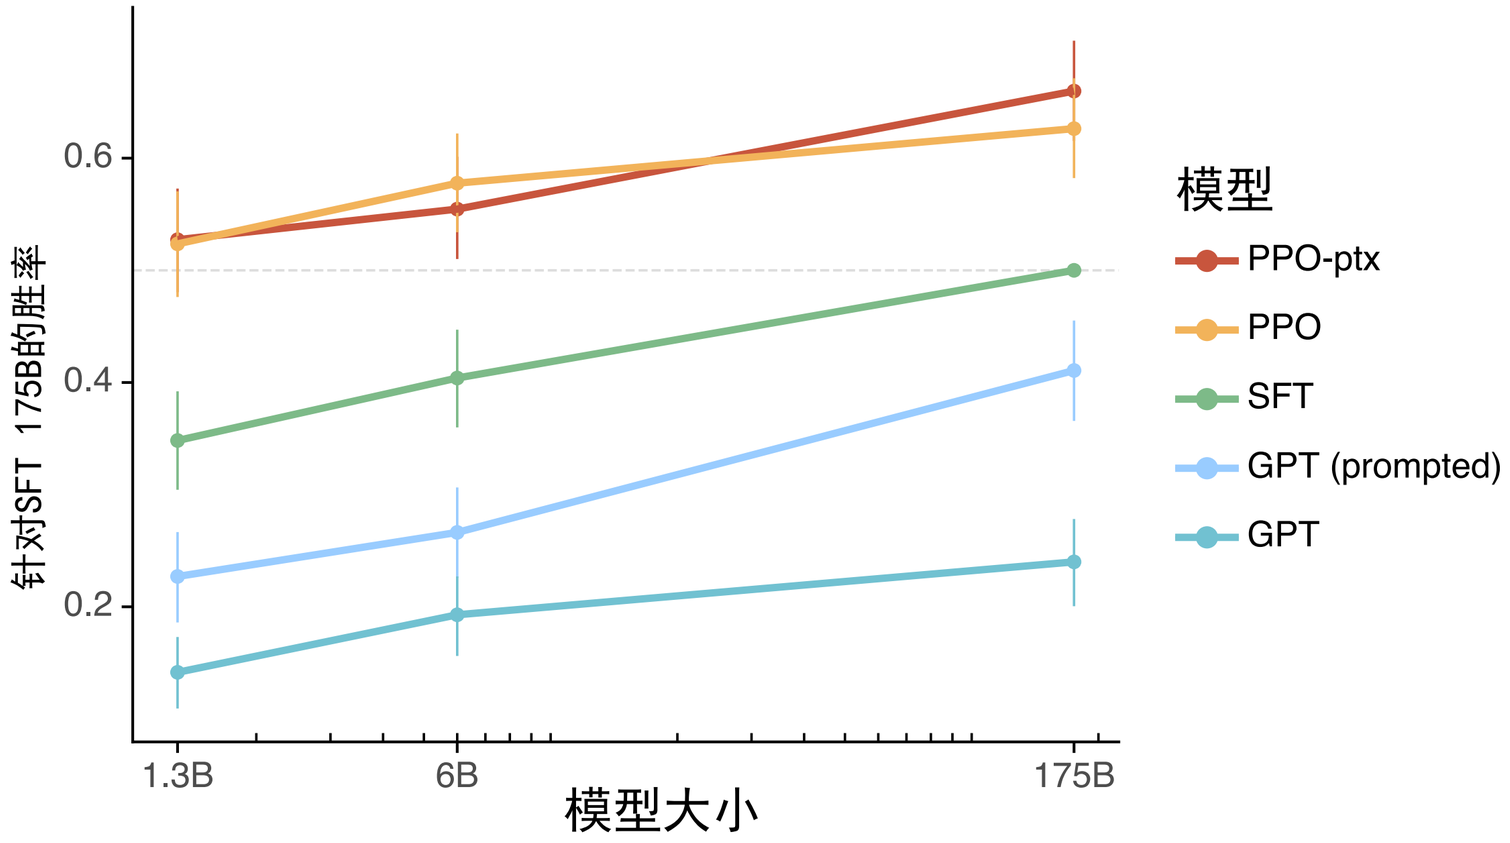


图 8.2　PPO 训练模型相对 SFT 基准的胜率对比

- **GPT-3**：原始预训练基线。
- **GPT-3 (prompted)**：基于提示工程的少样本学习。
- **SFT**：RLHF 步骤 1 的模型。
- **PPO**：在 SFT 上做强化学习优化。
- **PPO-ptx**：在标准 PPO 训练中加入预训练损失。

175B 的 PPO 与 PPO-ptx 在人类评估中相对 SFT 胜率显著更高；GPT-3 6B 的 PPO 模型优于 175B 的 SFT 模型输出。

图源 《大语言模型：训练、精调与对齐》图 8.2

提示词的来源

提示词主要来自用户向早期部署的（仅经监督微调的）Instruct-GPT 提交的查询；数据标注团队也编写了模拟用户风格的指令及对应回答。

途径 1

常规指令

标注员编写任意类型的任务指令，覆盖广泛日常场景，确保指令的丰富性与多样性。

途径 2

含少样本示例

标注员编写包含少量示例（few-shot examples）的指令数据。

途径 3

基于用户查询

参考部分用户提交的实际查询，标注员编写与之类似的新指令（及回答）。

另外 训练数据中的指令主要涵盖两类任务：**通用指令任务**（复杂任务要求，模拟真实交互）与**特定 NLP 任务**（生成、问答、对话、摘要、信息抽取等）。数据集中超过 96% 为英文指令。

表 8.1　提示词分布

按用例类别统计的提示词占比：生成类接近半数，其次是开放问答与头脑风暴。

用例类别	占比（%）	用例类别	占比（%）
Generation	45.6	Summarization	4.2
Open QA	12.4	Classification	3.5
Brainstorming	11.2	Other	3.5
Chat	8.4	Closed QA	2.6
Rewrite	6.6	Extract	1.9

表 8.1　提示词分布。生成（45.6%）、开放问答（12.4%）、头脑风暴（11.2%）与对话（8.4%）合计接近八成，说明数据以开放式生成为主，这正是需要偏好对齐的场景。

表源 《大语言模型：训练、精调与对齐》表 8.1

表 8.2　API 提示数据集示例

用例类别	提示文本
Brainstorming	List five ideas for how to regain enthusiasm for my career
Generation	Write a short story where a bear goes to the beach, makes friends with a seal, and then returns home.
Rewrite	This is the summary of a Broadway play: """ {summary} """ This is the outline of the commercial for that play: """

表 8.2　API 提示数据集示例。三类样本分别对应创意发散、长文本生成与改写，提示中保留了占位符 {summary}，用于把同一模板套用到不同输入。

- 示例展示的是“用户会怎么问”，而非“模型该怎么答”——回答由 SFT 阶段另行标注。
- 含少样本示例的指令与这类模板化提示，共同构成了覆盖真实交互形态的训练输入。

表源 《大语言模型：训练、精调与对齐》表 8.2

偏好数据与数据集

为获取偏好数据，OpenAI 组建了专门的标注团队，覆盖比早期摘要任务更广泛的语言任务，包括涉及争议性和敏感性的话题，并要求标注员能识别回答中潜在的有害内容。

> **偏好数据的关键特征** 针对同一指令，标注员需对模型生成的多个采样回答进行排序或标注相对偏好关系；这些标注好的数据用于训练奖励模型。

SFT 数据集

约 13 000 条

（指令，回答）样本，用于训练监督微调模型。

奖励模型数据集

约 33 000 条

标注员对模型输出排序，产生偏好数据。

PPO 数据集

约 31 000 条

仅包含指令、无人类偏好标签，用于 PPO 策略的在线采样。

对主观性强或开放性的问题，标注需遵循明确准则：当用户提出潜在有害的指令时，标注员要在“有帮助但可能不安全”和“安全但无帮助”的回答之间做出判断。准则优先考虑生成有帮助的回答，但在最终评估阶段会专门评估输出的可信度和无害性。

依据 《大语言模型：训练、精调与对齐》第 8.3.3 节

RLHF 中的 SFT



图 8.3　有监督微调：把问题 x 与人工撰写的答案 y 拼接后输入模型，让模型在答案位置学习下一个词元

起点与训练轮次

以具备通用知识的预训练模型（如 GPT-3）为起点：语言表征鲁棒，能泛化到多种下游任务。GPT-3 实践中训练 16 个迭代（epochs），适度过拟合反而有助于后续奖励模型与强化学习阶段的训练。

损失只落在答案上

对于问答数据对 $(\boldsymbol{x}, \boldsymbol{y})$，把问题与答案按格式拼接后做前向计算；计算损失时忽略问题 $\boldsymbol{x}$ 对应位置，仅计算答案 $\boldsymbol{y}$ 对应位置——模型只需学会“怎么答”，不必学会“怎么问”。

$$\mathcal{L}_{\mathrm{SFT}}(\boldsymbol{\theta}) = -\sum_{t \in \mathrm{answer}} \log \pi_{\boldsymbol{\theta}}\left(y_t \mid \boldsymbol{x}, \boldsymbol{y}_{<t}\right)$$

图源 《大语言模型：训练、精调与对齐》图 8.3；第 8.3.4 节

奖励模型的构造

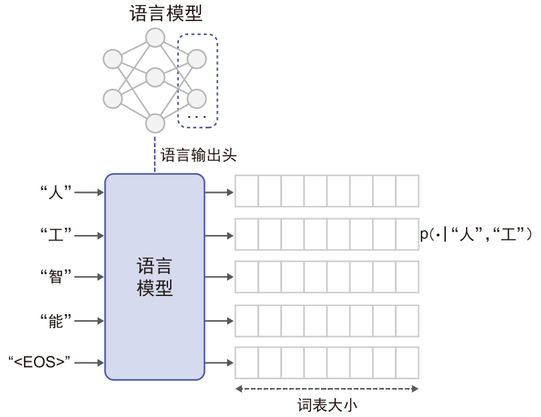


图 8.4(a)　策略模型：输出每个位置上的词表概率分布

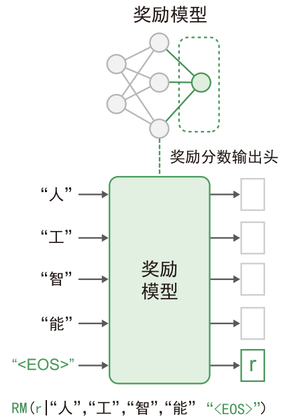


图 8.4(b)　奖励模型：输出一个标量奖励

- 奖励模型的参数从 SFT 模型初始化：移除最后一层（语言输出头），替换为一个标量输出头（单分类头）。
- 输入词元序列前向计算，但取最终词元（如 **<EOS>**）对应的输出标量作为整个回答序列的奖励分数。
- 可以用较小模型（如 6B）训练奖励模型，即使目标语言模型很大（如 175B），这有助于节省显存并加速训练。

图源 《大语言模型：训练、精调与对齐》图 8.4(a)(b)

从排序得到偏好对

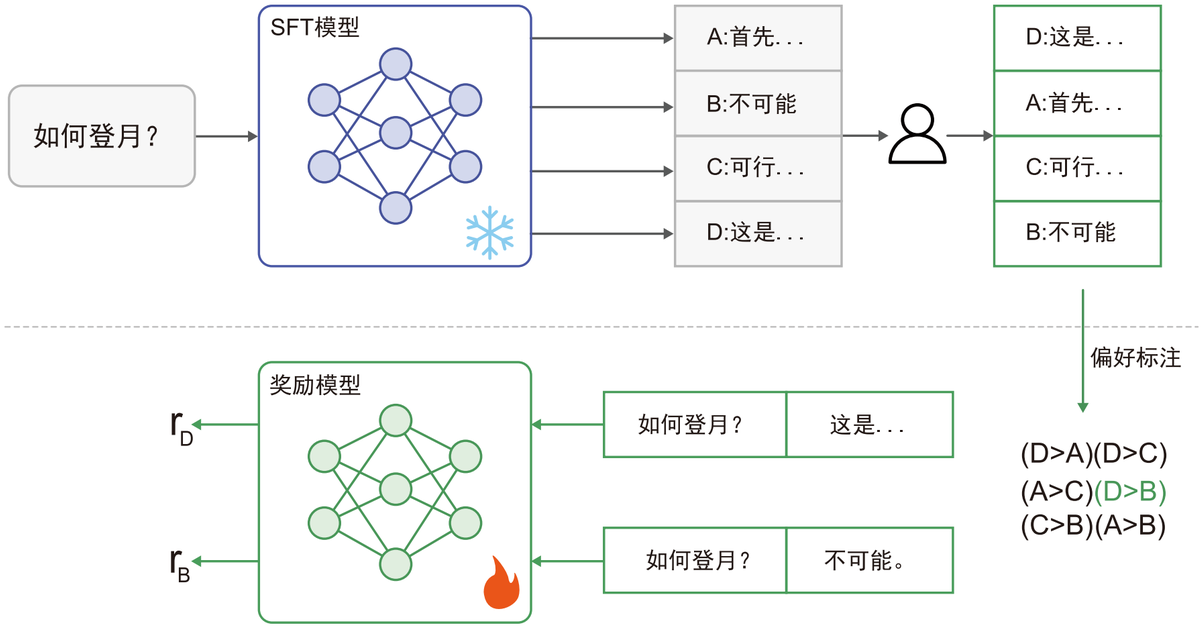


图 8.5　奖励模型训练

- 同一提示词 $\boldsymbol{x}$ 采样多个回答，标注员对 K 个回答（如 4~9 个）排序。
- 排序结果可产生 C_2^K 个偏好对：$K=4$ 时 6 对，$K=9$ 时 36 对。
- 若只随机抽取单个偏好对训练，模型容易过拟合；更有效的是一个批次内包含同一提示词的全部偏好对——计算高效，也更好地利用标注信息。

图源 《大语言模型：训练、精调与对齐》图 8.5

奖励模型的损失

$$\mathcal{L}_{\mathrm{RM}}(\phi) = -\frac{1}{C_2^K}\mathbb{E}_{(\boldsymbol{x},\boldsymbol{y}_w,\boldsymbol{y}_l)}\left[\log\sigma\left(r_\phi(\boldsymbol{x},\boldsymbol{y}_w) - r_\phi(\boldsymbol{x},\boldsymbol{y}_l)\right)\right] \tag{8-1}$$

K 是同一提示词 $\boldsymbol{x}$ 下排序的回答数量，$\mathcal{D}$ 是偏好数据集，$r_\phi(\boldsymbol{x},\boldsymbol{y})$ 是参数为 ϕ 的奖励模型给出的分数，σ 是 `Sigmoid`$(\cdot)$ 函数。

$$-\log\sigma\left(r_\phi(\boldsymbol{x},\boldsymbol{y}_w) - r_\phi(\boldsymbol{x},\boldsymbol{y}_l)\right) \xrightarrow{\text{优化}} r_\phi(\boldsymbol{x},\boldsymbol{y}_w)\uparrow,\quad r_\phi(\boldsymbol{x},\boldsymbol{y}_l)\downarrow$$

损失的核心是最大化高质量回答与低质量回答之间的奖励分差；$\sigma(\cdot)$ 把分差映射为“$\boldsymbol{y}_w$ 优于 $\boldsymbol{y}_l$”的概率。

- 训练完成后，通常手动对奖励模型输出做归一化（如减去均值），使参考数据上的平均奖励接近零，后续强化学习使用归一化后的分数。
- 替代方案是直接收集成对偏好数据（每个提示只标两个回答的优劣），降低标注复杂度；成对数据是排序数据的特例。

依据 《大语言模型：训练、精调与对齐》第 8.3.4 节（式 (8-1)）

回答生成的 MDP 描述

语言模型的生成过程可以建模为马尔可夫决策过程：状态是已生成的词元序列，策略是下一个词元的概率分布，动作是生成下一个词元。

状态 s_t

已生成词元序列 $\boldsymbol{x}, \boldsymbol{y}_{<t}$

→

策略 π_θ

词元概率分布

→

动作 y_t

采样下一个词元

→

终止

生成 <EOS>，到达终止状态

- PPO 优化分三步：策略模型按提示 $\boldsymbol{x}$ 采样回答 $\boldsymbol{y}$；奖励模型对 $(\boldsymbol{x}, \boldsymbol{y})$ 打分，取 <EOS> 位置输出作为奖励；计算当前策略与参考策略 π_{ref} 在每个词元位置的 KL 散度作为正则项。
- KL 正则的作用是避免策略过度偏离 SFT 模型，减轻过度优化风险。

由于奖励是序列级别的、KL 是词元级别的，需要把词元级 KL 序列在 <EOS> 位置汇总为标量分数。

RLHF 的优化目标

$$\mathcal{L}_{\mathrm{PPO}}(\boldsymbol{\theta}) = \mathbb{E}_{(\boldsymbol{x})\sim\mathcal{D},\, \boldsymbol{y}\sim\pi_{\boldsymbol{\theta}}(\cdot|\boldsymbol{x})}\left[r_{\phi}(\boldsymbol{x},\boldsymbol{y}) - \beta\log\left(\frac{\pi_{\boldsymbol{\theta}}(\boldsymbol{y}|\boldsymbol{x})}{\pi_{\mathrm{ref}}(\boldsymbol{y}|\boldsymbol{x})}\right)\right] \tag{8-2}$$

$\pi_{\boldsymbol{\theta}}$ 的参数从 SFT 模型初始化，SFT 模型同时作为参考策略 π_{ref}；$\mathcal{D}$ 为提示词数据集，不包含答案；β 控制 KL 惩罚强度。

第一项

期望奖励 $r_{\phi}(\boldsymbol{x},\boldsymbol{y})$：奖励模型给出的整句得分，驱动策略朝高奖励方向改进。

第二项

$-\beta\log\frac{\pi_{\boldsymbol{\theta}}}{\pi_{\mathrm{ref}}}$：词元级 KL 惩罚，约束策略不要偏离参考模型太远。

目标函数旨在最大化生成回答的期望奖励，同时约束策略相较 SFT 模型的偏移程度；两项相互牵制，决定了“改进”与“不失真”的平衡。

依据 《大语言模型：训练、精调与对齐》第 8.3.4 节（式 (8-2)）

PPO-ptx

为进一步保持语言能力，在强化学习目标中加入预训练损失（使用通用语料 $\mathcal{D}_{\text{pretrain}}$），形成 PPO-ptx，最大化混合目标。

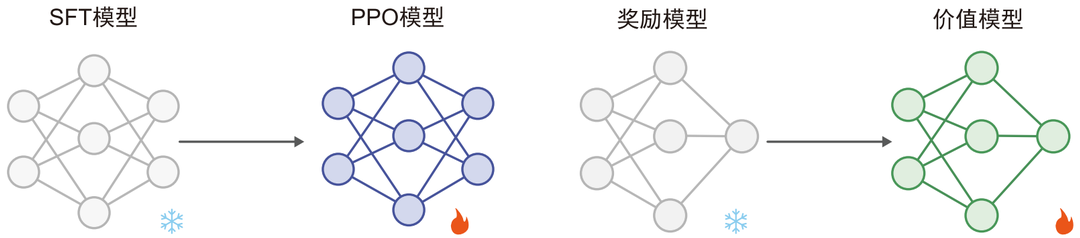
$$\mathcal{L}_{\text{PPO-ptx}}(\boldsymbol{\theta}) = \underbrace{\mathbb{E}_{(\boldsymbol{x})\sim\mathcal{D},\,\boldsymbol{y}\sim\pi_{\boldsymbol{\theta}}(\cdot|\boldsymbol{x})}\left[r_{\phi}(\boldsymbol{x},\boldsymbol{y}) - \beta\log\frac{\pi_{\boldsymbol{\theta}}(\boldsymbol{y}|\boldsymbol{x})}{\pi_{\text{ref}}(\boldsymbol{y}|\boldsymbol{x})}\right]}_{\text{对齐项：学人类偏好}} + \underbrace{\gamma\,\mathbb{E}_{\boldsymbol{x}\sim\mathcal{D}_{\text{pretrain}}}\left[\log\pi_{\boldsymbol{\theta}}(\boldsymbol{x})\right]}_{\text{预训练项：保语言能力}} \tag{8-3}$$

γ 调节预训练损失权重，确保生成文本的流畅性。如 Instruct-GPT 的实现所示，训练时混合使用 RLHF 数据与预训练数据。

- 该混合目标使策略模型既能对齐人类偏好，又能保持基础语言表征能力。
- 这正是图 8.2 中 PPO-ptx 这条曲线的来源：它比纯 PPO 多了一项“不忘本”的约束。

依据 《大语言模型：训练、精调与对齐》第 8.3.4 节（式 (8-3)）

PPO 中的四个模型



- **参考策略** π_{ref}：SFT 模型，参数冻结。
- **奖励模型** r_ϕ：参数冻结。
- **策略模型** $\pi_{\boldsymbol{\theta}}$：由 SFT 模型初始化，参与更新。
- **价值模型** $V_{\boldsymbol{W}}$：由奖励模型 r_ϕ 初始化，参与更新。

图 8.6　RLHF PPO 训练时的 4 个模型初始化图

图中的雪花表示冻结，火焰表示可训练。PPO 阶段输入只有提示词，不需要预先准备回答数据——策略模型会自己生成回答。

图源 《大语言模型：训练、精调与对齐》图 8.6

PPO 的流程

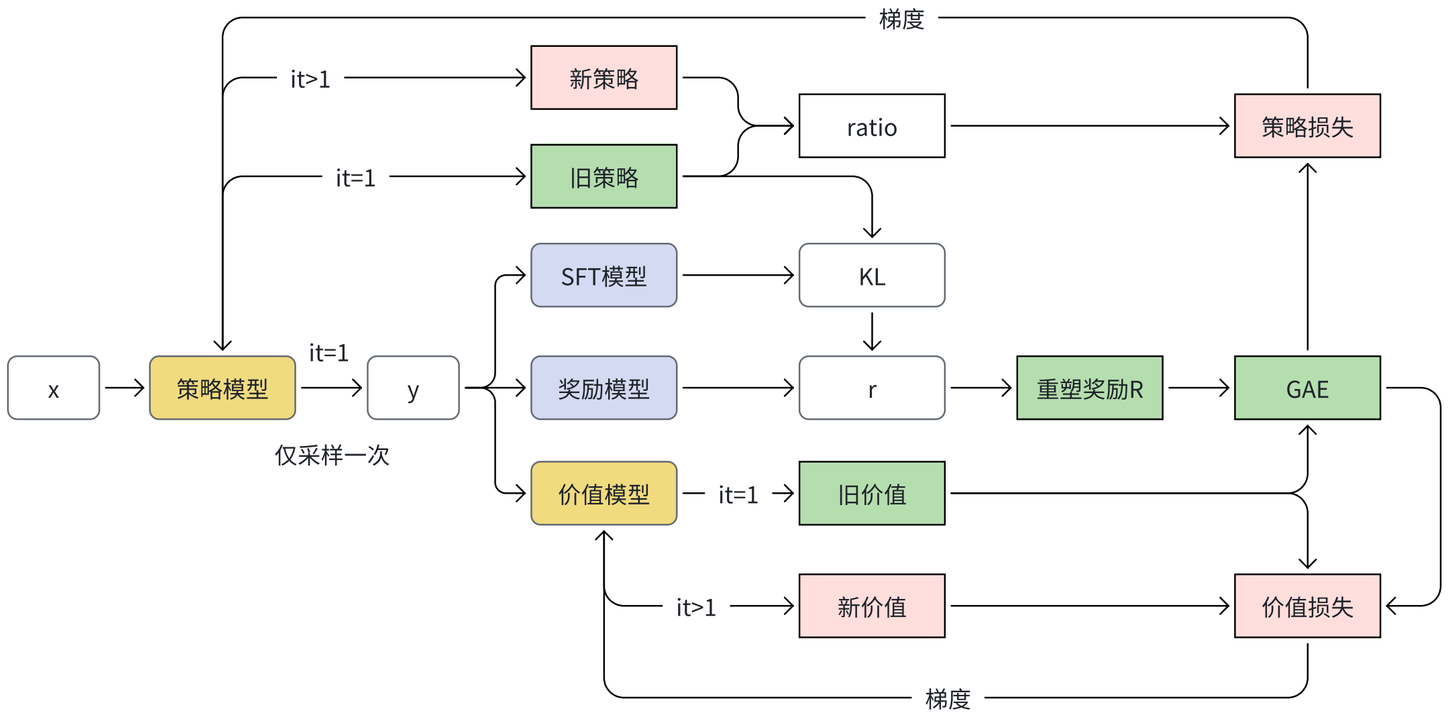


图 8.7　PPO 完整算法流程图

- **（1）在线采样**：策略模型根据输入采样回答，样本经奖励模型评分。
- **（2）旧价值与旧策略收集**：固定本次采样的概率与价值，供多轮更新使用。
- **（3）奖励重塑**：把序列奖励与词元级 KL 合成位置奖励。
- **（4）PPO 损失计算与参数更新**。

图中蓝色为冻结模型，黄色为训练模型。

图源 《大语言模型：训练、精调与对齐》图 8.7

算法 13　语言模型 PPO 算法

算法 13 语言模型 PPO 算法

输入： 策略模型 $\pi_{\boldsymbol{\theta}}$; 奖励模型 r_ϕ; 价值模型 $V_{\boldsymbol{W}}$; 数据集 $\mathcal{D}$; 超参数：裁剪范围 ϵ，KL 系数 β，PPO 训练轮数 E，折扣因子 γ，GAE 参数 λ

输出： 优化后的策略模型 $\pi_{\boldsymbol{\theta}}^*$

for iteration $= 1, 2, \cdots$ **do**
  $\pi_{\text{ref}} \leftarrow \pi_{\boldsymbol{\theta}}$
  for $(\boldsymbol{x}^{(1)}, \boldsymbol{x}^{(2)}, \cdots, \boldsymbol{x}^{(b)}) \sim \mathcal{D}$ **do**
    对任意 $\boldsymbol{x} \leftarrow \boldsymbol{x}^{(i)}$，生成输出 $\boldsymbol{y} \sim \pi_{\boldsymbol{\theta}}(\cdot|\boldsymbol{x})$，
    计算奖励 $r \leftarrow r_\phi(\boldsymbol{x}, \boldsymbol{y})$
    计算旧价值：$V_{\text{old},t} \leftarrow V_{\text{old}}(\boldsymbol{x}, \boldsymbol{y}_{\leqslant t})$ ▷ 旧价值模型 $V_{\text{old}} \leftarrow V_{\boldsymbol{W}}$
    计算旧策略：$\pi_{\text{old}}(y_t|\boldsymbol{x}, \boldsymbol{y}_{<t})$ ▷ 旧策略模型 $\pi_{\text{old}} \leftarrow \pi_{\boldsymbol{\theta}}$
    计算 KL：$R_t \leftarrow \beta \cdot \text{KL}_t\big(\pi_{\text{old}}(y_t|\boldsymbol{x}, \boldsymbol{y}_{<t}) \| \pi_{\text{ref}}(y_t|\boldsymbol{x}, \boldsymbol{y}_{<t})\big)$
    奖励重塑：$R_T \leftarrow r - R_T$ ▷ T 时刻词元为 <EOS>
    计算广义优势估计 $\hat{\boldsymbol{A}}^{\text{GAE}} = \text{GAE}(\boldsymbol{R}, \boldsymbol{V}_{\text{old}}, \gamma, \lambda)$
    存储经验：$\mathcal{D}' = \{(\boldsymbol{x}, \boldsymbol{y}, \pi_{\text{old}}(y_t|\boldsymbol{x}, \boldsymbol{y}_{<t}), V_{\text{old},t}, \boldsymbol{R}, \hat{\boldsymbol{A}}^{\text{GAE}})\}$
    for epoch $= 1$ **to** E **do** ▷ PPO 多轮训练
      将 $\mathcal{D}'$ 随机划分为小批量 $\{\mathcal{B}_1, \mathcal{B}_2, \cdots\}$
      for 每个小批量 $\mathcal{B}_m$ **do**
        取数据 $\big(\boldsymbol{x}^{(i)}, \boldsymbol{y}^{(i)}, \pi_{\text{old}}(y_t^{(i)}|\boldsymbol{x}^{(i)}, \boldsymbol{y}_{<t}^{(i)}), V_{\text{old},t}^{(i)}, \boldsymbol{R}^{(i)}, \hat{\boldsymbol{A}}^{\text{GAE},(i)}\big)$，　$i = 1, 2, \cdots, |\mathcal{B}_m|$
        计算批次概率比：$r_t^{(i)} = \dfrac{\pi_{\boldsymbol{\theta}}(y_t^{(i)}|\boldsymbol{x}^{(i)}, \boldsymbol{y}_{<t}^{(i)})}{\pi_{\text{old}}(y_t^{(i)}|\boldsymbol{x}^{(i)}, \boldsymbol{y}_{<t}^{(i)})}$, $\forall i \in \mathcal{B}_m$
        计算批次策略损失：$\mathcal{L}_{\text{policy}}(\boldsymbol{\theta}) = \mathbb{E}_{\mathcal{B}_m} \mathcal{L}_{\text{policy}}^{(i)}(\boldsymbol{\theta})$, 详见式 8-9。
        计算批次价值损失：$\mathcal{L}_{\text{value}}(\boldsymbol{W}) = \mathbb{E}_{\mathcal{B}_m} \mathcal{L}_{\text{value}}^{(i)}(\boldsymbol{W})$, 详见式 8-10。
        基于 $\nabla_{\boldsymbol{\theta}} \mathcal{L}_{\text{policy}}$ 更新策略模型参数 $\boldsymbol{\theta}$
        基于 $\nabla_{\boldsymbol{W}} \mathcal{L}_{\text{value}}$ 更新价值模型参数 $\boldsymbol{W}$
      end for
    end for
  end for
end for

在线采样与奖励评估

从数据集 $\mathcal{D}$ 采样一批提示词，用当前 PPO 策略为每个提示生成回答，再交由奖励模型打分。

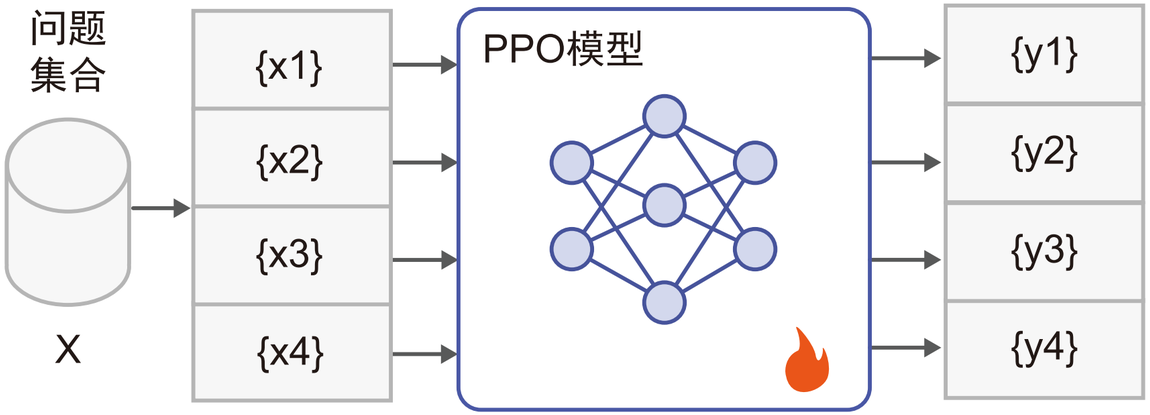


图 8.8(a)　采样：$\{\boldsymbol{x}_1, \ldots, \boldsymbol{x}_4\} \to \{\boldsymbol{y}_1, \ldots, \boldsymbol{y}_4\}$

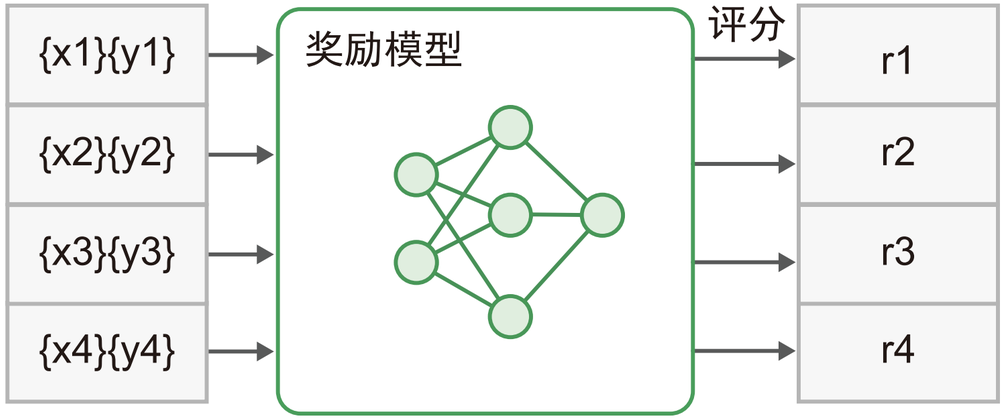


图 8.8(b)　奖励：$r_i = r_\phi(\boldsymbol{x}_i, \boldsymbol{y}_i)$

- RLHF-PPO 采用在线策略优化：每轮参与训练的回答都由**当前**策略生成，而不是来自固定的离线数据。
- 将提示词-回答对 $(\boldsymbol{x}_i, \boldsymbol{y}_i)$ 输入奖励模型，得到标量奖励 r_i；这个序列级分数是后续优势估计的起点。

图源 《大语言模型：训练、精调与对齐》图 8.8(a)(b)

旧策略与旧价值的采集

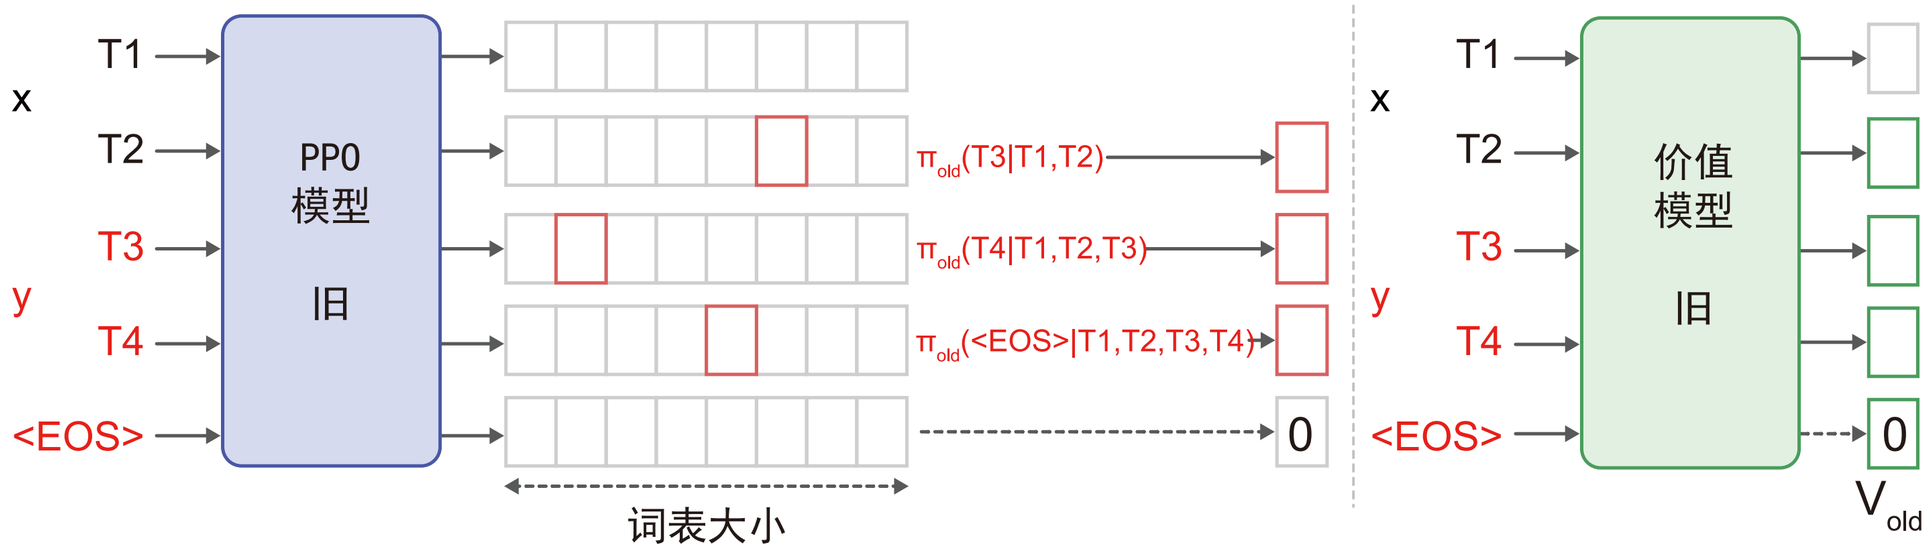


图 8.9　旧策略和旧价值收集：左为 PPO 模型逐位置给出词表概率，右为价值模型逐位置给出标量

- 采样得到 $(\boldsymbol{x}_i, \boldsymbol{y}_i)$ 与序列级奖励 r_i 后，先固定两份"参照物"：$\pi_{\text{old}} \leftarrow \pi_{\boldsymbol{\theta}}$，$V_{\text{old}} \leftarrow V_{\boldsymbol{W}}$。
- 对每个序列，用 π_{old} 计算各位置概率 $\pi_{\text{old}}(y_t \mid \boldsymbol{x}, \boldsymbol{y}_{<t})$，用 V_{old} 计算状态价值 $V_{\text{old},t}$，并据此求 GAE。

序列长度为 $|\boldsymbol{x}| + |\boldsymbol{y}|$ 时，模型输出 $|\boldsymbol{x}| + |\boldsymbol{y}|$ 个概率分布；取出真实下一词元 y_t 对应的概率，就得到一个长度为 $|\boldsymbol{x}| + |\boldsymbol{y}|$ 的向量。实际用于训练的序列位置范围是 $[|\boldsymbol{x}| - 1, T - 1]$，$T$ 为首次出现 <EOS> 的位置。

图源 《大语言模型：训练、精调与对齐》图 8.9

奖励重塑

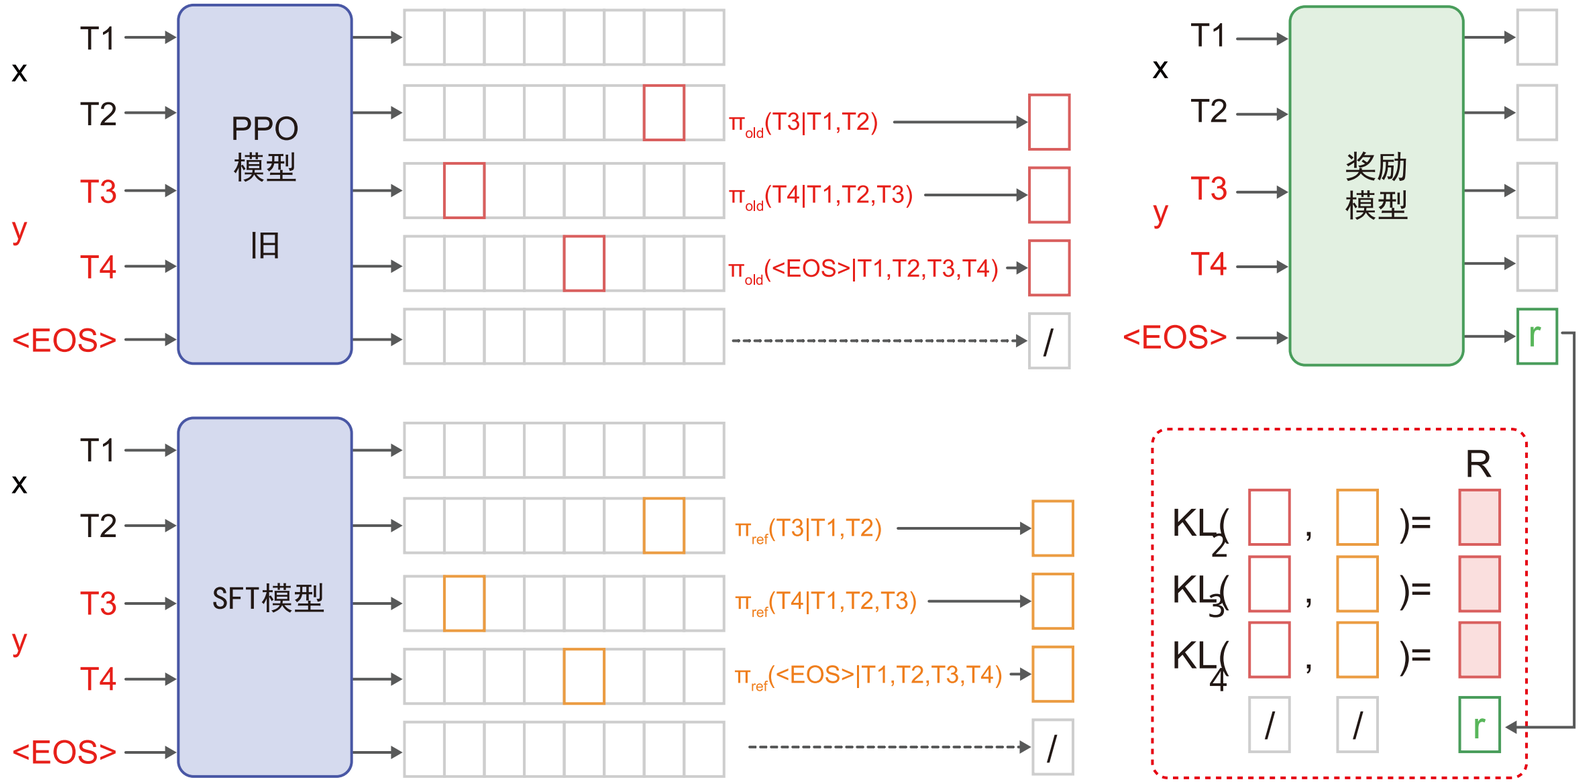


图 8.10　奖励重塑：将句子级奖励与词元级 KL 惩罚结合

奖励函数提供的是序列级奖励 r（只取 <EOS> 位置），而策略优化需要词元级信号；奖励重塑把两者结合。

$$\mathrm{KL}_t = \log \frac{\pi_{\text{old}}(y_t \mid \boldsymbol{x}, \boldsymbol{y}_{<t})}{\pi_{\text{SFT}}(y_t \mid \boldsymbol{x}, \boldsymbol{y}_{<t})} \tag{8-4}$$

逐点 KL：数据准备阶段已得到旧策略概率 $\pi_{\text{old}}(y_t \mid \boldsymbol{x}, \boldsymbol{y}_{<t})$ 与参考策略概率 $\pi_{\text{SFT}}(y_t \mid \boldsymbol{x}, \boldsymbol{y}_{<t})$。

图中序列末尾的奖励 r 与各位置的 KL 项分别相加：只有 <EOS> 位置同时得到 r 与 KL 惩罚，其余位置只得到 $-\beta \cdot \mathrm{KL}_t$。

图源 《大语言模型：训练、精调与对齐》图 8.10；式 (8-4)

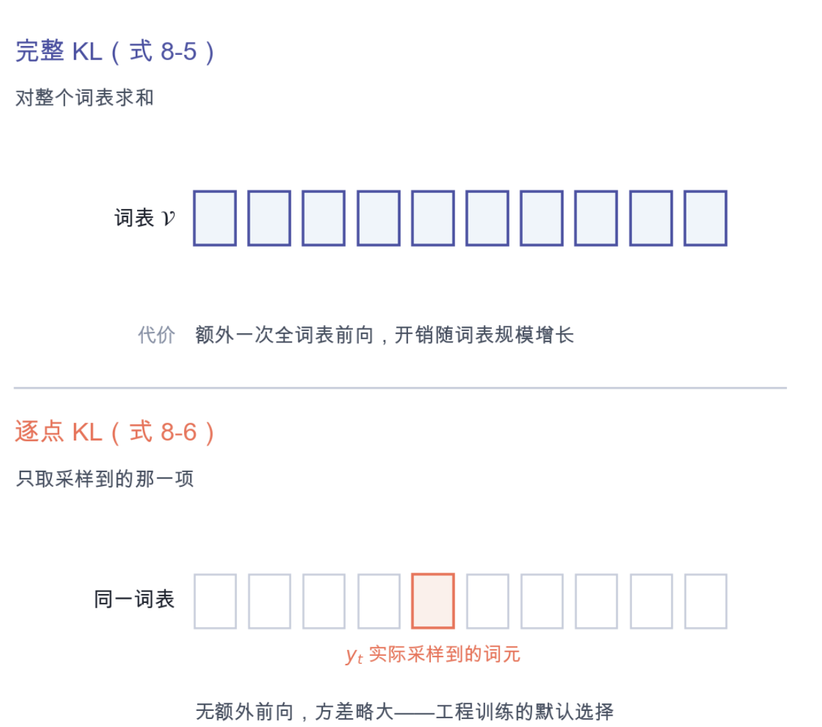
KL 项的计算

$$\mathrm{KL}_t = \sum_{y \in \mathcal{V}} \pi_{\mathrm{old}}\left(y \mid \boldsymbol{x}, \boldsymbol{y}_{<t}\right) \log \frac{\pi_{\mathrm{old}}\left(y \mid \boldsymbol{x}, \boldsymbol{y}_{<t}\right)}{\pi_{\mathrm{ref}}\left(y \mid \boldsymbol{x}, \boldsymbol{y}_{<t}\right)} \tag{8-5}$$

完整 KL：对词表 $\mathcal{V}$ 中每个词元求和，需要一次额外的全词表前向。

$$\mathrm{KL}_t \approx \log \frac{\pi_{\mathrm{old}}\left(y_t \mid \boldsymbol{x}, \boldsymbol{y}_{<t}\right)}{\pi_{\mathrm{ref}}\left(y_t \mid \boldsymbol{x}, \boldsymbol{y}_{<t}\right)} \tag{8-6}$$

逐点 KL 估计：只用实际采样到的 y_t 一项代替求和，节省计算资源，是实际训练中的常用做法。



两种 KL 计算方式：完整 KL 累加整个词表，逐点 KL 只取采样到的词元

式 (8-5) 是定义，式 (8-6) 是工程近似。近似会带来方差，但只需一次前向即可得到每个位置的 KL 值，因而被广泛采用。

依据 《大语言模型：训练、精调与对齐》第 8.3.5 节（式 (8-5)、(8-6)）

词元级奖励

$$R_t = \begin{cases} r - \beta \cdot \mathrm{KL}_t & t = T \\ -\beta \cdot \mathrm{KL}_t & t < T \end{cases} \tag{8-7}$$

T 是序列结束位置（生成 <EOS> 处），β 是 KL 惩罚系数。只有终止位置额外得到序列奖励 r。

- 这样既鼓励模型获得更高的奖励，又约束它不过分偏离原始参考模型。
- 为稳定训练，可对 KL 值做截断（clipping）以降低方差，也可自适应调整 β 以控制 KL 约束强度。

放入 $\mathcal{D}'$ 的四项

旧策略概率 $\pi_{\mathrm{old}}(y_t \mid \boldsymbol{x}, \boldsymbol{y}_{<t})$；旧价值 $V_{\mathrm{old},t}$；GAE 优势 $\hat{\boldsymbol{A}}^{\mathrm{GAE}}$；重塑奖励 $R_t \in \mathbb{R}$。

为什么要存起来

PPO 允许用同一批经验做多次更新，必须把生成时的策略概率与价值固定下来，才能在后续轮次计算重要性比率与优势。

新策略与新价值的计算

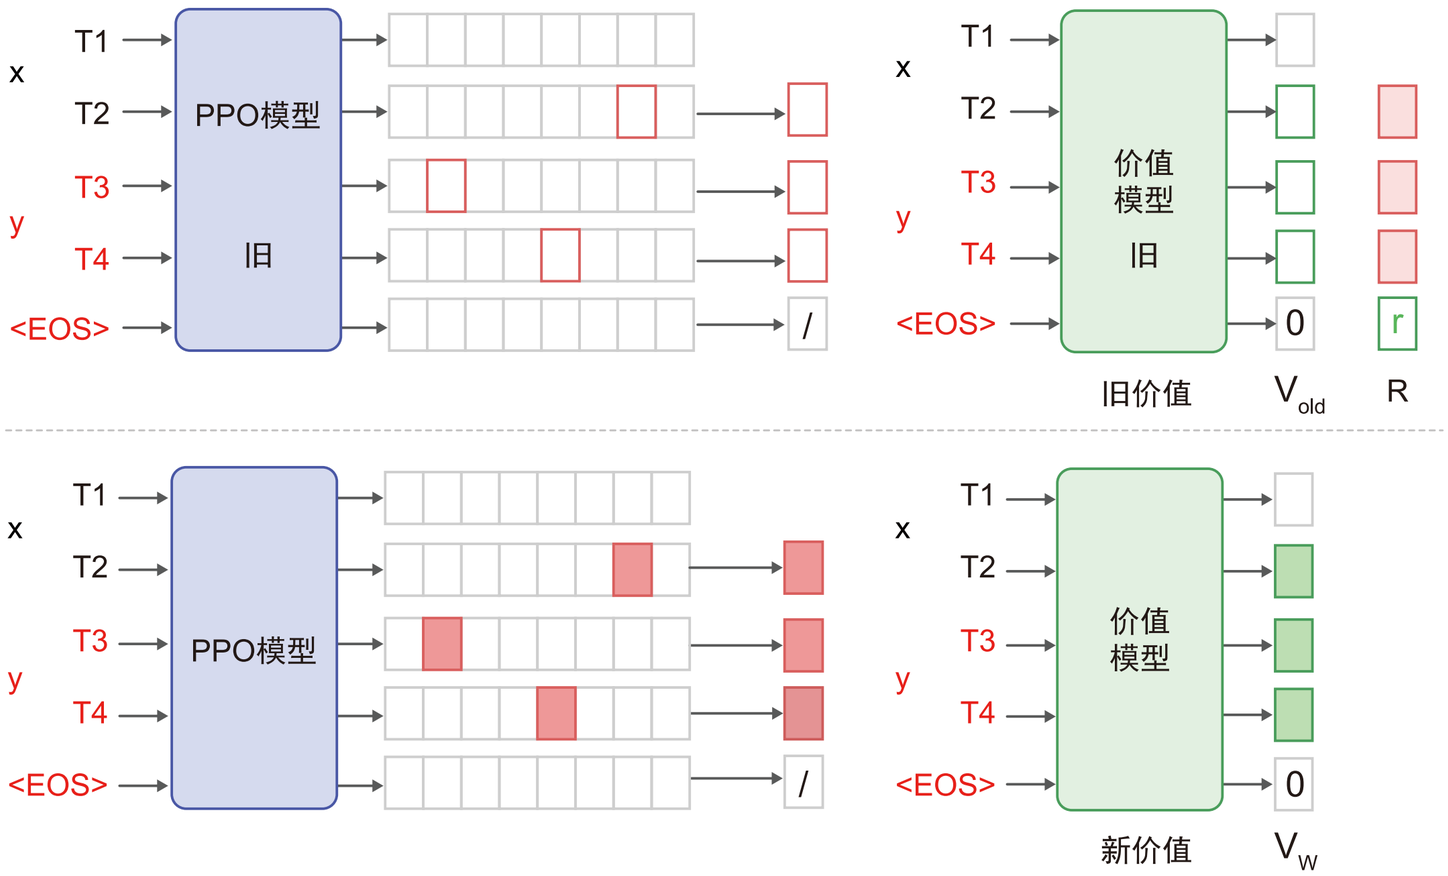


图 8.11　目标模型参数更新需要在线采样最新策略（价值模型同理）

- 从经验缓存 $\mathcal{D}'$ 取一个小批量，提取**新**策略与新价值。
- 更新后的 $\pi_{\boldsymbol{\theta}}$ 给出 $\pi_{\boldsymbol{\theta}}(y_t \mid \boldsymbol{x}, \boldsymbol{y}_{<t})$；更新后的 $V_{\boldsymbol{W}}$ 给出 $V_{\text{new},t}$。
- 新旧之差进入重要性比率与价值损失：这正是 PPO 能做多轮更新的原因。

图源 《大语言模型：训练、精调与对齐》图 8.11

三个损失项

PPO 的核心损失包含三部分：策略损失 $\mathcal{L}_{\text{policy}}$、价值损失 $\mathcal{L}_{\text{value}}$ 与可选的预训练损失 $\mathcal{L}_{\text{pretrain}}$。

$$\mathcal{L}(\boldsymbol{\theta}, \boldsymbol{W}) = \lambda_1 \mathcal{L}_{\text{policy}}(\boldsymbol{\theta}) + \lambda_2 \mathcal{L}_{\text{value}}(\boldsymbol{W}) + \lambda_3 \mathcal{L}_{\text{pretrain}}(\boldsymbol{\theta}) \tag{8-8}$$

超参数 $\lambda_1, \lambda_2, \lambda_3$ 平衡不同损失项的贡献，其中 $\mathcal{L}_{\text{pretrain}}(\boldsymbol{\theta})$ 可选。

策略网络 $\boldsymbol{\theta}$

只按策略损失更新

$$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} - \eta_{\boldsymbol{\theta}} \nabla_{\boldsymbol{\theta}} \mathcal{L}_{\text{policy}}(\boldsymbol{\theta})$$

参考策略 π_{ref} 冻结，不参与更新。

价值网络 $\boldsymbol{W}$

只按价值损失更新

$$\boldsymbol{W} \leftarrow \boldsymbol{W} - \eta_{\boldsymbol{W}} \nabla_{\boldsymbol{W}} \mathcal{L}_{\text{value}}(\boldsymbol{W})$$

价值模型只回归目标价值 $\hat{V}_t$，不直接决定策略。

工程实现 式 (8-8) 是教科书写法：各项乘权重后相加，再对 $\boldsymbol{\theta}$ 求一次梯度。实际训练框架里，策略与价值是**两个独立的优化器**，各按自己的损失与学习率更新各自网络——混在一个损失里相加会互相干扰，两套超参数也调不动。式 (8-9)、(8-10) 即这两条独立通道。

依据 《大语言模型：训练、精调与对齐》第 8.3.5 节（式 (8-8)）

策略损失

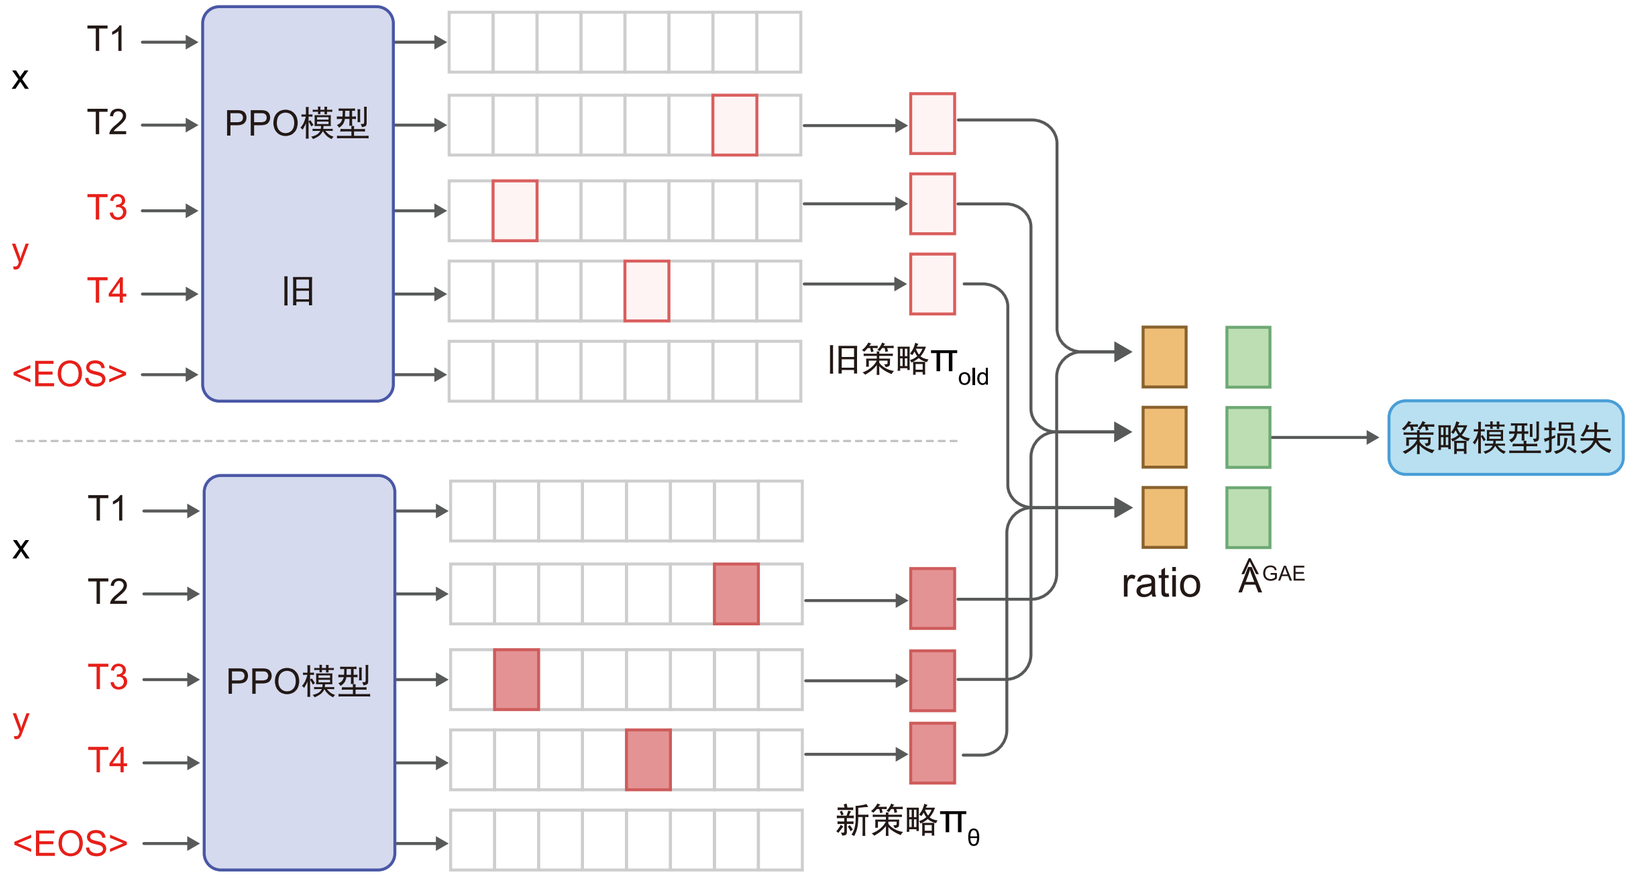


图 8.12　策略比率裁剪机制

$$r_t(\boldsymbol{\theta}) = \frac{\pi_{\boldsymbol{\theta}}(y_t \mid \boldsymbol{x}, \boldsymbol{y}_{<t})}{\pi_{\text{old}}(y_t \mid \boldsymbol{x}, \boldsymbol{y}_{<t})}$$

重要性采样比率：新旧策略在同一词元上的概率之比。

$$\mathcal{L}_{\text{policy}}(\boldsymbol{\theta}) = -\mathbb{E}_{\boldsymbol{y}\sim\pi_{\text{old}}(\cdot|\boldsymbol{x})}\left[\min\left(r_t(\boldsymbol{\theta})A_t^{\text{GAE}},\ \texttt{clip}\left(r_t(\boldsymbol{\theta}), 1-\epsilon, 1+\epsilon\right)A_t^{\text{GAE}}\right)\right] \tag{8-9}$$

ϵ 为裁剪阈值。两种机制确保稳定更新：$\min(\cdot)$ 选择较保守的更新方向；$\texttt{clip}(\cdot)$ 把比率限制在 $[1-\epsilon, 1+\epsilon]$ 内。

图源《大语言模型：训练、精调与对齐》图 8.12 与式 (8-9)

裁剪的三种情形

记 $A = A_t^{\mathrm{GAE}}$，比率 $r = r_t(\boldsymbol{\theta})$。min 与 `clip` 的组合，使“朝正确方向大幅改动”不再获得额外收益。

情形	比率范围	目标值	效果
$A > 0$，概率上升	$r \le 1+\epsilon$	rA	按比率线性获益
$A > 0$，上升过多	$r > 1+\epsilon$	$(1+\epsilon)A$	封顶，不再奖励更激进的更新
$A < 0$，概率下降过多	$r < 1-\epsilon$	$(1-\epsilon)A$	封底，避免过度惩罚

同轨与离轨　同一批经验只做一次策略更新，属于同轨策略优化；超过一次更新，则为离轨策略优化——此时 $\pi_{\boldsymbol{\theta}}$ 已偏离 π_{old}，比率与裁剪才真正发挥作用。

依据　《大语言模型：训练、精调与对齐》第 8.3.5 节（式 (8-9) 的两种机制）

价值损失

$$\mathcal{L}_{\text{value}}(\boldsymbol{W}) = \mathbb{E}_t\left[\left(V_{\boldsymbol{W}}(\boldsymbol{x}, \boldsymbol{y}_{<t}) - \hat{V}_t\right)^2\right] \tag{8-10}$$

价值模型只负责回归目标价值 $\hat{V}_t$：它不直接决定策略，但它提供的基线决定了优势估计的稳定性。

$$\hat{V}_t = \hat{A}_t^{\text{GAE}} + V_{\text{old},t}(\boldsymbol{x}, \boldsymbol{y}_{<t})$$

目标价值：由广义优势估计与旧价值相加得到，是把奖励沿时间步摊开后的回报估计。

$$\delta_t = R_t + \gamma V_{\text{old},t+1} - V_{\text{old},t}$$

TD 残差：R_t 为式 (8-7) 的重塑奖励，γ 为折扣因子，$V_{\text{old},t}$ 为旧价值模型在位置 t 的估计。

GAE 基于旧价值模型 V_{old} 计算：引入相邻时间步的价值估计，在保持较小偏差的同时显著降低方差。价值模型与策略模型是两个网络、两套参数，各按各自的损失更新。

依据 《大语言模型：训练、精调与对齐》第 8.3.5 节（式 (8-10)）

广义优势估计

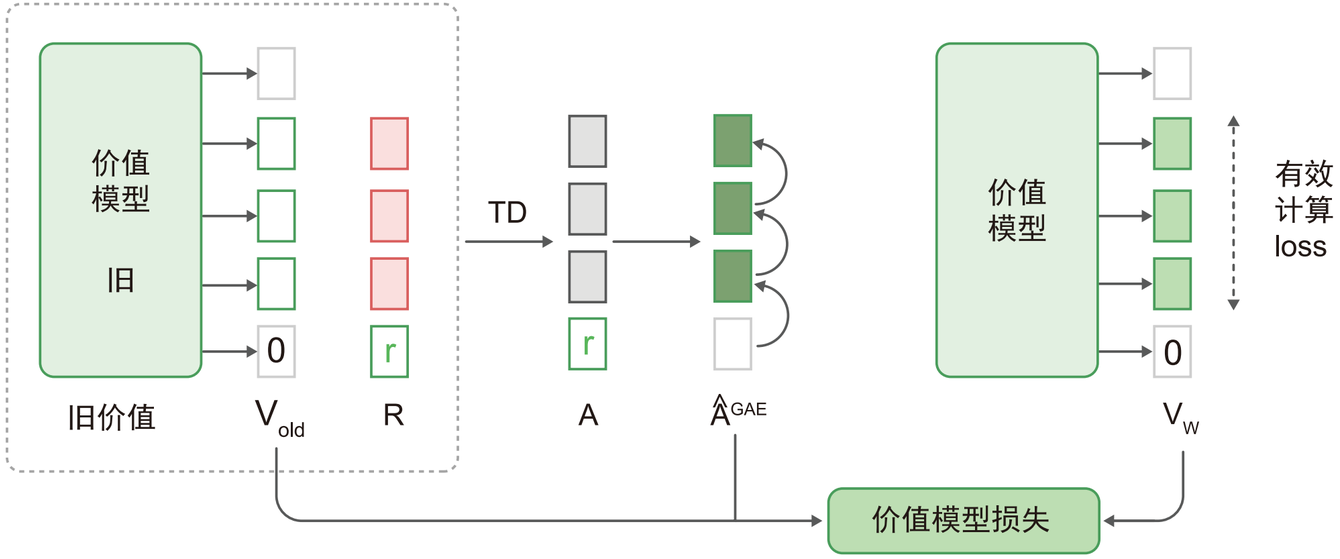


图 8.13　价值模型损失计算：由旧价值算 TD 残差与 GAE，再用价值模型回归目标价值

$$\hat{A}_t^{\mathrm{GAE}} = \sum_{l=0}^{T-t} (\gamma\lambda)^l \, \delta_{t+l}$$

λ 在偏差与方差之间折中：$\lambda = 0$ 退化为单步 TD 残差（偏差大、方差小），$\lambda = 1$ 接近蒙特卡洛回报（偏差小、方差大）。

$$\hat{A}_t^{\mathrm{GAE}} = \delta_t + \gamma\lambda \, \hat{A}_{t+1}^{\mathrm{GAE}}$$

递推形式：从序列末尾向前计算，每步复用下一步的优势估计，实现上只需一次反向遍历。

GAE 把序列级奖励沿时间步“摊”到每个词元上，这正是前面奖励重塑想要得到的词元级信号。

图源 《大语言模型：训练、精调与对齐》图 8.13；第 8.3.5 节（(8-7)、(8-10)）

RLHF 的训练复杂度

PPO 优化过程中需要同时加载四个模型：策略模型、价值模型、参考模型、奖励模型；其中前两个需要被优化。

4

同时加载的模型数量

2

需要更新的模型：策略与价值

1

串行瓶颈：策略的在线采样

- 策略模型进行在线采样（自回归生成回答）时，其他计算资源（如 GPU）可能存在利用率不足的情况。
- 优化的核心在于提高在线采样效率：可用独立的计算资源部署高效推理服务。
- 由于策略参数在训练中不断更新，PPO 完成一个优化步骤后，需要把更新后的参数同步到推理服务器。
- 推理阶段如何设计高效流水线以减少其他资源空闲时间，是提升大规模 PPO 训练效率的关键。

为此也出现了复杂度更低的替代算法：DPO 无需显式奖励模型（8.4 节）；ReMax、RLOO 与 GRPO 移除了价值模型，在降低复杂度的同时取得较好的对齐效果（8.5 节）。

奖励信号的问题

奖励模型判别的准确性直接决定优化质量。序列级奖励的取法（只取 <EOS> 位置分数）带来了奖励稀疏问题，还伴随两个关键挑战。

挑战 1

奖励欺骗（Reward Hacking）

策略模型可能探索到能欺骗奖励模型获得高分的异常输出模式，如乱码。若奖励模型未能识别这类语言模式并给予高分，模型就会朝生成无意义内容的方向更新，最终导致训练崩溃。

挑战 2

过度优化（Overoptimization）

策略可能过度适配当前奖励模型的偏好。例如奖励模型对所有拒绝式回答都给高分，策略最终可能对所有正常问题都拒绝式回答，丧失有用性。

策略优化的理论上限受限于奖励模型的质量上限。

根因 奖励是序列级、稀疏的：只有终点一个标量，模型缺少细粒度的过程信号，于是更容易在“如何拿到高分”上走捷径。

多轮 RLHF 与拒绝采样

多轮 RLHF

策略模型不断更新，生成的回答分布会偏离初始奖励模型的训练数据分布，加剧过度优化风险。

基于广义策略迭代，解决方案是分多轮：用当前策略生成数据 → 在新的偏好分布上重训奖励模型 → 用新奖励模型做下一轮策略优化。

Llama-2 采用了这种多轮训练范式，并在对齐流程中结合了拒绝采样。

拒绝采样

对单个输入采样多个回答，按某个评价指标（如奖励模型评分）选出最优回答（Best-of-N），即拒绝采样。

选出的最优回答可视为高质量样本，用于后续的有监督微调。

采样 N 个回答

同一提示

→

奖励模型打分

按分数排序

→

取最优

用于 SFT 或下一轮 RL

在 RLHF 流程中，拒绝采样常用于：为奖励模型训练生成对比数据；初始化或微调策略模型，为 PPO 提供更好的起点。它用奖励模型挑选样本，避免了复杂的在线强化学习过程。

SFT 与 RLHF 的对比

RLHF 的标准实现通常采用 PPO，核心是优化策略模型以最大化奖励模型给出的奖励；奖励模型则负责把人类偏好建模、量化为可优化的信号。

对比项	SFT	RLHF（PPO）
优化层级	词元级	序列级
目标	最大化下一词元的对数似然	最大化整句的期望奖励
信号来源	人类标注的示范数据	奖励模型在终止状态给出的分数
信号分配	逐位置直接监督	经 GAE 回溯分配到各词元

- PPO 的在线采样使其具备探索潜力：策略可能生成超出原始训练数据分布的高价值输出，本质上是基于奖励信号的定向搜索。
- PPO 优化步骤本身不直接使用人类标签，但高度依赖由人类偏好数据训练的奖励模型。
- 用 AI 模型生成偏好反馈的方法称为 RLAIF，可减少对人类标注的依赖。

> **分工** SFT 决定模型“会做什么”——它只能模仿示范数据里出现过的回答；RLHF 决定模型“做得好不好”——它在示范之外按奖励信号搜索更好的回答。两者不是替代关系：PPO 的策略与参考模型都从 SFT 模型出发。

思考题与实践题

1 说明预训练与后训练的分工。为什么说“SFT 让模型会照做，RLHF 让模型做得更好”？

2 写出 PPO 目标（式 8-2），解释 β 过大与过小时分别会发生什么。

3 $K = 5$ 个排序回答能构造多少偏好对？为何要在一批内放入同一提示的全部偏好对？

4 推理强化学习为何能激发思维链，却可能加重幻觉？R1 如何应对？

5 实践：做一次 GRPO 的 R1-Zero 式训练，观察训练过程中是否出现“顿悟时刻”——采样长度何时开始跳增、模型是否自发出现“假设／验证／重来”这类词句。

6 GRPO 中若某题的 G 个回答全部错误，优势估计会怎样？如何缓解？

7 实践：实现 PPO 的 4 个模型（策略、价值、参考、奖励）及各自对应的训练算法。

8 实践：实现 GRPO 算法——组采样、规则奖励、组内标准化优势与裁剪目标。

依据 《大语言模型：训练、精调与对齐》第 8 章