基于强化学习的大语言模型训练

第 8 章（下）

第 12 课时 本课时讲解 8.4–8.6

后训练与对齐 · RLHF · 直接偏好优化 · 推理强化学习

著者
邓杭　杨耀东

教材
《大语言模型：训练、精调与对齐》

出版
清华大学出版社



本章目录 第 12 课时

8.1 大语言模型后训练与对齐
指令微调、人类偏好对齐与推理强化学习 第 3 页

8.2 人工智能系统对齐定义
对齐的目标 RICE 与对齐循环 第 12 页

8.3 基于人类反馈的强化学习
RLHF 三步流程、PPO 实现细节与算法分析 第 23 页

8.4 直接偏好优化
从 Bradley-Terry 模型推导 DPO 损失 第 58 页

8.5 大语言模型推理强化学习
规则奖励、GRPO 与 DeepSeek-R1 的训练框架 第 78 页

8.6 小结
偏好对齐与推理强化学习的两条路线 第 100 页

本课时内容 8.4 直接偏好优化、8.5 大语言模型推理强化学习、8.6 小结（其余部分见第 11 课时）

8.4

直接偏好优化

绕过显式奖励模型与强化学习循环，直接用偏好数据微调策略——但推导必须一步步走完。

本节内容

8.4.1　偏好模型

8.4.2　DPO 问题定义

8.4.3　DPO 推导

8.4.4　DPO 分析

DPO 的提出动机

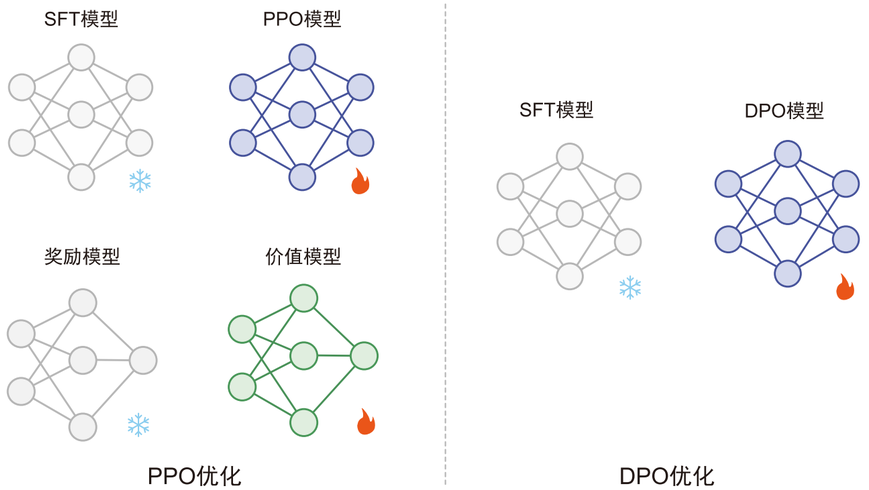


图 8.14　PPO 与 DPO 算法所需加载和训训练的模型数量对比

RLHF 训练范式行之有效，能提升模型的对齐程度和指令理解能力，但缺点在于训练流程繁琐、算法复杂、超参数多且计算开销大。

- DPO 把“构建奖励模型”和“进行 PPO”两个阶段整合为一步，直接利用偏好数据微调策略模型。
- 在使输出更符合人类偏好的同时，显著降低了训练复杂度与时间成本。
- 图中可见：PPO 需加载策略、价值、参考、奖励四个模型；DPO 只需策略与参考两个。

图源 《大语言模型：训练、精调与对齐》图 8.14

DPO 的推导路线

本节按四步推进：偏好模型 → 问题定义 → 推导 → 分析。每一步都为下一步准备一个等式。

8.4.1 偏好模型

BT 模型给出 $P(i > j) = \sigma(\beta_i - \beta_j)$

→

8.4.2 问题定义

用隐式奖励 r^* 表示偏好，写出带 KL 的目标

8.4.3 推导

解出最优策略 π^*，反解 r

→

8.4.4 分析

代回 BT 模型，得到可优化的损失

> **关键思想** 奖励不必显式训练：只要策略与参考策略的概率比确定，隐式奖励就确定了。DPO 正是把“奖励”消掉，只留下策略本身。

Bradley-Terry 模型

偏好模型通常用经典的 Bradley-Terry（BT）模型建模：它预测两个个体比较中一方胜出的概率，广泛用于成对比较数据，以估计和比较个体间的**相对**能力。

$$P(i > j) = \frac{p_i}{p_i + p_j} \tag{8-11}$$

$$= \frac{e^{\beta_i}}{e^{\beta_i} + e^{\beta_j}} \tag{8-12}$$

$$= \frac{1}{1 + e^{-(\beta_i - \beta_j)}} \tag{8-13}$$

$$= \sigma(\beta_i - \beta_j) \tag{8-14}$$

其中 $p_i = e^{\beta_i} > 0$ 是个体 i 的正实数能力分数，β_i 是其对数尺度能力分数；$\sigma(x) = \frac{1}{1+e^{-x}}$。

式 (8-11) 到 (8-14) 是同一式的逐步变形：先写成能力分数之比，再代入 $p_i = e^{\beta_i}$，分子分母同除以 e^{β_i}，最后写成 sigmoid。σ 把对数能力差 $\beta_i - \beta_j$ 映射为 $P(i > j) \in [0, 1]$。

依据 《大语言模型：训练、精调与对齐》第 8.4.1 节（式 (8-11)–(8-14)）

极大似然估计

$$\boldsymbol{\beta} = \arg\max_{\boldsymbol{\beta}} \prod_{(i,j)\in\mathcal{D}} P(i > j) \qquad \text{最大似然估计} \tag{8-15}$$

$$\boldsymbol{\beta} = \arg\min_{\boldsymbol{\beta}} -\frac{1}{|\mathcal{D}|} \sum_{(i,j)\in\mathcal{D}} \log \sigma(\beta_i - \beta_j) \qquad \text{负对数似然} \tag{8-16}$$

给定成对比较样本 (i, j) 构成的偏好数据集 $\mathcal{D}$，通过极大似然估计求解能力参数 $\boldsymbol{\beta}$。

- 取对数把连乘变成求和，取负号把“最大化似然”变成“最小化损失”；除以 $|\mathcal{D}|$ 得到平均损失。
- 式 (8-16) 在形式上等同于二元交叉熵损失。
- BT 模型学的是相对差异 $\beta_i - \beta_j$，而非绝对地增大某个 β_i 或减小某个 β_j。

依据 《大语言模型：训练、精调与对齐》第 8.4.1 节（式 (8-15)、(8-16)）

损失函数的形状

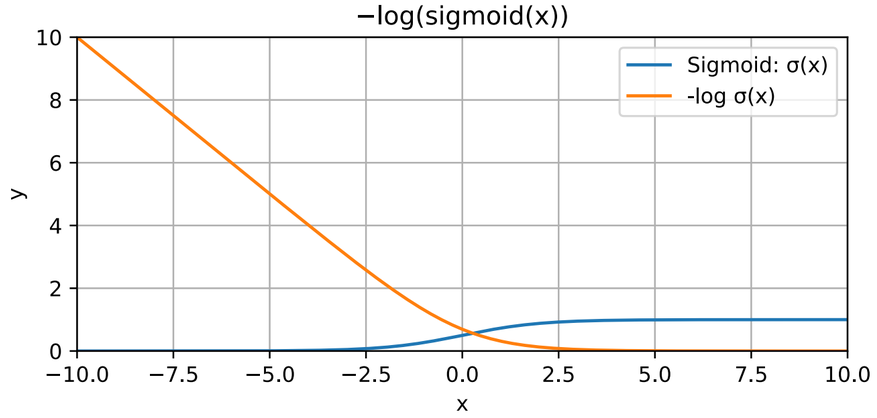


图 8.15　损失函数 $-\log\sigma(x)$ 的图像

- 损失值随 $\beta_i - \beta_j$ 的增大而减小。
- 当个体 i 确实优于 j 时，模型期望它们的分数差足够大，从而使损失变小。
- 差值为 0 时损失为 $\log 2 \approx 0.693$，是“分不出高下”的基准线。
- 差值很负时损失线性增长，说明排序错误会受到持续惩罚。

图源 《大语言模型：训练、精调与对齐》图 8.15

BT 模型在回答上的应用

给定输入 $\boldsymbol{x}$ 及两个响应 $\boldsymbol{y}_1, \boldsymbol{y}_2$，人类偏好标注为 $\boldsymbol{y}_1 \succ \boldsymbol{y}_2$。奖励模型要学一个隐式奖励 $r^*(\boldsymbol{x}, \boldsymbol{y})$，再通过 BT 模型把偏好分布 p^* 建模出来。

$$p^*(\boldsymbol{y}_1 \succ \boldsymbol{y}_2 \mid \boldsymbol{x}) = \frac{\exp\left(r^*(\boldsymbol{x}, \boldsymbol{y}_1)\right)}{\exp\left(r^*(\boldsymbol{x}, \boldsymbol{y}_1)\right) + \exp\left(r^*(\boldsymbol{x}, \boldsymbol{y}_2)\right)} \tag{8-17}$$

与式 (8-11) 完全同构：把“个体能力 β_i”换成“回答的隐式奖励 $r^*(\boldsymbol{x}, \boldsymbol{y}_i)$”。分子分母同除以分子，还可写成 $p^* = \sigma\left(r^*(\boldsymbol{x}, \boldsymbol{y}_1) - r^*(\boldsymbol{x}, \boldsymbol{y}_2)\right)$，即两回答奖励差的 sigmoid。

$$\mathcal{L}_R(\phi) = -\mathbb{E}_{(\boldsymbol{x}, \boldsymbol{y}_w, \boldsymbol{y}_l) \sim \mathcal{D}} \left[\log \sigma\left(r_\phi(\boldsymbol{x}, \boldsymbol{y}_w) - r_\phi(\boldsymbol{x}, \boldsymbol{y}_l)\right)\right] \tag{8-18}$$

偏好数据集 $\mathcal{D} = \{(\boldsymbol{x}^{(i)}, \boldsymbol{y}_w^{(i)}, \boldsymbol{y}_l^{(i)})\}_{i=1}^N$，$\boldsymbol{y}_w$ 为偏好响应，$\boldsymbol{y}_l$ 为非偏好响应；奖励模型参数 ϕ 通过最小化负对数似然估计。

依据 《大语言模型：训练、精调与对齐》第 8.4.2 节（式 (8-19)、(8-20)）

带 KL 惩罚的优化目标

$$\max_{\pi_{\boldsymbol{\theta}}} \mathbb{E}_{\boldsymbol{x}\sim\mathcal{D},\, \boldsymbol{y}\sim\pi_{\boldsymbol{\theta}}(\boldsymbol{y}|\boldsymbol{x})}\left[r_{\phi}(\boldsymbol{x},\boldsymbol{y})\right] - \beta\mathbb{D}_{\mathrm{KL}}\left[\pi_{\boldsymbol{\theta}}(\boldsymbol{y}\mid\boldsymbol{x})\,\|\,\pi_{\mathrm{ref}}(\boldsymbol{y}\mid\boldsymbol{x})\right] \tag{8-19}$$

$\pi_{\boldsymbol{\theta}}$ 为待优化策略，π_{ref} 为参考策略（通常为 SFT 模型）。目标是在最大化期望奖励的同时，约束优化策略与参考策略的偏离程度。

$$r(\boldsymbol{x},\boldsymbol{y}) = r_{\phi}(\boldsymbol{x},\boldsymbol{y}) - \beta\left(\log\pi_{\boldsymbol{\theta}}(\boldsymbol{y}\mid\boldsymbol{x}) - \log\pi_{\mathrm{ref}}(\boldsymbol{y}\mid\boldsymbol{x})\right) \tag{8-20}$$

为推导 DPO，先把 KL 惩罚吸收进奖励，定义“重构奖励” $r(\boldsymbol{x},\boldsymbol{y})$：奖励高、但偏离参考策略的回答，也会被扣分。

式 (8-19) 与 8.3 节式 (8-2) 是同一个目标的两种写法：一个把 KL 显式写在期望外，一个把它并入奖励项。DPO 的推导从这里出发。

依据 《大语言模型：训练、精调与对齐》第 8.4.2 节（式 (8-19)、(8-20)）

DPO 推导（一） 展开 KL 与引入配分函数

$$
\begin{aligned}
&\max_{\pi}\ \mathbb{E}_{\boldsymbol{x}\sim\mathcal{D},\,\boldsymbol{y}\sim\pi}\left[r(\boldsymbol{x},\boldsymbol{y})\right]-\beta\mathbb{D}_{\mathrm{KL}}\left[\pi(\boldsymbol{y}|\boldsymbol{x})\,\|\,\pi_{\mathrm{ref}}(\boldsymbol{y}|\boldsymbol{x})\right]\\
&=\max_{\pi}\ \mathbb{E}_{\boldsymbol{x}\sim\mathcal{D}}\mathbb{E}_{\boldsymbol{y}\sim\pi(\boldsymbol{y}|\boldsymbol{x})}\left[r(\boldsymbol{x},\boldsymbol{y})-\beta\log\frac{\pi(\boldsymbol{y}|\boldsymbol{x})}{\pi_{\mathrm{ref}}(\boldsymbol{y}|\boldsymbol{x})}\right]\\
&=\min_{\pi}\ \mathbb{E}_{\boldsymbol{x}\sim\mathcal{D}}\mathbb{E}_{\boldsymbol{y}\sim\pi(\boldsymbol{y}|\boldsymbol{x})}\left[\log\frac{\pi(\boldsymbol{y}|\boldsymbol{x})}{\pi_{\mathrm{ref}}(\boldsymbol{y}|\boldsymbol{x})}-\frac{1}{\beta}r(\boldsymbol{x},\boldsymbol{y})\right]
\end{aligned}
\tag{8-21}
$$

把 KL 的定义展开为对数比的期望；再把“最大化”改写成“最小化负值”，并除以 β。这一步没有引入任何近似：式 (8-21) 与式 (8-19) 完全等价。

$$
\begin{aligned}
&=\min_{\pi}\ \mathbb{E}_{\boldsymbol{x}\sim\mathcal{D}}\mathbb{E}_{\boldsymbol{y}\sim\pi(\boldsymbol{y}|\boldsymbol{x})}\left[\log\frac{\pi(\boldsymbol{y}|\boldsymbol{x})}{\pi_{\mathrm{ref}}(\boldsymbol{y}|\boldsymbol{x})}-\log\frac{\exp\left(\frac{1}{\beta}r(\boldsymbol{x},\boldsymbol{y})\right)}{Z(\boldsymbol{x})}\right.\\
&\qquad\left.-\log Z(\boldsymbol{x})\right]
\end{aligned}
\tag{8-22}
$$

把 $Z(\boldsymbol{x})$ 拆出来：$\log\frac{\pi}{\pi_{\mathrm{ref}}}-\log e^{\frac{1}{\beta}r}+\log Z(\boldsymbol{x})-\log Z(\boldsymbol{x})$。前后两个 $\log Z(\boldsymbol{x})$ 相消，只剩一条与 π 无关的常数项。

$$
Z(\boldsymbol{x})=\sum_{y}\pi_{\mathrm{ref}}(\boldsymbol{y}|\boldsymbol{x})\exp\left(\frac{1}{\beta}r(\boldsymbol{x},\boldsymbol{y})\right)
$$

配分函数只依赖于 $\boldsymbol{x}$ 与 π_{ref}，与待优化策略 π 无关——这是整个推导能成立的关键。

两步合看 左栏把 KL 还原成逐样本的对数比，右栏把这个对数比整理成“π 与某个新分布的 KL 加上一个与 π 无关的常数”。下一步就是指出那个新分布正是最优解。

依据 《大语言模型：训练、精调与对齐》第 8.4.3 节（式 (8-21)、(8-22)）

DPO 推导（二） 最优策略

$$\pi^*(\boldsymbol{y}|\boldsymbol{x}) = \frac{1}{Z(\boldsymbol{x})}\pi_{\text{ref}}(\boldsymbol{y}|\boldsymbol{x})\exp\left(\frac{1}{\beta}r(\boldsymbol{x},\boldsymbol{y})\right) \tag{8-23}$$

π^* 是有效概率分布：$\pi^*(\boldsymbol{y}|\boldsymbol{x}) \geqslant 0$，且由 $Z(\boldsymbol{x})$ 的定义满足 $\sum_y \pi^*(\boldsymbol{y}|\boldsymbol{x}) = 1$。

$$\min_{\pi}\ \mathbb{E}_{\boldsymbol{x}\sim\mathcal{D}}\left[\mathbb{E}_{\boldsymbol{y}\sim\pi(\boldsymbol{y}|\boldsymbol{x})}\left[\log\frac{\pi(\boldsymbol{y}|\boldsymbol{x})}{\pi^*(\boldsymbol{y}|\boldsymbol{x})}\right] - \log Z(\boldsymbol{x})\right] \tag{8-24}$$

$$= \min_{\pi}\ \mathbb{E}_{\boldsymbol{x}\sim\mathcal{D}}\left[\mathbb{D}_{\text{KL}}\left(\pi(\boldsymbol{y}|\boldsymbol{x})\,\|\,\pi^*(\boldsymbol{y}|\boldsymbol{x})\right) - \log Z(\boldsymbol{x})\right] \tag{8-25}$$

由于 $-\log Z(\boldsymbol{x})$ 与 π 无关，目标等价于最小化 KL 散度项；当且仅当 $\pi = \pi^*$ 时 KL 达到最小值零。

$$\pi(\boldsymbol{y}|\boldsymbol{x}) = \pi^*(\boldsymbol{y}|\boldsymbol{x}) = \frac{1}{Z(\boldsymbol{x})}\pi_{\text{ref}}(\boldsymbol{y}|\boldsymbol{x})\exp\left(\frac{1}{\beta}r(\boldsymbol{x},\boldsymbol{y})\right) \tag{8-26}$$

这就是带 KL 约束的奖励最大化问题的最优解：一个“参考策略按奖励指数加权”的分布。

依据 《大语言模型：训练、精调与对齐》第 8.4.3 节（式 (8-23)–(8-26)）

DPO 推导（三） 反解奖励与代回 BT 模型

$$r(\boldsymbol{x},\boldsymbol{y}) = \beta \log \frac{\pi^*(\boldsymbol{y} \mid \boldsymbol{x})}{\pi_{\text{ref}}(\boldsymbol{y} \mid \boldsymbol{x})} + \beta \log Z(\boldsymbol{x}) \tag{8-27}$$

把最优策略 π^* 代回重构奖励式 (8-20)：$\log \pi^* = \log \pi_{\text{ref}} + \frac{1}{\beta} r - \log Z$，移项后乘以 β。

$$p^*(\boldsymbol{y}_1 \succ \boldsymbol{y}_2 \mid \boldsymbol{x}) = \frac{\exp\left(r^*(\boldsymbol{x},\boldsymbol{y}_1)\right)}{\exp\left(r^*(\boldsymbol{x},\boldsymbol{y}_1)\right) + \exp\left(r^*(\boldsymbol{x},\boldsymbol{y}_2)\right)} \tag{8-28}$$

$$= \frac{1}{1 + \exp\left(r^*(\boldsymbol{x},\boldsymbol{y}_2) - r^*(\boldsymbol{x},\boldsymbol{y}_1)\right)} \tag{8-29}$$

式 (8-27)→(8-29)：分子分母同除以分子，把 BT 商式化成 sigmoid 的分母形式。

$$= \frac{1}{1 + \exp\left(\beta \log \frac{\pi^*(\boldsymbol{y}_2|\boldsymbol{x})}{\pi_{\text{ref}}(\boldsymbol{y}_2|\boldsymbol{x})} + \beta \log Z(\boldsymbol{x}) - \beta \log \frac{\pi^*(\boldsymbol{y}_1|\boldsymbol{x})}{\pi_{\text{ref}}(\boldsymbol{y}_1|\boldsymbol{x})} - \beta \log Z(\boldsymbol{x})\right)} \tag{8-30}$$

把式 (8-27) 的 r^* 逐项代入式 (8-29)：两次代入各带一个 $\beta \log Z(\boldsymbol{x})$，此处显式写出，下一式再约去。

$$= \frac{1}{1 + \exp\left(\beta \log \frac{\pi^*(\boldsymbol{y}_2|\boldsymbol{x})}{\pi_{\text{ref}}(\boldsymbol{y}_2|\boldsymbol{x})} - \beta \log \frac{\pi^*(\boldsymbol{y}_1|\boldsymbol{x})}{\pi_{\text{ref}}(\boldsymbol{y}_1|\boldsymbol{x})}\right)} \tag{8-31}$$

$$= \sigma\left(\beta \log \frac{\pi^*(\boldsymbol{y}_1 \mid \boldsymbol{x})}{\pi_{\text{ref}}(\boldsymbol{y}_1 \mid \boldsymbol{x})} - \beta \log \frac{\pi^*(\boldsymbol{y}_2 \mid \boldsymbol{x})}{\pi_{\text{ref}}(\boldsymbol{y}_2 \mid \boldsymbol{x})}\right) \tag{8-32}$$

约去 $\beta \log Z(\boldsymbol{x})$ 得 (8-31)；再把 $\frac{1}{1+e^{-x}}$ 写成 $\sigma(x)$（x 取括号内分差的相反数）即得 (8-32)。

关键一步 常数 $\beta \log Z(\boldsymbol{x})$ 与 $\boldsymbol{y}$ 无关，而 BT 模型比较的是同一 $\boldsymbol{x}$ 下两个回答的奖励**之差**——两次代入的 $Z(\boldsymbol{x})$ 恰好相互抵消。DPO 能绕过奖励模型，靠的就是这一点。至此奖励模型被完全消去。

依据 《大语言模型：训练、精调与对齐》第 8.4.3 节（式 (8-27)–(8-32)）

DPO 损失函数

把偏好概率的优化目标转化为最小化负对数似然，就得到 DPO 的损失函数。

$$\mathcal{L}_{\mathrm{DPO}}(\boldsymbol{\theta}) = -\mathbb{E}_{(\boldsymbol{x},\boldsymbol{y}_w,\boldsymbol{y}_l)\sim\mathcal{D}}\left[\log\sigma\left(\underbrace{\beta\log\frac{\pi_{\boldsymbol{\theta}}(\boldsymbol{y}_w\mid\boldsymbol{x})}{\pi_{\mathrm{ref}}(\boldsymbol{y}_w\mid\boldsymbol{x})}}_{\hat{r}_{\boldsymbol{\theta}}(\boldsymbol{x},\boldsymbol{y}_w)} - \underbrace{\beta\log\frac{\pi_{\boldsymbol{\theta}}(\boldsymbol{y}_l\mid\boldsymbol{x})}{\pi_{\mathrm{ref}}(\boldsymbol{y}_l\mid\boldsymbol{x})}}_{\hat{r}_{\boldsymbol{\theta}}(\boldsymbol{x},\boldsymbol{y}_l)}\right)\right] \tag{8-33}$$

$\pi_{\boldsymbol{\theta}}$ 为待优化的参数化策略。该损失本质上是最大化优选响应 $\boldsymbol{y}_w$ 与劣选响应 $\boldsymbol{y}_l$ 的隐式奖励差异。

$$\hat{r}_{\boldsymbol{\theta}}(\boldsymbol{x},\boldsymbol{y}) = \beta\log\frac{\pi_{\boldsymbol{\theta}}(\boldsymbol{y}\mid\boldsymbol{x})}{\pi_{\mathrm{ref}}(\boldsymbol{y}\mid\boldsymbol{x})}$$

括号内的两项正是隐式奖励 $\hat{r}_{\boldsymbol{\theta}}$：DPO 从不训练奖励模型，却等价于在用 BT 模型做奖励建模。

算法 14　语言模型 DPO 算法

算法 14 语言模型 DPO 算法

输入： 初始化策略模型 $\pi_{\boldsymbol{\theta}}$（由 π_{SFT} 初始化）；参考模型 π_{ref}（固定，通常为 π_{SFT}）；偏好数据集 $\mathcal{D} = \{(\boldsymbol{y}, \boldsymbol{y}_w, \boldsymbol{y}_l)\}$；超参数：KL 约束系数 β

输出： 优化后的策略模型 $\pi_{\boldsymbol{\theta}}^*$

for iteration $= 1, \ldots, \mathrm{I}$ **do**
  for 从 $\mathcal{D}$ 采样小批量 $\mathcal{D} = \{(\boldsymbol{y}^{(i)}, \boldsymbol{y}_w^{(i)}, \boldsymbol{y}_l^{(i)})\}_{i=1}^{N}$ **do**
    for 每个样本 $(\boldsymbol{y}, \boldsymbol{y}_w, \boldsymbol{y}_l) \in \mathcal{B}$ **do**
      计算选择响应概率：$\pi_{\boldsymbol{\theta}}(\boldsymbol{y}_w|\boldsymbol{y})$
      计算拒绝响应概率：$\pi_{\boldsymbol{\theta}}(\boldsymbol{y}_l|\boldsymbol{y})$
      计算参考模型概率：$\pi_{\text{ref}}(\boldsymbol{y}_w|\boldsymbol{y})$ 和 $\pi_{\text{ref}}(\boldsymbol{y}_l|\boldsymbol{y})$
      $r_w^{(i)} = \beta \log \frac{\pi_{\boldsymbol{\theta}}(\boldsymbol{y}_w|\boldsymbol{y})}{\pi_{\text{ref}}(\boldsymbol{y}_w|\boldsymbol{y})}$，$r_l^{(i)} = \beta \log \frac{\pi_{\boldsymbol{\theta}}(\boldsymbol{y}_l|\boldsymbol{y})}{\pi_{\text{ref}}(\boldsymbol{y}_l|\boldsymbol{y})}$
    end for
    计算 DPO 损失：$\mathcal{L}_{\text{DPO}}(\boldsymbol{\theta}) = -\frac{1}{N}\sum_{i=1}^{N} \log \sigma\left(r_w^{(i)} - r_l^{(i)}\right)$
    更新策略：$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \nabla\boldsymbol{\theta}$　▷ $\nabla\boldsymbol{\theta}$ 参数更新量
  end for
end for

算法 14　语言模型 DPO 算法

整个循环里没有奖励模型、没有采样、没有价值模型：每步只需四次前向（策略与参考模型各两次），再对 $\boldsymbol{\theta}$ 反传。

DPO 的局限

局限 1

点态奖励假设

DPO 依赖将成对偏好转换为点态奖励的假设。当偏好数据有限，或偏好标签确定性极高（概率接近 1）时，可能导致过拟合。

局限 2

损失下降 ≠ 方向正确

当最优策略（偏好响应）的概率趋近于零时，即使模型并未向优化偏好策略的方向更新，损失值也可能急剧下降。

局限 3

目标内生于训练分布

DPO 的优化目标内生于训练数据分布；PPO 则依赖显式奖励模型，该模型在策略可能生成的分布外数据上评估，因此要求奖励模型具有一定的分布外鲁棒性。

代价转移 DPO 省掉了奖励模型，也省掉了奖励模型作为“分布外裁判”的作用；PPO 保住了裁判，却要承担奖励欺骗的风险。

依据 《大语言模型：训练、精调与对齐》第 8.4.4 节

离线 DPO 与迭代 DPO

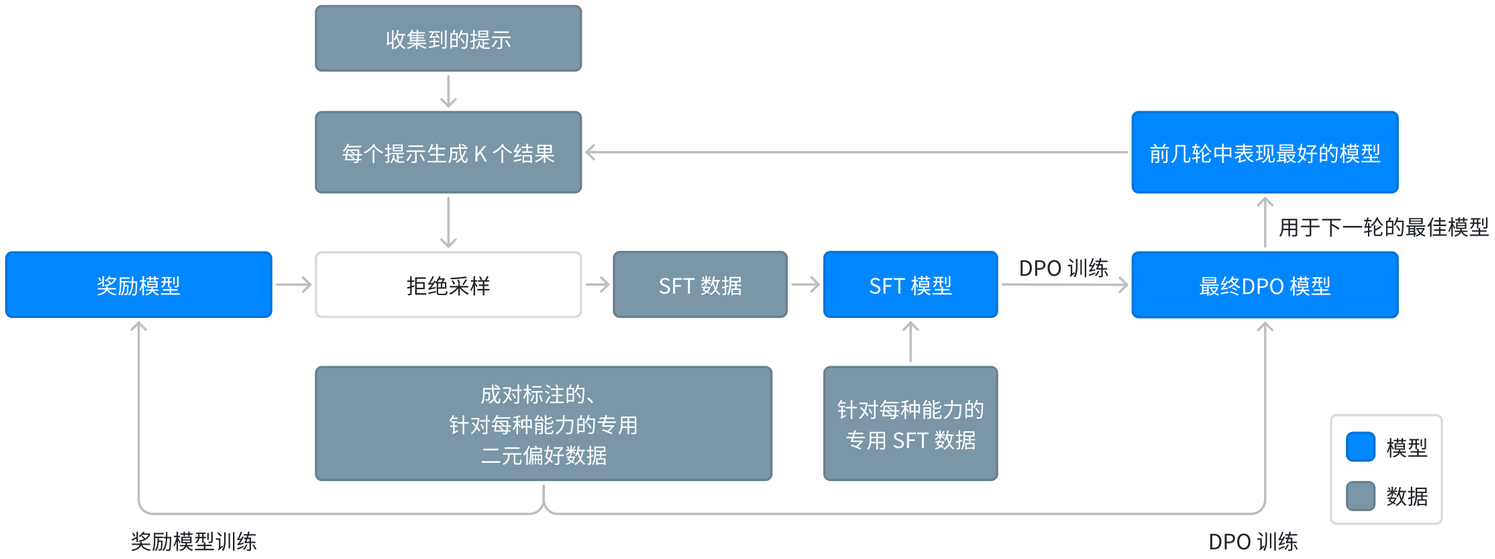


图 8.16　Llama-3 模型偏好对齐流程（采用迭代 DPO 算法）

标准 DPO：离线

使用离线收集的偏好数据做离线策略优化，不与环境交互。优点是流程简单、成本低；代价是数据分布固定。

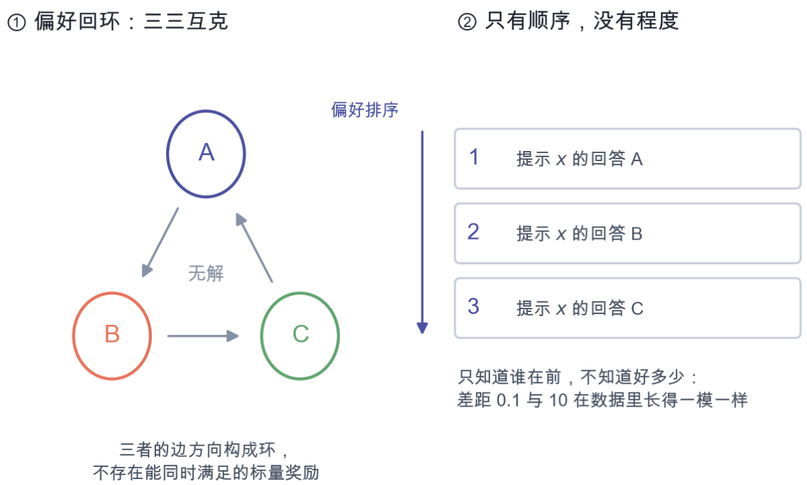
PPO：在线

通过与当前策略交互在线采样。结合在线数据收集机制（如迭代更新偏好数据）的 DPO 变体，表现优于标准（离线）DPO。

Llama-3 采用迭代 DPO 做偏好对齐：每轮用当前模型产出新的偏好数据，再训练下一轮。另有实验表明，在代码任务上 PPO 全面优于 DPO——两者并非普适的替代关系。

图源 《大语言模型：训练、精调与对齐》图 8.16；第 8.4.4 节

BT 偏好建模的问题



BT 建模的两个前提并不总成立：偏好关系可能出现回环，且成对比较只给出顺序、不给出程度

偏好回环

$A \succ B,\ B \succ C,\ C \succ A$ 一组偏好数据（数据量 $\geqslant 3$）的关系可能存在回环，导致梯度更新方向冲突，难以收敛。

标注一致性

噪声数据 标注员对偏好的标注会存在不一致性，噪声数据使模型难以捕捉真实偏好，策略优化方向偏离预期。

奖励量纲

只有顺序，没有程度 偏好数据只体现相对好坏的绝对关系，而没有更具体的量纲衡量偏好的程度。

出路之一是非成对学习：**KTO** 算法无需成对的偏好数据，只需标注各样本的优劣标签。

依据 《大语言模型：训练、精调与对齐》第 8.4.4 节

DPO 的梯度方向

$$\nabla_{\boldsymbol{\theta}} \mathcal{L}_{\mathrm{DPO}}(\boldsymbol{\theta}) = -\beta \mathbb{E}_{(\boldsymbol{x}, \boldsymbol{y}_w, \boldsymbol{y}_l) \sim \mathcal{D}} \Big[\sigma\left(\hat{r}_{\boldsymbol{\theta}}(\boldsymbol{x}, \boldsymbol{y}_l) - \hat{r}_{\boldsymbol{\theta}}(\boldsymbol{x}, \boldsymbol{y}_w)\right) \cdot \left[\nabla_{\boldsymbol{\theta}} \log \pi(\boldsymbol{y}_w \mid \boldsymbol{x}) - \nabla_{\boldsymbol{\theta}} \log \pi(\boldsymbol{y}_l \mid \boldsymbol{x})\right] \Big]$$

对式 (8-33) 求导。其中 $\hat{r}_{\boldsymbol{\theta}}(\boldsymbol{x}, \boldsymbol{y}) = \beta \log \frac{\pi_{\boldsymbol{\theta}}(\boldsymbol{y}|\boldsymbol{x})}{\pi_{\mathrm{ref}}(\boldsymbol{y}|\boldsymbol{x})}$ 是由策略与参考模型隐式定义的奖励。

权重项

$\sigma\left(\hat{r}_{\boldsymbol{\theta}}(\boldsymbol{x}, \boldsymbol{y}_l) - \hat{r}_{\boldsymbol{\theta}}(\boldsymbol{x}, \boldsymbol{y}_w)\right)$：当奖励估计错误（劣选反而得分高）时，权重更大。

方向项

$\nabla_{\boldsymbol{\theta}} \log \pi(\boldsymbol{y}_w \mid \boldsymbol{x}) - \nabla_{\boldsymbol{\theta}} \log \pi(\boldsymbol{y}_l \mid \boldsymbol{x})$：增加 $\boldsymbol{y}_w$ 的似然，降低 $\boldsymbol{y}_l$ 的似然。

有研究指出：同样的策略概率下，$\boldsymbol{y}_l$ 样本的梯度比例较 $\boldsymbol{y}_w$ 更大，使优化偏向降低 $\boldsymbol{y}_l$ 的策略；也有研究分析了优化过程中 $\boldsymbol{y}_w$ 概率反而下降的成因并给出解决方法。

依据 《大语言模型：训练、精调与对齐》第 8.4.4 节（DPO 梯度）

r_w 下降的原因

DPO 直接利用成对偏好数据，通过最大化 BT 模型的似然来优化策略，在 BT 模型下具备理论最优性，但容易过拟合导致泛化性差。

$$r_w = \beta \log \frac{\pi_{\boldsymbol{\theta}}(\boldsymbol{y}_w \mid \boldsymbol{x}_w)}{\pi_{\text{ref}}(\boldsymbol{y}_w \mid \boldsymbol{x}_w)}, \qquad r_l = \beta \log \frac{\pi_{\boldsymbol{\theta}}(\boldsymbol{y}_l \mid \boldsymbol{x}_l)}{\pi_{\text{ref}}(\boldsymbol{y}_l \mid \boldsymbol{x}_l)}$$

在 BT 偏好建模形式下，优化过程中会出现 r_w 与 r_l 同时下降的情况。

- 这会导致训练过程策略远离偏优策略 $\boldsymbol{y}_w$：DPO 保证的是 $r_w - r_l$ 整体最大化，而非对单体数据做特定方向的优化。
- 与监督微调只拟合正样本不同，DPO 有相对的负反馈信号参与训练——这是它的优势，也是上述现象的来源。

结论 “损失在降”不等于“$\boldsymbol{y}_w$ 的概率在升”。看 DPO 的训练曲线时，应同时观察 r_w 与 $r_w - r_l$ 两条量。

偏好优化算法的变种

在 DPO 的基础上，一批变种方法各自修补它的一处薄弱环节：补回 SFT 项、换掉 sigmoid 正则、改长度归一化、放宽成对数据的要求。

RRHF

长度归一化对数似然，并包含对 $\boldsymbol{y}_w$ 的 SFT 目标。

SLiC-HF

基于对数似然，同样包含 $\boldsymbol{y}_w$ 的 SFT 目标。

IPO

引入正则化项，解决 DPO 的过拟合问题。

CPO

使用序列似然作为奖励，结合 SFT 目标。

KTO

支持非成对偏好数据的学习。

ORPO

联合优化 SFT 与偏好目标，可从预训练模型开始训练。

R-DPO

显式建模长度偏差。

SimPO

基于长度归一化的偏好优化。

共同走向：补 SFT 项、换正则、改归一化、放宽数据形式。各方法的目标函数对比见表 8.3。

表 8.3　偏好优化算法变种比较

方法	优化目标
RRHF	$\max\left(0, -\frac{1}{\lvert\boldsymbol{y}_w\rvert}\log\pi_{\boldsymbol{\theta}}(\boldsymbol{y}_w\lvert\boldsymbol{x}) + \frac{1}{\lvert\boldsymbol{y}_l\rvert}\log\pi_{\boldsymbol{\theta}}(\boldsymbol{y}_l\lvert\boldsymbol{x})\right) - \lambda\log\pi_{\boldsymbol{\theta}}(\boldsymbol{y}_w\lvert\boldsymbol{x})$
SLiC-HF	$\max\left(0, \delta - \log\pi_{\boldsymbol{\theta}}(\boldsymbol{y}_w\lvert\boldsymbol{x}) + \log\pi_{\boldsymbol{\theta}}(\boldsymbol{y}_l\lvert\boldsymbol{x})\right) - \lambda\log\pi_{\boldsymbol{\theta}}(\boldsymbol{y}_w\lvert\boldsymbol{x})$
DPO	$-\log\sigma\left(\beta\log\frac{\pi_{\boldsymbol{\theta}}(\boldsymbol{y}_w\lvert\boldsymbol{x})}{\pi_{\text{ref}}(\boldsymbol{y}_w\lvert\boldsymbol{x})} - \beta\log\frac{\pi_{\boldsymbol{\theta}}(\boldsymbol{y}_l\lvert\boldsymbol{x})}{\pi_{\text{ref}}(\boldsymbol{y}_l\lvert\boldsymbol{x})}\right)$
IPO	$\left(\log\frac{\pi_{\boldsymbol{\theta}}(\boldsymbol{y}_w\lvert\boldsymbol{x})}{\pi_{\text{ref}}(\boldsymbol{y}_w\lvert\boldsymbol{x})} - \log\frac{\pi_{\boldsymbol{\theta}}(\boldsymbol{y}_l\lvert\boldsymbol{x})}{\pi_{\text{ref}}(\boldsymbol{y}_l\lvert\boldsymbol{x})} - \frac{1}{2\tau}\right)^2$
CPO	$-\log\sigma\left(\beta\log\pi_{\boldsymbol{\theta}}(\boldsymbol{y}_w\lvert\boldsymbol{x}) - \beta\log\pi_{\boldsymbol{\theta}}(\boldsymbol{y}_l\lvert\boldsymbol{x})\right) - \lambda\log\pi_{\boldsymbol{\theta}}(\boldsymbol{y}_w\lvert\boldsymbol{x})$
KTO	$-\lambda_w\sigma\left(\beta\log\frac{\pi_{\boldsymbol{\theta}}(\boldsymbol{y}_w\lvert\boldsymbol{x})}{\pi_{\text{ref}}(\boldsymbol{y}_w\lvert\boldsymbol{x})} - z_{\text{ref}}\right) + \lambda_l\sigma\left(z_{\text{ref}} - \beta\log\frac{\pi_{\boldsymbol{\theta}}(\boldsymbol{y}_l\lvert\boldsymbol{x})}{\pi_{\text{ref}}(\boldsymbol{y}_l\lvert\boldsymbol{x})}\right)$
ORPO	$-\log p_{\boldsymbol{\theta}}(\boldsymbol{y}_w\lvert\boldsymbol{x}) - \lambda\log\sigma\left(\log\frac{p_{\boldsymbol{\theta}}(\boldsymbol{y}_w\lvert\boldsymbol{x})}{1-p_{\boldsymbol{\theta}}(\boldsymbol{y}_w\lvert\boldsymbol{x})} - \log\frac{p_{\boldsymbol{\theta}}(\boldsymbol{y}_l\lvert\boldsymbol{x})}{1-p_{\boldsymbol{\theta}}(\boldsymbol{y}_l\lvert\boldsymbol{x})}\right)$
R-DPO	$-\log\sigma\left(\beta\log\frac{\pi_{\boldsymbol{\theta}}(\boldsymbol{y}_w\lvert\boldsymbol{x})}{\pi_{\text{ref}}(\boldsymbol{y}_w\lvert\boldsymbol{x})} - \beta\log\frac{\pi_{\boldsymbol{\theta}}(\boldsymbol{y}_l\lvert\boldsymbol{x})}{\pi_{\text{ref}}(\boldsymbol{y}_l\lvert\boldsymbol{x})} + (\alpha\lvert\boldsymbol{y}_w\rvert - \alpha\lvert\boldsymbol{y}_l\rvert)\right)$
SimPO	$-\log\sigma\left(\frac{\beta}{\lvert\boldsymbol{y}_w\rvert}\log\pi_{\boldsymbol{\theta}}(\boldsymbol{y}_w\lvert\boldsymbol{x}) - \frac{\beta}{\lvert\boldsymbol{y}_l\rvert}\log\pi_{\boldsymbol{\theta}}(\boldsymbol{y}_l\lvert\boldsymbol{x}) - \gamma\right)$

表 8.3　偏好优化算法变种比较。KTO 中 $z_{\text{ref}} = \mathbb{E}_{(\boldsymbol{x},\boldsymbol{y})\sim\mathcal{D}}\left[\beta\text{KL}(\pi_{\boldsymbol{\theta}}(\boldsymbol{y}|\boldsymbol{x})\|\pi_{\text{ref}}(\boldsymbol{y}|\boldsymbol{x}))\right]$；ORPO 中 $p_{\boldsymbol{\theta}}(y|\boldsymbol{x}) = \exp\left(\frac{1}{|\boldsymbol{y}|}\log\pi_{\boldsymbol{\theta}}(y|\boldsymbol{x})\right)$。

表源 《大语言模型：训练、精调与对齐》表 8.3

8.5

大语言模型推理强化学习

当奖励来自“答案对不对”而不是“人喜不喜欢”，强化学习就从偏好对齐转向了能力激发。

本节内容

8.5.1　推理模型概览

8.5.2　推理强化学习方法

8.5.3　基于强化学习的语言模型智能体

推理能力的发展

人类面对数学、常识推理和代码调试等复杂问题，通常需要逻辑严密且步骤繁多的推理过程，最终才能得出答案。数学能力是衡量语言模型推理能力的代表。

2024 年 9 月

OpenAI o1

在 Codeforces 编程竞赛排名第 89 位，在 AIME 资格赛中位列全美前 500 名学生水平，在 GPQA 上准确率超越人类博士。

2024 年 12 月

DeepSeek-R1

提出首个基于预训练直接运用强化学习推理训练的方案。它揭示了强化学习能激发语言模型的“顿悟时刻”（Aha-Moment），使模型自主习得复杂推理技巧。

2021 年 11 月

GSM8K：8 500 个数学问题，参考答案通常含 2 至 8 个解题步骤。

同期

MATH：12 500 道数学竞赛题，分 5 个难度级别。

难度参照

MATH 上 GPT-3（175B）仅得 5.2%；计算机科学博士约 40%；IMO 三金得主可达 90%。

依据 《大语言模型：训练、精调与对齐》第 8.5.1 节

推理能力相关技术

Verifier

探索验证器模型与测试时计算量对 GSM8K 表现的影响。

逐步解答微调

用包含逐步解答的数学数据集微调，显著提高准确率。

思维链提示

在提示中加入逐步推理示例，帮助模型结构化推理过程。

STaR

迭代地筛选能推导出正确答案的推理步骤，用于提升能力。

过程监督

验证中间步骤的准确性以提升最终答案正确率。

PRM800K

提供步骤级准确性标签，训练过程奖励模型，为搜索或强化学习提供细粒度奖励。

自反思

用提示词引导模型分析并优化其已生成的输出。

测试时计算扩展

基于过程奖励模型，在推理时增加计算量（如探索更多路径）。

此外，部分研究利用蒙特卡洛树搜索（MCTS）等方法来优化推理过程。DeepSeek-R1 的策略则更进一步：只按最终答案的正确性做强化学习，避开了昂贵的步骤级监督。

偏好对齐与正确性对齐

RLHF：对齐偏好

优化模型输出的人类偏好，适用于创意写作、开放式问答等主观问题。

奖励来自训练好的偏好奖励模型，可刻画复杂、难以写成规则的标准。

推理 RL：对齐正确性

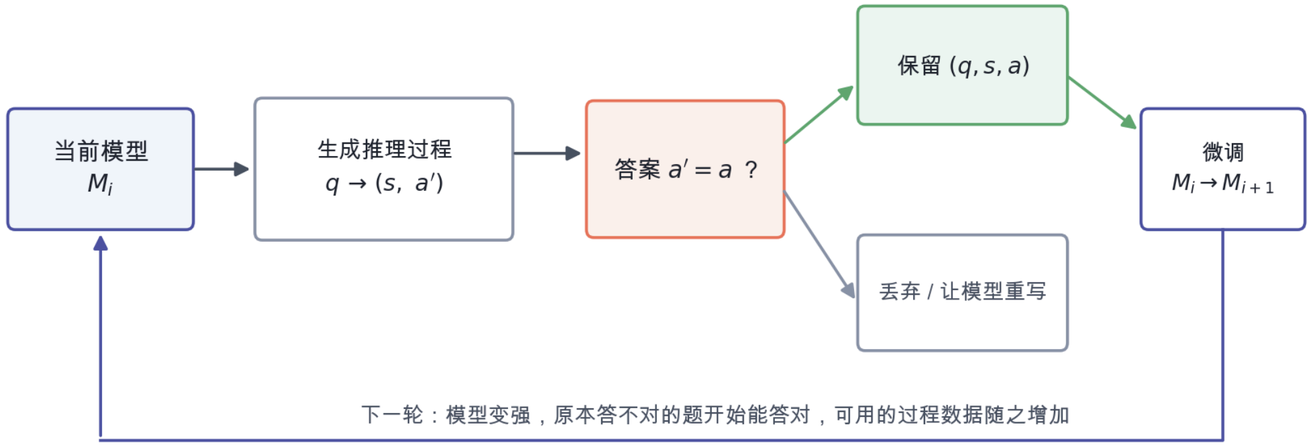
用准确性的奖励信号引导强化学习，适用于数学、代码等封闭式、有正确答案的问题。

奖励来自规则判定，只需最终答案标签，可扩展性好。

- 推理能力的提升也可能间接增强模型处理开放性问题的能力。
- 如何把主观开放性问题有效转化为封闭式客观问题，是拓展推理强化学习应用边界的关键方向。
- 该思路已延伸至多模态理解领域：例如 DeepResearch 探索用强化学习提升智能体在开放互联网环境下检索信息与主题研究的能力。

> **关键** 强化学习的目标由奖励函数决定，算法只负责优化过程的参数调整。设计好的奖励函数与设计算法同样重要。

STaR：以结果筛选推理过程



STaR 的迭代自举循环：生成 → 按答案筛选 → 用筛出的过程微调，再回到生成

- **做法**：当前模型对问题 $\boldsymbol{q}$ 生成推理过程与答案 $\boldsymbol{a'}$；只用 $\mathbb{I}(\boldsymbol{a'} = \boldsymbol{a}) = 1$ 的样本，把全过程 $(\boldsymbol{q}, \boldsymbol{s}, \boldsymbol{a})$ 当作监督信号微调。
- **自举**：模型变强后，原本答不对的题开始能答对，可用的过程数据随之增加，于是逐轮迭代。
- **与推理 RL 的关系**：两者都只看最终答案，绕开过程标注；区别在于 STaR 把筛选结果用于监督微调，不做在线策略梯度，也不需奖励模型与采样循环。

这也是 R1 冷启动数据构造的思路来源：先采样、再按答案过滤、然后人工修正，最后拿来微调。

推理问题的形式化

参考 MATH 数据集：给定数学问题 $\boldsymbol{q}$、非严格步骤解答 $\boldsymbol{s}$ 及最终答案标签 $\boldsymbol{a}$（例如 $\boldsymbol{a}=0.5$），答案客观无歧义。

$$\begin{aligned}\boldsymbol{y} &\sim \pi_{\boldsymbol{\theta}}(\cdot \mid \boldsymbol{q}) \\ &\longrightarrow \quad \boldsymbol{a}' = \operatorname{Extract}(\boldsymbol{y}) \\ &\longrightarrow \quad \mathbb{I}(\boldsymbol{a}' = \boldsymbol{a}) \in \{0,1\}\end{aligned}$$

模型预测 $\boldsymbol{y}$ 后，用规则提取其中首个 $\boxed{\cdot}$ 包含的答案（如 $\boxed{1/2}$），再根据匹配函数 $\mathbb{I}(\cdot)$ 判断预测答案与标签的数学等价性（$1/2$ 与 0.5 等价）。

- 此类无需额外模型的判别机制称为**规则判别**（或规则奖励）；选择题可直接匹配有限选项。
- 当前数学能力测评仅针对最终答案 $\boldsymbol{a}$ 评估，对 $\boldsymbol{y}$ 中的解答过程无严格正确性要求——因步骤表述差异，过程正确性难以判定。
- 测评目标是使 $\pi_{\boldsymbol{\theta}}$ 在测试集上的准确率 $\frac{1}{N}\sum_{i=1}^{N}\mathbb{I}\big(\boldsymbol{a}'^{(i)} = \boldsymbol{a}^{(i)}\big)$ 最大化。

依据 《大语言模型：训练、精调与对齐》第 8.5.1 节

MATH 数据集

Problem

The equation $x^2 + 2x = i$ has two complex solutions. Determine the product of their real parts.

Solution

Complete the square by adding 1 to each side. Then $(x+1)^2 = 1 + i = e^{\frac{i\pi}{4}}\sqrt{2}$, so $x + 1 = \pm e^{\frac{i\pi}{8}}\sqrt[4]{2}$. The desired product is then

$$\left(-1 + \cos\left(\frac{\pi}{8}\right)\sqrt[4]{2}\right)\left(-1 - \cos\left(\frac{\pi}{8}\right)\sqrt[4]{2}\right) = 1 - \cos^2\left(\frac{\pi}{8}\right)\sqrt{2} = 1 - \frac{1+\cos\left(\frac{\pi}{4}\right)}{2}\sqrt{2} = \boxed{\frac{1-\sqrt{2}}{2}}$$

示例说明两件事：其一，解答过程 $\boldsymbol{s}$ 很长且写法多样；其二，最终答案可以由 $\boxed{\cdot}$ 精确提取，因而能被规则奖励直接判定。在仅监督结果的设定下，数据集中提供的解答 $\boldsymbol{s}$ 并非必需。

> **关于 \boxed{}**　\boxed{} 是 LaTeX 的排版命令，只负责在公式外画一个框：源码 \boxed{\frac{1-\sqrt{2}}{2}} 渲染出来就是方框里的 $\frac{1-\sqrt{2}}{2}$。它同时充当机器友好的分隔符——规则奖励用正则取出第一个 \boxed{…} 里的内容，再与标准答案比对，“答案在哪”因而不用语义解析，只靠一个固定符号。

从微调到强化学习

MATH 基准表明：基于三元组 $(\boldsymbol{q}, \boldsymbol{s}, \boldsymbol{a})$ 的有监督微调（同时学习解题步骤与答案）相比仅微调答案，能显著提升准确率。

仅微调答案

只学 $(\boldsymbol{q}, \boldsymbol{a})$

→

微调步骤与答案

学 $(\boldsymbol{q}, \boldsymbol{s}, \boldsymbol{a})$，显著更好

→

强化学习

只给答案奖励，步骤由探索得到

- 思维链指出：语言模型通过生成解题步骤可提高最终答案正确率。无论是微调还是提示词工程，生成逻辑正确的解题步骤都是关键。
- 但现有数据对数学能力的提升有限——人工写出的步骤既贵又受分布限制。
- DeepSeek-R1 采用思维链推理策略：通过探索不同解法，并依据规则奖励调整参数，以增加正确解法的预测概率。

依据 《大语言模型：训练、精调与对齐》第 8.5.2 节

GRPO 算法

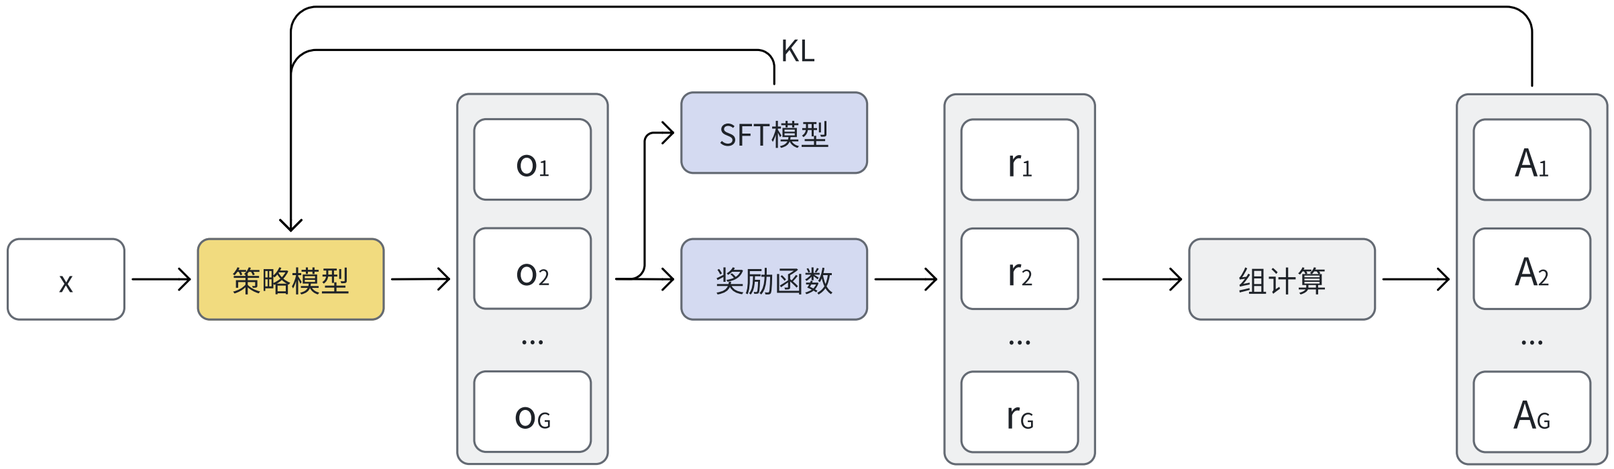


图 8.17　GRPO 算法流程图

- 组相对策略优化（GRPO）是 PPO 的变体，移除了价值模型，降低训练所需显存。
- 流程：对每个问题 $\boldsymbol{q}$，从旧策略采样 G 个回答；用规则奖励函数给每个回答打分；用组内奖励的均值与标准差做标准化，得到优势。

图中路线为：$\boldsymbol{x} \to$ 策略模型 $\to \{o_1, \ldots, o_G\}$；同时送入 SFT 模型与奖励函数计算 KL 与奖励 $\{r_1, \ldots, r_G\}$；组计算得到优势 $\{A_1, \ldots, A_G\}$，再回传更新策略。

图源 《大语言模型：训练、精调与对齐》图 8.17

组内相对优势

GRPO 的优势估计不使用价值模型，而是用同一问题下 G 个回答的奖励统计量做标准化。

$$\hat{A}_i = \frac{r_i - \operatorname{mean}\left(\{r_1, r_2, \cdots, r_G\}\right)}{\operatorname{std}\left(\{r_1, r_2, \cdots, r_G\}\right)} \tag{8-34}$$

r_i 为规则奖励函数 $R(\boldsymbol{o})$ 给回答 $\boldsymbol{o}_i$ 的分数。对于一个回答 $\boldsymbol{o}_i$，其生成轨迹中的所有词元共享相同的标准化奖励值，即 $A_{i,t} = \hat{A}_i$。

分子

当前样本奖励与组内平均奖励之差：比同组“平均表现”好多少，而不是比某个学出来的基线好多少。

分母

组内标准差：把不同题目的奖励尺度归一化，使同一超参数能跨题目使用。

若某题所有回答都错（全组奖励为 0），则均值为 0、标准差为 0，优势无定义且无梯度——这解释了 8.5.2 节末“问题过难时无法有效优化”的现象。

依据 《大语言模型：训练、精调与对齐》第 8.5.2 节（式 (8-34)）

GRPO 的优化目标

$$\mathcal{L}_{\mathrm{GRPO}}(\boldsymbol{\theta}) = \mathbb{E}_{\boldsymbol{q}\sim\mathcal{D},\,\{\boldsymbol{o}_i\}_{i=1}^{G}\sim\pi_{\mathrm{old}}(\boldsymbol{o}|\boldsymbol{q})}\,\frac{1}{G}\sum_{i=1}^{G}\Big[\min\left(\rho_i \boldsymbol{A}_i,\ \mathtt{clip}\left(\rho_i, 1-\epsilon, 1+\epsilon\right)\boldsymbol{A}_i\right) - \beta\,\mathbb{D}_{\mathrm{KL}}\left(\pi_{\boldsymbol{\theta}}\|\pi_{\mathrm{ref}}\right)\Big] \tag{8-35}$$

$\rho_i = \dfrac{\pi_{\boldsymbol{\theta}}(\boldsymbol{o}_i|\boldsymbol{q})}{\pi_{\mathrm{old}}(\boldsymbol{o}_i|\boldsymbol{q})}$ 为回答级重要性比率，ϵ 与 β 是超参数。与式 (8-9) 的 PPO 策略损失相比，比率从**词元级**换成**回答级**（整条 $\boldsymbol{o}_i$），KL 惩罚也直接写进同一期望。

$$\mathbb{D}_{\mathrm{KL}}\left(\pi_{\boldsymbol{\theta}}\|\pi_{\mathrm{ref}}\right) = \frac{\pi_{\mathrm{ref}}(\boldsymbol{o}_i|\boldsymbol{q})}{\pi_{\boldsymbol{\theta}}(\boldsymbol{o}_i|\boldsymbol{q})} - \log\frac{\pi_{\mathrm{ref}}(\boldsymbol{o}_i|\boldsymbol{q})}{\pi_{\boldsymbol{\theta}}(\boldsymbol{o}_i|\boldsymbol{q})} - 1 \tag{8-36}$$

基于样本 $(\boldsymbol{q}, \boldsymbol{o}_i)$ 的 KL 估计量（K3 估计），旨在降低标准 KL 估计的方差并保持无偏性。

读法整式与 PPO 的策略损失同构：先算比率 ρ_i 并裁剪，再乘优势 $\boldsymbol{A}_i$。差别只在两处——比率是回答级而非词元级，且没有价值模型，$\boldsymbol{A}_i$ 由组内奖励直接算出（见下一页）。

依据 《大语言模型：训练、精调与对齐》第 8.5.2 节（式 (8-35)、(8-36)）

组内采样与比较

GRPO 的组采样机制可视为类蒙特卡洛方法的探索策略：同一问题并行采多条轨迹，用组内相对表现代替价值模型。

	o_1	o_2	o_3	o_4
奖励 r_i	0	0	0	1
优势 $\hat{A}_i$	−0.58	−0.58	−0.58	+1.73

- 示意：$G = 4$，只有 o_4 答对。组内均值 $\bar{r} = 0.25$、标准差 ≈ 0.433，标准化后 o_4 得 $+1.73$，三个答错的各得 -0.58。
- 三错一对时优势不再对称：答对的那条被放大，因为它在组内是孤例——这正是组内相对优势奖励罕见正确的机制。
- 每个回答的所有词元共享同一优势值，序列级优势直接摊到每个词元上，同时省去价值模型的训练与显存开销。
- 全组都错或全组都对时，标准差为 0，优势无定义、无梯度——所以每道题都要留出"能答对一部分"的难度。

依据 《大语言模型：训练、精调与对齐》第 8.5.2 节（GRPO 组内相对优势）

GRPO 算法的三个循环

算法 15 GRPO 算法

输入： 初始化策略模型 $\pi_{\boldsymbol{\theta}_{\text{init}}}$；问题和最终答案数据集 $\mathcal{D}$；超参数 ϵ, β, μ

输出： $\pi_{\boldsymbol{\theta}}$

策略模型 $\pi_{\boldsymbol{\theta}} \leftarrow \pi_{\boldsymbol{\theta}_{\text{init}}}$
for iteration $= 1, \ldots, \mathrm{I}$ **do**
  参考模型 $\pi_{\text{ref}} \leftarrow \pi_{\boldsymbol{\theta}}$
  for step $= 1, \ldots, \mathrm{M}$ **do**
    从 $\mathcal{D}$ 采样训练数据 $\mathcal{D}_b$
    将当前策略作为旧策略 $\pi_{\text{old}} \leftarrow \pi_{\boldsymbol{\theta}}$
    训练样本 $(\boldsymbol{q}, \boldsymbol{a}) \in \mathcal{D}_b$ 的一个问题 $\boldsymbol{q}$，采样 G 个输出 $\{\boldsymbol{o}_i\}_{i=1}^{G} \sim \pi_{\text{old}}(\cdot \mid \boldsymbol{q})$
    根据奖励函数计算每个输出样本 $R(\boldsymbol{o}_i, \boldsymbol{a})$ 的奖励分数 $\{r_i\}_{i=1}^{G}$
    计算 o_i 输出 t 个词元的相对优势估计 $\hat{A}_{i,t}$
    for GRPO 迭代 $= 1, \ldots, \mu$ **do**
      通过最大化 GRPO 目标 (式 8-35) 更新目标策略模型 $\pi_{\boldsymbol{\theta}}$
    end for
  end for
end for

外层重置参考模型；中层采样问题、生成回答、算奖励与优势；内层在固定样本上反复最大化目标（可设 $\mu = 1$）。

GRPO 的适用范围

优势

组采样提升探索效率，可视为类蒙特卡洛的探索策略。

策略梯度采用改进的 REINFORCE 变体；组内相对优势的估计具有无偏性。

省去价值模型，显存与训练复杂度显著下降。

局限

奖励函数需显式定义，而非基于隐式奖励模型；不过框架支持通过生成式奖励模型扩展奖励来源，并可融合长度奖励、格式规范奖励等多类信号。

缺乏显式价值模型，难以对序列决策过程做长期价值建模：只能评估决策步骤对最终结果的影响，无法量化长期价值贡献。

> **一句话** GRPO 用“同题多答、组内比较”替换了价值模型，代价是失去了对长程价值的估计能力。

依据 《大语言模型：训练、精调与对齐》第 8.5.2 节

R1-Zero 的推理行为

DeepSeek-R1-Zero 基于预训练模型 DeepSeek-V3（未经过世界问答知识微调），使用 GRPO 训练。训练中观察到“顿悟时刻”：从中间数据采样的模型会输出“假设”“验证”“思考”等强逻辑属性的词句。

现象

模型自主产生思维链式解答过程；采样平均长度显著增加。

训练仅通过规则奖励激发推理能力，并未引入人类监督解题经验。

意义

结果监督避免了过程标注依赖；算法简洁高效——只需增加采样数量并延长采样长度，即可获得较优性能。

提示词模板

作为 AI 助理需要解决用户提问，先在脑海中思考推理过程，再将答案提供给用户。推理过程和答案分别包含在 <think></think> 和 <answer></answer> 标签中。用户：输入内容　AI 助理：

推理行为的一个实例

R1-Zero 训练早期，模型输出里开始自发出现“等一下、让我重来”这类句子——论文称之为“顿悟时刻”（aha moment）。下面是一条真实输出的摘录。

Question

If $a > 1$, then the sum of the real solutions of $\sqrt{a - \sqrt{a + x}} = x$ is equal to

Response

<think> To solve the equation, let's start by squaring both ···

$(a - x^2)^2 = a + x \implies x^4 - 2ax^2 - x + (a^2 - a) = 0$

Wait, wait. Wait. That's an aha moment I can flag here.

Let's reevaluate this step-by-step to identify if the correct sum can be ···

First, let's square both sides: $a - \sqrt{a + x} = x^2 \implies \sqrt{a + x} = a - x^2$ ···

> **为什么值得注意** 训练目标只奖励最终答案对错，从没教过模型“反思”。但“停下—质疑—重来”能提高答对概率，于是被强化学习自己找了出来：这正是采样长度增长、推理行为自发出现的直观证据。

R1-Zero 的问题

R1-Zero 侧重在预训练模型上用强化学习训练、在数据集上追求高准确性，但未约束推理过程的准确性和输出格式。

问题

可读性差

生成结果存在可读性差、语言混杂、乱码输出及无限循环等问题，导致无法直接上线使用。

出路

当作数据生成器

从训练好的模型中采样有效的思维链解答数据，用于 DeepSeek-R1 的训练。

转折 “能解对”与“能讲清楚”是两件事。R1-Zero 证明了前者可由规则奖励激发，而后者需要额外的数据与训练流程——这就是下一节 R1 训练框架的出发点。

依据 《大语言模型：训练、精调与对齐》第 8.5.2 节

DeepSeek-R1 的训练框架

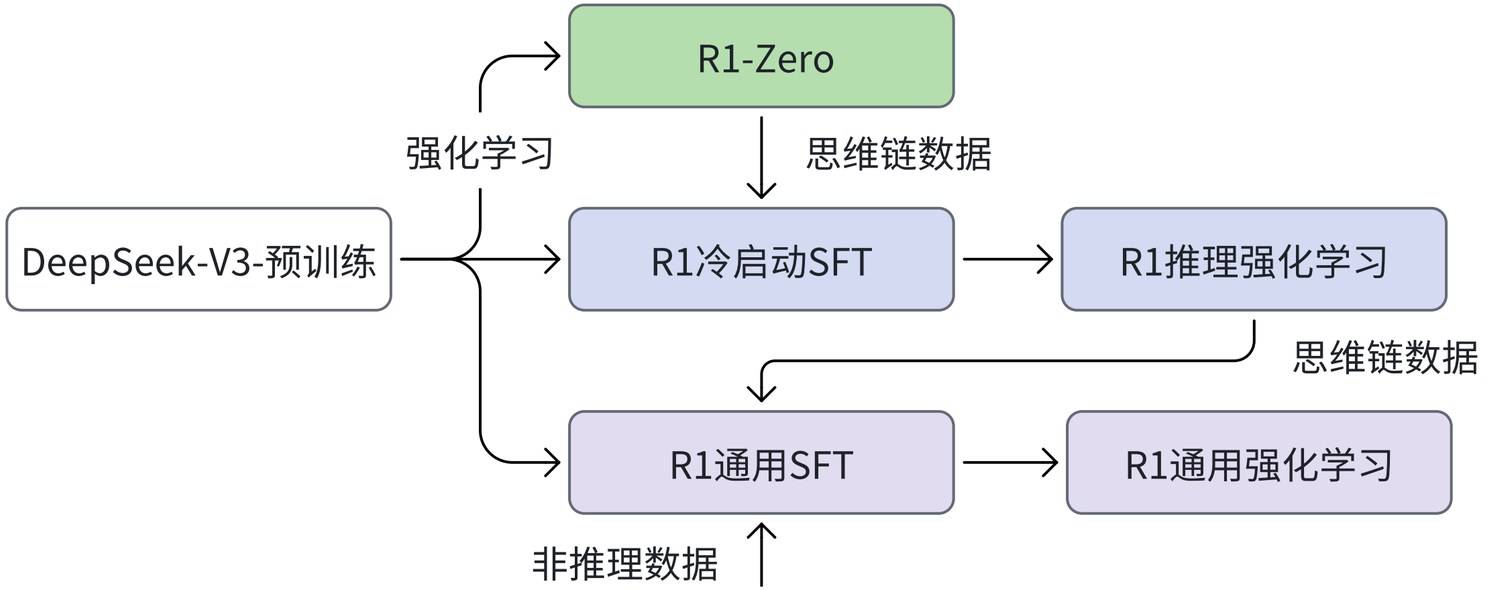


图 8.18　DeepSeek-R1 模型训练流程

- 先对 R1-Zero 的采样数据过滤（剔除语言混杂、可读性差的样本），人工修正部分解答，并增加长思维链的摘要总结，构建合成推理数据。
- 合成数据与收集的高质量思维链数据混合，形成**冷启动数据**。

整条流水线分两大阶段：推理能力提升（冷启动 SFT + 推理 RL）与通用能力提升（通用 SFT + 通用 RL），后者复用前者采样的 600 000 条长思维链数据。

图源 《大语言模型：训练、精调与对齐》图 8.18

DeepSeek-R1 的四个步骤

阶段一 · 推理能力提升

① 推理有监督微调　② 推理强化学习

基于冷启动数据在 DeepSeek-V3 上微调，得到“R1 冷启动 SFT”；再对其做推理 RL，由它采样 600 000 条格式良好的长思维链。此阶段尚未在通用指令任务上微调，常规指令跟随场景表现受限。

阶段二 · 通用能力提升

③ 通用能力有监督微调　④ 通用能力强化学习

200 000 条通用指令 + 600 000 条长思维链 = 800 000 条通用 SFT 数据，在 V3 上微调；再结合 RLHF 与推理 RL，按 GRPO 为两类任务配置不同奖励函数（偏好奖励需先训练奖励模型），得到 DeepSeek-R1。

数据流

R1-Zero 采样与人工思维链汇成冷启动数据；推理 RL 采出的 600 000 条思维链既蒸馏到小模型，也并入通用 SFT。

蒸馏：用 R1 采样的思维链数据蒸馏到较小模型（如 Qwen2.5-32B），性能优于直接在 Qwen2.5-32B 上做推理 RL——高质量思维链数据本身至关重要。

R1 模型分析

追问 1

预训练模型本身就有顿悟时刻吗?

预训练语料丰富，包含相关推理数据属正常。关注点应是推理 RL 中模型是否运用了更多推理模式。另有实验表明，预训练模型上 CoT 采样数量增长后，其推理性能优于经过推理 RL 的模型——即推理 RL 提高了求解答案的效率。

追问 2

采样出的思维链是否正确?

在结果监督下，过程正确性不会被直接判定：收到正奖励信号的输出，其思维链也被默认为正确。直觉上，思维链会随训练变得更严谨。

追问 3

对通用任务有增益吗?

Logic-RL 中，仅在逻辑谜题上训练的模型，在数学（GSM8K、MATH）、符号推理（BBH）和代码调试（HumanEval、MBPP）上显著提升。相同基座上，SFT 模型只在其他推理任务上有部分泛化；RL 模型在推理与非推理任务上泛化更广。

追问 4

幻觉更严重吗?

未经微调的预训练模型直接做推理 RL，所得模型表现出更严重的幻觉。R1 经过有益的有监督微调，能平衡通用能力与推理能力。

推理训练的三个方面

强化学习训练复杂度

GRPO 的采样效率受采样样本数量 G 与生成最大长度影响。采样通常可放在独立推理服务上执行，以提高整体效率。样本数足够大时相对优势估计更准确；若问题过难采不到正确答案，该组奖励为 0、相对优势为 0，无法有效优化。因此 GRPO 范式下的计算量比 SFT 与 PPO 更大。

过程监督的限制

基于 PRM 的搜索面临“步骤”难以标准化定义、标注成本高的问题；基于 MCTS 的方法受限于语言模型的计算资源需求，当前难以复刻 AlphaZero 的大规模模拟采样。GRPO 训练中的采样组数据可视为一种搜索形式。

测试时间扩展

推理模型需先生成思维链，因而增加了测试时间——可视为生成序列长度增加带来的开销。另一种扩展方式是采样更多轨迹，提高得到正确答案的可能性。

依据 《大语言模型：训练、精调与对齐》第 8.5.2 节

从推理模型到智能体

DeepSeek-R1 的成功引发开源社区复现热潮，催生众多基于强化学习的训练框架与推理能力优化算法，其经验也正推广至多模态领域。

部署问题 1

思维链过长

CoT 过长导致生成效率降低。

部署问题 2

安全对齐风险

推理能力增强伴随对抗性攻击等安全风险。

落地关键

领域适配

如何针对特定领域有效实施基于强化学习的推理训练。

- 在需要深度知识整合的任务（如 DeepResearch 类任务）中，用强化学习提升智能体的知识获取与工具运用能力，是通向通用人工智能的重要路径。
- 随着模型能力持续增强，对其进行有效的安全约束将成为未来的核心议题。

8.6 小结

两条路线、一个框架：偏好对齐与推理强化学习，都是把语言模型放进 MDP，再用奖励信号推动策略改进。

本节内容

对齐目标与主要手段

RLHF 与 DPO

推理强化学习

思考题与实践题

本章小结

语言模型的行为需要对齐到 3H 准则或 RICE 准则；对齐目标是在安全约束下具备强大的通用能力。强化学习是实现对齐的主要手段，而把语言模型任务在马尔可夫决策过程框架下展开，是迁移强化学习方法的前提。

路线一

基于人类反馈的强化学习

对齐复杂的偏好信号：SFT → 奖励模型 → PPO。训练后的模型提升了安全性和实用性。

与 SFT 相比，PPO 从序列整体优化，训练过程有探索性和负反馈，泛化性更好。

缺点：奖励欺骗；偏好学习无法建模绝对准确性，在逻辑推理场景存在限制；PPO 复杂度高。

路线二

推理强化学习

对齐静态的准确性奖励规则：以 GRPO 为代表，去除价值模型，用组内相对优势。

R1-Zero 依靠规则奖励激发推理能力；GRPO 简化了 PPO 并通过组采样增强探索性。

推理能力可泛化到其他场景；过程奖励模型与 MCTS 目前仍有步骤难定义、样本难获取等局限。

结合 两种方法可以相互结合：R1 的通用能力强化学习阶段就同时配置了偏好奖励与正确性奖励。

对齐方法对比

方法	奖励来源	需加载的模型	优化层级	典型用途
SFT	人工示范数据	策略	词元级	指令遵循
PPO / RLHF	偏好奖励模型	策略、价值、参考、奖励	序列级（经 GAE 分配）	偏好对齐
DPO	成对偏好数据	策略、参考	序列级	偏好对齐（离线）
拒绝采样	奖励模型打分排序	策略、奖励（推理调用）	样本级（Best-of-N）	偏好对齐、数据筛选
GRPO	规则奖励（可换奖励模型）	策略、参考	回答级	推理能力

拒绝采样严格说不是一种训练算法，而是一个“用奖励选样本”的环节：对同一提示采样 N 个回答，按奖励模型（或规则）排序取最优，选出的样本再做 SFT。它既能为奖励模型造对比数据，也能为 PPO 提供更好的起点，且完全避开在线强化学习。

- PPO 算法复杂度高，DPO 简化了 RLHF 流程；迭代式 DPO、拒绝采样和多轮 RLHF 是主要的对齐手段。
- 推理强化学习通过生成思维链提高具体任务性能，其方法已被扩展到多智能体环境，应用于更复杂的真实世界交互。
- 预训练学习语言自身的表示，有监督学习模仿行为，强化学习则从交互经验中学习具体任务策略。

依据 《大语言模型：训练、精调与对齐》第 8.6 节、第 8.3.6 节（拒绝采样）

思考题与实践题

1 说明预训练与后训练的分工。为什么说“SFT 让模型会照做，RLHF 让模型做得更好”？

2 写出 PPO 目标（式 8-2），解释 β 过大与过小时分别会发生什么。

3 $K = 5$ 个排序回答能构造多少偏好对？为何要在一批内放入同一提示的全部偏好对？

4 推理强化学习为何能激发思维链，却可能加重幻觉？R1 如何应对？

5 实践：做一次 GRPO 的 R1-Zero 式训练，观察训练过程中是否出现“顿悟时刻”——采样长度何时开始跳增、模型是否自发出现“假设／验证／重来”这类词句。

6 GRPO 中若某题的 G 个回答全部错误，优势估计会怎样？如何缓解？

7 实践：实现 PPO 的 4 个模型（策略、价值、参考、奖励）及各自对应的训练算法。

8 实践：实现 GRPO 算法——组采样、规则奖励、组内标准化优势与裁剪目标。

依据 《大语言模型：训练、精调与对齐》第 8 章