大语言模型：训练、精调与对齐 | 第 7 章（下）

强化学习

第 7 章（下）

第 10 课时 本课时讲解 7.6–7.9

强化学习基础 · 动态规划 · 时序差分 · 策略梯度

著者
邓杭　杨耀东

教材
《大语言模型：训练、精调与对齐》

出版
清华大学出版社



本章目录

第 10 课时

7.1 强化学习 第 3 页
MDP、回报、价值函数与贝尔曼方程

7.2 强化学习方法 第 31 页
三大类方法的全景与表 7.1

7.3 动态规划 第 36 页
策略评估、策略改进与 GPI

7.4 蒙特卡洛方法 第 47 页
用完整幕的平均回报估计价值

7.5 时序差分学习 第 59 页
TD、SARSA、Q 学习、DQN 与 TD(λ)

7.6 策略梯度方法 第 88 页
直接优化参数化策略：定理、证明与 REINFORCE

7.7 演员-评论家 第 109 页
演员更新策略、评论家评估价值：AC、TRPO、GAE 与 PPO

7.8 大语言模型的 MDP 描述 第 125 页
状态是词元序列，动作是下一个词元

7.9 小结 第 129 页
全章脉络：从 MDP 到三类求解方法

本课时内容 7.6 策略梯度方法、7.7 演员-评论家、7.8 大语言模型的 MDP 描述、7.9 小结（其余部分见第 9 课时）

7.6

策略梯度方法

不再经由价值函数中转：把策略本身写成带参数的函数，直接对期望回报做梯度上升。

本节内容

7.6.1 策略梯度定理

7.6.2 策略梯度证明*

7.6.3 REINFORCE 策略梯度

7.6.4 离轨策略梯度

直接学习策略的动机

表格型方法受限于有限资源；DQN 虽可用参数化网络估计价值函数处理复杂问题，但仍依赖价值函数作为中介。策略梯度直接学习参数化的策略模型。

价值中介的路线

先估计 $v_\pi(s)$ 或 $q_\pi(s,a)$，再由价值导出动作。

状态或动作空间连续时，无限的状态-动作对使价值估计困难。

DQN 缓解了存储问题，但价值仍是必经环节。

直接优化策略

用参数 $\boldsymbol{\theta}$ 建模策略 $\pi_{\boldsymbol{\theta}}(a \mid s)$，直接优化它。

规避了价值估计的瓶颈，天然适合连续状态与未知环境动态。

代价是梯度估计的方差较大，需要技巧控制。

目标函数定义为初始状态 S_1 的期望回报（式 (7-54)）；更新方式是梯度上升（式 (7-55)）。本节其余内容都在回答“这个梯度怎么算”。

策略梯度的目标函数

使用参数 $\boldsymbol{\theta}$ 建模策略，记为 $\pi_{\boldsymbol{\theta}}(a \mid s)$，其目标函数定义为初始状态 S_1 的期望回报。

$$J(\boldsymbol{\theta}) = v_{\pi_{\boldsymbol{\theta}}}(S_1) = \mathbb{E}_{\pi_{\boldsymbol{\theta}}}\left[G_1\right] \tag{7-54}$$

S_1 为初始状态，G_1 是时刻 $t=1$ 的回报。目标是通过调整 $\boldsymbol{\theta}$ 最大化 $J(\boldsymbol{\theta})$，即最大化策略 $\pi_{\boldsymbol{\theta}}$ 下的期望回报。

$$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \alpha \nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta}) \tag{7-55}$$

梯度上升：沿目标函数增大的方向更新参数，α 为学习率。逐步优化 $\boldsymbol{\theta}$，使策略 $\pi_{\boldsymbol{\theta}}$ 生成最大的期望回报。

与价值方法的区别在于“被优化的对象”：这里参数直接作用在动作分布上，价值函数至多作为辅助量出现（如基线）。

式 (7-54)

$J(\boldsymbol{\theta})$ 只依赖初始状态 S_1 的期望回报，是对“整条轨迹好坏”的标量度量。

式 (7-55)

$abla_{\boldsymbol{\theta}} J$ 的估计是全部难点：它不能直接对采样求和求导，需要下页的定理。

依据 《大语言模型：训练、精调与对齐》第 7.6 节（式 (7-54)、(7-55)）

直接求导的困难

通过贝尔曼方程（式 (7-16)，折扣因子设为 1）展开 $J(\boldsymbol{\theta})$：

$$J(\boldsymbol{\theta}) = \sum_{a \in \mathcal{A}} \pi_{\boldsymbol{\theta}}(a \mid s)\, q_{\pi_{\boldsymbol{\theta}}}(s, a) \tag{7-56}$$

$$= \sum_{a \in \mathcal{A}} \pi_{\boldsymbol{\theta}}(a \mid s) \sum_{s' \in \mathcal{S}, r \in \mathcal{R}} p(s', r \mid s, a)\,(r + v_{\pi_{\boldsymbol{\theta}}}(s')) \tag{7-57}$$

动作空间 $\mathcal{A}$ 有限且离散；$\pi_{\boldsymbol{\theta}}(a \mid s)$ 是策略在状态 s 下选择动作 a 的概率。

- 对目标方程求导时，当 $p(s' \mid s, a)$ 未知，就难以计算 $\nabla_{\boldsymbol{\theta}} p(s', r \mid s, a)$。
- 而且展开式里 $v_{\pi_{\boldsymbol{\theta}}}(s')$ 本身也依赖 $\boldsymbol{\theta}$，逐层展开会无限递归。
- 策略梯度定理的作用：把梯度整理成一个**不含** ∇p 的形式。

依据 《大语言模型：训练、精调与对齐》第 7.6.1 节（式 (7-56)、(7-57)）

策略梯度定理

$$\nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta}) = \nabla_{\boldsymbol{\theta}} \sum_{a \in \mathcal{A}} \pi_{\boldsymbol{\theta}}(a \mid s) q_{\pi_{\boldsymbol{\theta}}}(s, a) \tag{7-58}$$

$$\propto \sum_{s \in \mathcal{S}} d_{\pi}(s) \sum_{a \in \mathcal{A}} q_{\pi_{\boldsymbol{\theta}}}(s, a) \nabla_{\boldsymbol{\theta}} \pi_{\boldsymbol{\theta}}(a \mid s) \tag{7-59}$$

$d_{\pi_{\boldsymbol{\theta}}}(s)$ 是策略 $\pi_{\boldsymbol{\theta}}$ 诱导的马尔可夫链的稳态分布。求梯度时，$\nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta})$ 依赖动作的选择（由 $\pi_{\boldsymbol{\theta}}$ 决定）与稳态分布 d_{π}（不直接由 $\pi_{\boldsymbol{\theta}}$ 决定）。

- 关键结论：目标梯度与状态转移方程无关。状态转移概率在长期中收敛为稳态分布，梯度只与目标优化方程成比例。
- 这正是"绕开环境模型"的来源：不需要知道 $p(s' \mid s, a)$，只要按策略采样就能估计这个期望。
- 下一节给出从式 (7-59) 到显式期望形式的完整推导。

"成正比"而非"相等"是这一步的要点：省掉的因子是 $\sum_s \eta(s)$，它与 $\boldsymbol{\theta}$ 无关，不影响梯度上升的方向。

策略梯度推导（一）：对状态价值求导并展开

$$\nabla_{\boldsymbol{\theta}} v_{\pi_{\boldsymbol{\theta}}}(s) = \nabla_{\boldsymbol{\theta}} \Big(\sum_{a \in \mathcal{A}} \pi_{\boldsymbol{\theta}}(a \mid s) q_{\pi_{\boldsymbol{\theta}}}(s,a) \Big) \tag{7-60}$$

$$= \sum_{a \in \mathcal{A}} \Big(\nabla_{\boldsymbol{\theta}} \pi_{\boldsymbol{\theta}}(a \mid s) q_{\pi_{\boldsymbol{\theta}}}(s,a) + \pi_{\boldsymbol{\theta}}(a \mid s) \nabla_{\boldsymbol{\theta}} q_{\pi_{\boldsymbol{\theta}}}(s,a) \Big) \tag{7-61}$$

$$= \sum_{a \in \mathcal{A}} \Big(\nabla_{\boldsymbol{\theta}} \pi_{\boldsymbol{\theta}}(a \mid s) q_{\pi_{\boldsymbol{\theta}}}(s,a) + \pi_{\boldsymbol{\theta}}(a \mid s) \nabla_{\boldsymbol{\theta}} \sum_{s',r} p(s', r \mid s, a) \left(r + v_{\pi_{\boldsymbol{\theta}}}(s') \right) \Big) \tag{7-62}$$

$$= \sum_{a \in \mathcal{A}} \Big(\nabla_{\boldsymbol{\theta}} \pi_{\boldsymbol{\theta}}(a \mid s) q_{\pi_{\boldsymbol{\theta}}}(s,a) + \pi_{\boldsymbol{\theta}}(a \mid s) \sum_{s',r} p(s', r \mid s, a) \nabla_{\boldsymbol{\theta}} v_{\pi_{\boldsymbol{\theta}}}(s') \Big) \tag{7-63}$$

$$= \sum_{a \in \mathcal{A}} \Big(\nabla_{\boldsymbol{\theta}} \pi_{\boldsymbol{\theta}}(a \mid s) q_{\pi_{\boldsymbol{\theta}}}(s,a) + \pi_{\boldsymbol{\theta}}(a \mid s) \sum_{s'} p(s' \mid s, a) \nabla_{\boldsymbol{\theta}} v_{\pi_{\boldsymbol{\theta}}}(s') \Big) \tag{7-64}$$

式 (7-61) 用乘积法则拆两项；式 (7-62) 把第二项的 $q_{\pi_{\boldsymbol{\theta}}}$ 换成贝尔曼展开；式 (7-63) 中 r、p 不含 $\boldsymbol{\theta}$，梯度只落在 $v_{\pi_{\boldsymbol{\theta}}}(s')$；式 (7-64) 对 r 求和。至此 $\nabla v(s)$ 已写成 $\nabla v(s')$ 的加权和。

第一项 $\nabla_{\boldsymbol{\theta}} \pi \cdot q$

要保留的可采样部分。

第二项 $\pi \cdot \nabla_{\boldsymbol{\theta}} q$

展开后落回 $v(s')$。

递归成形

式 (7-64) 可再展开一步。

依据 《大语言模型：训练、精调与对齐》第 7.6.2 节（式 (7-60)–(7-64)）

策略梯度推导（二）：定义多步转移概率

$$
\begin{aligned}
k = 0: &\qquad \rho_{\pi_\theta}(s \to s, 0) = 1 \\
k = 1: &\qquad \rho_{\pi_\theta}(s \to s', 1) = \sum_{a} \pi_{\boldsymbol{\theta}}(a \mid s)\, p(s' \mid s, a) \\
k \geqslant 1: &\quad \rho_{\pi_\theta}(s \to x, k+1) = \sum_{s'} \rho_{\pi_\theta}(s \to s', k)\, \rho_{\pi_\theta}(s' \to x, 1)
\end{aligned}
$$

三行的等号对齐。$\rho_{\pi_\theta}(s \to x, k)$ 为从 s 经 k 步转移到 x 的概率：$k=0$ 表示停留在自身；$k=1$ 是先按策略选动作、再按环境转移一步；递推式把"走 k 步到 s'，再走 1 步到 x"拼接起来。

为什么需要 ρ

式 (7-64) 只说了相邻两步的递归。要把递归解到无穷，必须把"走了几步、经过哪些状态"的随机性收进一个量。

有了 ρ，展开就变成对"目的地 x"与"步数 k"的纯求和拼接。

策略梯度推导（三）：递归展开到全轨迹

$$\nabla_{\boldsymbol{\theta}} v_{\pi_\theta}(s) = \phi(s) + \sum_{s'} \rho_{\pi_\theta}(s \to s', 1) \nabla_{\boldsymbol{\theta}} v_{\pi_\theta}(s') \tag{7-65}$$

$$= \phi(s) + \sum_{s'} \rho_{\pi_\theta}(s \to s', 1) \left[\phi(s') + \sum_{s''} \rho_{\pi_\theta}(s' \to s'', 1) \nabla_{\boldsymbol{\theta}} v_{\pi_\theta}(s'') \right] \tag{7-66}$$

$$= \phi(s) + \sum_{s'} \rho_{\pi_\theta}(s \to s', 1) \phi(s') + \sum_{s''} \rho_{\pi_\theta}(s \to s'', 2) \nabla_{\boldsymbol{\theta}} v_{\pi_\theta}(s'') \tag{7-67}$$

$$= \cdots \tag{7-68}$$

$$= \sum_{x \in \mathcal{S}} \sum_{k=0}^{\infty} \rho_{\pi_\theta}(s \to x, k) \phi(x) \tag{7-69}$$

记 $\phi(s)$ 为式 (7-64) 括号内的第一项，递归写成式 (7-65)。

式 (7-66)

把 $\nabla v(s')$ 再用式 (7-65) 展开一层。

式 (7-67)

用 ρ 的递推合并两步转移。

式 (7-69)

末项推到无穷远，只剩对状态与步数求和。

策略梯度推导（四）：得到策略梯度定理

$$\nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta}) = \nabla_{\boldsymbol{\theta}} v^{\pi_\theta}(s_0) \tag{7-70}$$

$$= \sum_s \sum_{k=0}^{\infty} \rho_{\pi_\theta}(s_0 \to s, k)\, \phi(s) \tag{7-71}$$

$$= \sum_s \eta(s) \phi(s) \tag{7-72}$$

$$= \Big(\sum_s \eta(s) \Big) \sum_s \frac{\eta(s)}{\sum_s \eta(s)} \phi(s) \tag{7-73}$$

$$\propto \sum_s \frac{\eta(s)}{\sum_s \eta(s)} \phi(s) \tag{7-74}$$

$$= \sum_s d^{\pi}(s) \sum_a \nabla_{\boldsymbol{\theta}} \pi_{\boldsymbol{\theta}}(a \mid s) q^{\pi}(s, a) \tag{7-75}$$

$\eta(s)$ 是访问状态 s 的期望次数，$\sum_s \eta(s)$ 与 $\boldsymbol{\theta}$ 无关、是标量，故可按比例化简（式 (7-74)）；$d_\pi(s) = \eta(s) / \sum_s \eta(s)$ 是稳态分布。

- 式 (7-75) 把 $\phi(s)$ 代回，梯度只含 $\nabla_{\boldsymbol{\theta}} \pi_{\boldsymbol{\theta}}$ 与 q^{π}，对 $q_{\pi_\theta}(s, a)$ 的求导被完全去除。
- 环境转移概率 $p(s' \mid s, a)$ 不再出现——这正是策略梯度定理可以直接对参数优化期望回报的原因。

依据 《大语言模型：训练、精调与对齐》第 7.6.2 节（式 (7-70)–(7-75)）

从定理到样本梯度

蒙特卡洛策略梯度（REINFORCE）依赖蒙特卡洛方法采样分幕数据并更新策略参数 $\boldsymbol{\theta}$。根据策略梯度定理，样本梯度正比于实际梯度。

$$\nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta}) \propto \sum_{s \in \mathcal{S}} d_\pi(s) \sum_{a \in \mathcal{A}} q_\pi(s,a) \nabla_{\boldsymbol{\theta}} \pi_{\boldsymbol{\theta}}(a \mid s) \tag{7-76}$$

$$= \mathbb{E}_\pi \left[\sum_a q_\pi(S_t, a) \nabla_{\boldsymbol{\theta}} \pi_{\boldsymbol{\theta}}(a \mid S_t) \right] \tag{7-77}$$

式 (7-77) 把“对状态按稳态分布求和”识别为“对策略采样到的状态 S_t 取期望”。

式 (7-77) 里还没有显式的 $\pi_{\boldsymbol{\theta}}(a \mid S_t)$ 作为加权系数。下一步通过乘除同一个概率把它引入，才能把求和变成对采样动作的期望。

对数导数技巧

$$\nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta}) = \mathbb{E}_{\pi}\left[\sum_{a} q_{\pi}(S_t, a)\, \pi_{\boldsymbol{\theta}}(a \mid S_t) \frac{\nabla_{\boldsymbol{\theta}} \pi_{\boldsymbol{\theta}}(a \mid S_t)}{\pi_{\boldsymbol{\theta}}(a \mid S_t)}\right] \tag{7-78}$$

$$= \mathbb{E}_{\pi}\left[q_{\pi}(S_t, A_t) \frac{\nabla_{\boldsymbol{\theta}} \pi_{\boldsymbol{\theta}}(A_t \mid S_t)}{\pi_{\boldsymbol{\theta}}(A_t \mid S_t)}\right] \tag{7-79}$$

$$= \mathbb{E}_{\pi}\left[q_{\pi}(S_t, A_t) \nabla_{\boldsymbol{\theta}} \ln \pi_{\boldsymbol{\theta}}(A_t \mid S_t)\right] \tag{7-80}$$

$$= \mathbb{E}_{\pi}\left[G_t \nabla_{\boldsymbol{\theta}} \ln \pi_{\boldsymbol{\theta}}(A_t \mid S_t)\right] \tag{7-81}$$

式 (7-78)：对求和项乘除 $\pi_{\boldsymbol{\theta}}(a \mid S_t)$，得到按策略概率加权的形式；式 (7-79)：加权后求和即为对采样动作 A_t 的期望；式 (7-80)：用 $\nabla \ln x = \nabla x / x$；式 (7-81)：用 $\mathbb{E}_{\pi}\left[G_t \mid S_t, A_t\right] = q_{\pi}(S_t, A_t)$。

四步的核心是同一个技巧：把“对动作求和”改写为“按概率采样再求期望”。改写之后，梯度只剩下 $\ln \pi$ 的导数与回报的乘积，两者都能从一条轨迹直接算出。

依据 《大语言模型：训练、精调与对齐》第 7.6.3 节（式 (7-78)–(7-81)）

参数更新式

$$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \alpha\, G \nabla_{\boldsymbol{\theta}} \ln \pi_{\boldsymbol{\theta}}(A_t \mid S_t) \tag{7-82}$$

其中 G 可从真实采样轨迹中估计。由于 G 依赖完整轨迹，REINFORCE 必须采样完整幕。伪代码中的更新式还含折扣因子 γ^t（上述推导对应特例 $\gamma = 1$）。

- 梯度方向由 $\nabla_{\boldsymbol{\theta}} \ln \pi_{\boldsymbol{\theta}}(A_t \mid S_t)$ 给出，幅度由回报 G 加权。
- 直观看：回报高，就提高该动作在同样状态下被选中的概率；回报低则降低。
- 对整个幕反向遍历，每一步都用从该时刻起累积的 G 更新一次。

$abla_{\boldsymbol{\theta}} \ln \pi_{\boldsymbol{\theta}}(A_t \mid S_t)$ 指向“让该动作概率增大”的参数方向；乘上 G 后，回报为正则强化、为负则抑制。若回报全为正，所有动作都会被强化，这时就需要基线。

依据 《大语言模型：训练、精调与对齐》第 7.6.3 节（式 (7-82)）

算法 8　REINFORCE 策略梯度算法

算法 8 REINFORCE 策略梯度算法

输入： 给定含参数 $\boldsymbol{\theta}$ 的策略模型 $\pi_{\boldsymbol{\theta}}(a|s)$，学习率 α，折扣因子 γ
输出： 最优策略 $\pi(a|s;\boldsymbol{\theta}_*)$ 的参数 $\boldsymbol{\theta}_*$ 模型

1: **for** 每一幕 **do**
2: 　　以 $\pi(a|s;\boldsymbol{\theta})$，生成幕序列 $S_0, A_0, R_0, \ldots, S_T, A_T, R_T$
3: 　　**for** 对幕中的每一步循环,$t = \{T, T-1, \cdots, 1, 0\}$ **do**
4: 　　　　$G \leftarrow \sum_{k=t+1}^{T} \gamma^{k-t-1} R_k$
5: 　　　　$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \alpha\gamma^t G \nabla \ln \pi(A_t|S_t;\boldsymbol{\theta})$
6: 　　**end for**
7: **end for**

第 2 步采样一整幕；第 4 步从后向前累加折扣回报；第 5 步是式 (7-82) 的带折扣版本，更新幅度额外乘上 γ^t，越早的动作权重越低。

基线的引入

更通用的 REINFORCE 通过减去基线（baseline）降低策略梯度的方差，同时保证梯度估计的无偏性。例如采用优势函数 $A(s,a)=q_\pi(s,a)-v_\pi(s)$ 替代回报。

$$\nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta}) \propto \sum_{s\in\mathcal{S}} d_\pi(s) \sum_{a\in\mathcal{A}} \left(q_\pi(s,a)-b(s)\right) \nabla_{\boldsymbol{\theta}} \pi_{\boldsymbol{\theta}}(a\mid s) \tag{7-83}$$

$b(s)$ 为基线函数（任意函数）。

$$\sum_{a\in\mathcal{A}} b(s)\nabla_{\boldsymbol{\theta}}\pi_{\boldsymbol{\theta}}(a\mid s) = b(s)\nabla_{\boldsymbol{\theta}} \sum_{a\in\mathcal{A}} \pi_{\boldsymbol{\theta}}(a\mid s) = b(s)\nabla_{\boldsymbol{\theta}} 1 = 0 \tag{7-84}$$

式 (7-84) 说明 $b(s)$ 的期望贡献恒为零：概率之和恒为 1，其梯度为零。因此减去基线不改变梯度的期望，只改变方差。

三步都很短，但逻辑链完整：把 $b(s)$ 提到求和号外 → 概率之和恒为 1 → 常数的梯度为零。正因如此，基线可以取任意函数，不必保证精确。

依据 《大语言模型：训练、精调与对齐》第 7.6.3 节（式 (7-83)、(7-84)）

优势函数

用参数 $\boldsymbol{W}$ 估计状态价值 $\hat{v}(s;\boldsymbol{W})$ 作为基线。基于 $v_\pi(s)=\sum_a \pi_{\boldsymbol{\theta}}(a\mid s)q_\pi(s,a)$，优势函数 $A(s,a)=q_\pi(s,a)-v_\pi(s)$ 量化了动作 a 相对于平均水平的优势。

$$\nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta}) = \mathbb{E}_\pi\left[\left(q_\pi(S_t,A_t)-\hat{v}(S_t;\boldsymbol{W})\right)\nabla_{\boldsymbol{\theta}}\ln\pi_{\boldsymbol{\theta}}(A_t\mid S_t)\right] \tag{7-85}$$

$$= \mathbb{E}_\pi\left[\left(G_t-\hat{v}(S_t;\boldsymbol{W})\right)\nabla_{\boldsymbol{\theta}}\ln\pi_{\boldsymbol{\theta}}(A_t\mid S_t)\right] \tag{7-86}$$

式 (7-86) 用采样回报 G_t 替代 q_π：G_t 是 q_π 的无偏样本。括号内即优势的估计，正值表示该动作优于平均水平。

若某动作的回报高于状态的平均价值，就提高它的概率；低于平均值则降低。基线把“绝对好坏”变成“相对好坏”，方差显著下降。

式 (7-85)

用动作价值 q_π 减基线：理论上精确，但 q_π 未知，需要估计。

式 (7-86)

用采样回报 G_t 减基线：可直接计算，是算法 9 采用的实现形式。

依据 《大语言模型：训练、精调与对齐》第 7.6.3 节（式 (7-85)、(7-86)）

算法 9　带基线的 REINFORCE 策略梯度算法

算法 9 带基线的 REINFORCE 策略梯度算法

输入： 给定含参数 $\boldsymbol{\theta}$ 的策略模型 $\pi(a|s;\boldsymbol{\theta})$，学习率 $\beta^{\boldsymbol{\theta}}$，给定参数 W 的状态价值函数 $v(s;\boldsymbol{W})$, 学习率 $\beta^{\boldsymbol{W}}$，折扣因子 γ

输出： 最优策略 $\pi(a|s;\boldsymbol{\theta}_*)$ 的参数 $\boldsymbol{\theta}_*$ 模型，状态价值模型 $v(s;\boldsymbol{W}_*)$

for 每一幕 **do**
  以 $\pi(a|s;\boldsymbol{\theta})$，生成幕序列 $S_0, A_0, R_0, \ldots, S_T, A_T, R_T$
  for 对幕中的每一步循环,$t = \{T, T-1, \cdots, 1, 0\}$ **do**
    $G \leftarrow \sum_{k=t+1}^{T} \gamma^{k-t-1} R_k$
    $\delta \leftarrow G - v(S_t;\boldsymbol{W})$
    $\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \beta^{\boldsymbol{\theta}} \gamma^t \delta \nabla \ln \pi(A_t|S_t;\boldsymbol{\theta})$
    $\boldsymbol{W} \leftarrow \boldsymbol{W} + \beta^{\boldsymbol{W}} \delta \nabla V(S_t;\boldsymbol{W})$
  end for
end for

第 5 步用同一个 δ 同时驱动两条更新：第 6 步调整策略（演员），第 7 步调整基线（价值模型）。这已经是演员-评论家的雏形。

离轨策略梯度

REINFORCE 属于同轨方法，训练样本必须从目标策略 π_{θ} 中采样。离轨策略梯度方法放宽了这一限制。

优势一

重用历史数据

无需采样完整轨迹，可重复利用历史幕数据（经验回放），提高采样效率。

优势二

增强探索

通过行为策略 $\beta(a \mid s)$ 收集样本，采样分布与目标策略解耦，探索更灵活。

代价是引入了分布不匹配：样本来自 β，而目标函数评估的是 π_{θ}。解决办法是用重要性采样比 $\dfrac{\pi_{\theta}(a \mid s)}{\beta(a \mid s)}$ 做偏差校正。

依据 《大语言模型：训练、精调与对齐》第 7.6.4 节

重要性采样推导

$$J(\boldsymbol{\theta}) = \sum_{s\in\mathcal{S}} d^{\beta}(s) \sum_{a\in\mathcal{A}} q_{\pi}(s,a)\pi_{\boldsymbol{\theta}}(a \mid s) = \mathbb{E}_{s\sim d^{\beta}}\left[\sum_{a\in\mathcal{A}} q_{\pi}(s,a)\pi_{\boldsymbol{\theta}}(a \mid s)\right] \tag{7-87}$$

$$\nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta}) = \nabla_{\boldsymbol{\theta}} \mathbb{E}_{s\sim d^{\beta}}\left[\sum_{a} q_{\pi}(s,a)\pi_{\boldsymbol{\theta}}(a \mid s)\right] \tag{7-88}$$

$$= \mathbb{E}_{s\sim d^{\beta}}\left[\sum_{a} \left(q_{\pi}(s,a)\nabla_{\boldsymbol{\theta}}\pi_{\boldsymbol{\theta}}(a \mid s) + \pi_{\boldsymbol{\theta}}(a \mid s)\nabla_{\boldsymbol{\theta}} q_{\pi}(s,a)\right)\right] \tag{7-89}$$

$$= \mathbb{E}_{s\sim d^{\beta}}\left[\sum_{a} q_{\pi}(s,a)\nabla_{\boldsymbol{\theta}}\pi_{\boldsymbol{\theta}}(a \mid s)\right] \tag{7-90}$$

$d^{\beta}(s)$ 是行为策略 β 的稳态分布。式 (7-88) 对状态分布取期望，d^{β} 与 $\boldsymbol{\theta}$ 无关，梯度只作用于内层；式 (7-89) 用乘积法则；式 (7-90) 忽略对 $\nabla_{\boldsymbol{\theta}} q_{\pi}(s,a)$ 的求导项。

依据 《大语言模型：训练、精调与对齐》第 7.6.4 节（式 (7-87)–(7-90)）

离轨梯度的形式

$$= \mathbb{E}_{s\sim d^{\beta}}\left[\sum_{a}\beta(a\mid s)\frac{\pi_{\boldsymbol{\theta}}(a\mid s)}{\beta(a\mid s)}q_{\pi}(s,a)\frac{\nabla_{\boldsymbol{\theta}}\pi_{\boldsymbol{\theta}}(a\mid s)}{\pi_{\boldsymbol{\theta}}(a\mid s)}\right] \tag{7-91}$$

$$= \mathbb{E}_{\beta}\left[\frac{\pi_{\boldsymbol{\theta}}(A_t\mid S_t)}{\beta(A_t\mid S_t)}q_{\pi}(S_t,A_t)\nabla_{\boldsymbol{\theta}}\ln\pi_{\boldsymbol{\theta}}(A_t\mid S_t)\right] \tag{7-92}$$

式 (7-91) 在求和项里乘除 $\beta(a\mid s)$：乘以它得到"按行为策略采样的概率"，除以它得到重要性权重；再乘除 $\pi_{\boldsymbol{\theta}}$ 得到对数导数的形式。式 (7-92) 把求和识别为对行为策略样本的期望。

其中忽略了红色项（$\nabla_{\boldsymbol{\theta}}q_{\pi}(s,a)$）：该项难以计算，且理论证明忽略后仍能收敛。最终形式引入重要性采样比 $\dfrac{\pi_{\boldsymbol{\theta}}(a\mid s)}{\beta(a\mid s)}$，通过重要性权重调整实现离轨策略梯度。

比值的含义

大于 1：该动作在目标策略下更可能，样本权重放大；小于 1 则缩小。

代价

比值可能很大，导致方差升高；策略差距越大，估计越不稳定。

期望的下标是怎么变的

式 (7-91) 的期望只写 $s \sim d^{\beta}$，动作在求和号里；式 (7-92) 的期望写成 $\mathbb{E}_{\beta}$。下标变了，因为“对一个概率分布求和”本来就可以写成“对该分布的期望”。

$$\mathbb{E}_{a\sim\beta(\cdot|s)}\left[f(s,a)\right] = \sum_{a} \beta(a \mid s)\, f(s,a)$$

$$\mathbb{E}_{s\sim d^{\beta}}\Big[\sum_{a} \beta(a \mid s) f(s,a)\Big] = \mathbb{E}_{s\sim d^{\beta},\, a\sim\beta(\cdot|s)}\left[f(s,a)\right] = \mathbb{E}_{\beta}\left[f(S_t, A_t)\right]$$

左边先按 d^{β} 抽状态、再对动作求和；右边把“抽状态 + 抽动作”合并成一次联合采样。$\mathbb{E}_{\beta}$ 的下标 β 同时代表状态分布 d^{β} 与动作分布 $\beta(a \mid s)$，即行为策略诱导的 (S_t, A_t) 联合分布。

第一步：补一个 β/β

$\sum_a \beta(a \mid s) \cdot \dfrac{\pi_{\boldsymbol{\theta}}(a \mid s)}{\beta(a \mid s)} f(s,a)$，值不变，但出现了“对 β 求和”的形状。

第二步：识别成期望

对 a 的求和按上式合并进 $\mathbb{E}_{\beta}$，求和号消失。

第三步：写成样本均值

一条由 β 采出的轨迹，就给出 $\mathbb{E}_{\beta}$ 的一个无偏估计。

算法 10　离轨的 REINFORCE 策略梯度算法

算法 10 离轨的 REINFORCE 策略梯度算法

输入： 给定含参数 $\boldsymbol{\theta}$ 的策略模型 $\pi_{\boldsymbol{\theta}}(a|s)$，学习率 α，将观测策略模型 $\beta(a|s)$ 以参数 $\boldsymbol{\theta}$ 初始化。
输出： 最优策略 $\pi_{\boldsymbol{\theta}_*}(a|s)$ 的参数 $\boldsymbol{\theta}_*$ 模型

1: **for** 每一幕 **do**
2: 　以 $\beta(a|s)$，生成幕序列 $\tau = S_0, A_0, R_0, \ldots, S_T, A_T, R_T$
3: 　$\mathcal{T} \leftarrow \tau$
4: 　**for** $\mathcal{T}$ 取出幕 τ **do**
5: 　　**for** 对幕 τ 中的每一步循环,$t = \{T-1, T-2, \cdots, 1, 0\}$ **do**
6: 　　$G \leftarrow \sum_{k=t+1}^{T} \gamma^{k-t-1} R_k$
7: 　　$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \alpha\gamma^t q_{\pi_{\boldsymbol{\theta}}}(s,a) \frac{\pi_{\boldsymbol{\theta}}(a|s)}{\beta(a|s)} \nabla \ln \pi_{\boldsymbol{\theta}}(A_t|S_t)$
8: 　　**end for**
9: 　**end for**
10: **end for**

与算法 8 的差别集中在第 2 步与第 7 步：数据由行为策略 β 生成，更新时乘上重要性采样比，把“按 β 采样的期望”校正为“按 $\pi_{\boldsymbol{\theta}}$ 的期望”。

7.7

演员-评论家

策略梯度给出方向，价值函数给出尺度：演员按评论家的 TD 误差更新策略，评论家持续评估价值。

本节内容

7.7.1 演员-评论家算法

7.7.2 信赖域策略优化

7.7.3 近端策略优化

7.7.4 策略梯度类方法小结

演员-评论家的两个组件

策略梯度方法包含两个核心组件：策略模型与价值函数。带基线的 REINFORCE 用价值函数估计作基线降低方差，此时可改用时序差分改进价值估计。当策略梯度方法同时建模策略模型与价值模型时，称为演员-评论家方法（AC）。

评论家 Critic

评估价值

更新价值函数参数 $\boldsymbol{W}$，估计动作价值 $q(s,a;\boldsymbol{W})$ 或状态价值 $v(s;\boldsymbol{W})$。

用最小化 TD 误差 δ_t^2 更新价值参数。

演员 Actor

更新策略

基于评论家给出的时序差分误差，更新策略参数 $\boldsymbol{\theta}$。

用 $\beta^{\boldsymbol{\theta}}$ 与 $\beta^{\boldsymbol{W}}$ 两个独立学习率分别更新。

与 REINFORCE 的差别：那里用完整回报 G_t 作权重，这里换成单步 TD 误差 δ_t，更新可以逐步进行，方差也更低。

从基线到时序差分误差

$$\nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta}) = \mathbb{E}_{\pi}\left[\left(G_t - v(s;\boldsymbol{W})\right) \nabla_{\boldsymbol{\theta}} \ln \pi(A_t \mid S_t;\boldsymbol{\theta}) \right] \tag{7-93}$$

$$= \mathbb{E}_{\pi}\left[\left(R_{t+1} + \gamma v(S_{t+1};\boldsymbol{W}) - v(S_t;\boldsymbol{W})\right) \nabla_{\boldsymbol{\theta}} \ln \pi(A_t \mid S_t;\boldsymbol{\theta}) \right] \tag{7-94}$$

$$= \mathbb{E}_{\pi}\left[\delta_t \nabla_{\boldsymbol{\theta}} \ln \pi(A_t \mid S_t;\boldsymbol{\theta}) \right] \tag{7-95}$$

式 (7-94)：把 G_t 换成单步 TD 目标 $R_{t+1} + \gamma v(S_{t+1};\boldsymbol{W})$；式 (7-95)：括号内即 TD 误差 $\delta_t = R_{t+1} + \gamma v(S_{t+1};\boldsymbol{W}) - v(S_t;\boldsymbol{W})$。

式 (7-93)

回报减基线，权重覆盖整幕。

式 (7-94)

用一步自举替代回报，权重只看一步。

式 (7-95)

写成 δ_t，演员与评论家共用。

- $\delta_t > 0$ 说明这一步比预期好，提高该动作概率；$\delta_t < 0$ 则降低。
- 用自举替代采样回报，仍保持"相对优势"的含义，但不再需要等一幕结束。

依据 《大语言模型：训练、精调与对齐》第 7.7.1 节（式 (7-93)–(7-95)）

算法 11　演员-评论家算法

算法 11 “演员-评论家”算法

输入： 给定含参数 $\boldsymbol{\theta}$ 的策略模型 $\pi(a|s;\boldsymbol{\theta})$，学习率 $\beta^{\boldsymbol{\theta}}$，给定参数 W 的状态价值函数 $v(s,W)$, 学习率 $\beta^{\boldsymbol{W}}$，折扣因子 γ

输出： 最优策略 $\pi(a|s;\boldsymbol{\theta}_*)$ 的参数 $\boldsymbol{\theta}_*$ 模型，状态价值模型 $v(s;\boldsymbol{W}_*)$

for 每一幕 **do**
  初始化状态 S
  $I \leftarrow 1$
  for 对幕中的每一步循环,$t = \{T-1, T-2, \cdots, 1, 0\}$ **do**
    $A_t \sim \pi(\cdot|S_t;\boldsymbol{\theta})$,
    执行动作 A_t，得到奖励 R 并跳转到下一个状态 S_{t+1}
    $\delta \leftarrow R + \gamma v(S_{t+1};\boldsymbol{W}) - v(S_t;\boldsymbol{W})$
    $\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \beta^{\boldsymbol{\theta}} I \delta \nabla \ln \pi(A_t|S_t;\boldsymbol{\theta})$
    $\boldsymbol{W} \leftarrow \boldsymbol{W} + \beta^{\boldsymbol{W}} \delta \nabla v(S_t;\boldsymbol{W})$
    $I \leftarrow \gamma I$
    $S \leftarrow S'$
  end for
end for

第 7 步算 TD 误差；第 8、9 步用同一个 δ 分别更新演员与评论家；第 10 步的 I 是折扣累计因子，用于给早期动作合适的权重。

演员与评论家的更新

采样

$A_t \sim \pi(\cdot \mid S_t; \boldsymbol{\theta})$

→

评论家

算 $\delta_t = R + \gamma v(S_{t+1}) - v(S_t)$

→

演员

$\boldsymbol{\theta} \mathrel{+}= \beta^{\boldsymbol{\theta}} \delta_t \nabla \ln \pi$

→

评论家更新

$\boldsymbol{W} \mathrel{+}= \beta^{\boldsymbol{W}} \delta_t \nabla v$

演员的目标

最大化累积奖励：沿 $\nabla_{\boldsymbol{\theta}} \ln \pi$ 的方向，按 δ_t 调整动作概率。

评论家的目标

最小化时序差分误差 δ_t^2：让 $v(s; \boldsymbol{W})$ 更准确地预测实际回报。

两者共用同一个 δ_t，但更新方向不同：演员做梯度上升，评论家做梯度下降。学习率分开设置，是因为两个模型的尺度与收敛速度不同。

依据 《大语言模型：训练、精调与对齐》第 7.7.1 节

TRPO 算法

为提升策略梯度训练的稳定性，需要避免在单个训练步中对策略做过大调整。信赖域策略优化（TRPO）采用 KL 散度约束每次迭代的策略更新幅度。

在离轨强化学习设置中，行为策略 β 收集轨迹数据，目标策略 π 被优化。目标函数涉及状态访问分布与动作优势函数；当训练数据分布与目标策略的状态分布存在差异时，通过重要性采样进行偏差校正。

$$J(\boldsymbol{\theta}) = \sum_{s\in\mathcal{S}} \rho^{\pi_{\boldsymbol{\theta}_{\text{old}}}} \sum_{a\in\mathcal{A}} \left(\pi_{\boldsymbol{\theta}}(a \mid s) \hat{A}_{\boldsymbol{\theta}_{\text{old}}}(s,a) \right) \tag{7-96}$$

$$= \sum_{s\in\mathcal{S}} \rho^{\pi_{\boldsymbol{\theta}_{\text{old}}}} \sum_{a\in\mathcal{A}} \left(\beta(a \mid s) \frac{\pi_{\boldsymbol{\theta}}(a \mid s)}{\beta(a \mid s)} \hat{A}_{\boldsymbol{\theta}_{\text{old}}}(s,a) \right) \tag{7-97}$$

$$= \mathbb{E}_{s\sim\rho^{\pi_{\boldsymbol{\theta}_{\text{old}}}}, a\sim\beta} \left[\frac{\pi_{\boldsymbol{\theta}}(a \mid s)}{\beta(a \mid s)} \hat{A}_{\boldsymbol{\theta}_{\text{old}}}(s,a) \right] \tag{7-98}$$

$\boldsymbol{\theta}_{\text{old}}$ 是更新前的策略参数，$\rho^{\pi_{\boldsymbol{\theta}_{\text{old}}}}$ 是旧策略的状态访问分布，$\beta(a \mid s)$ 是收集轨迹的行为策略。式 (7-97) 乘除 β 完成重要性采样。

注意我们使用估计的优势函数 $\hat{A}_{\boldsymbol{\theta}_{\text{old}}}(s,a)$ 替代真实优势 $A(s,a)$，因为真实奖励未知；估计值由 GAE 给出，通过减少方差提升稳定性。

TRPO 的目标函数

在 TRPO 的在线算法中，数据由当前策略 $\pi_{\boldsymbol{\theta}_{\text{old}}}$ 收集，因此优化函数简化为：

$$J(\boldsymbol{\theta}) = \mathbb{E}_{s\sim\rho^{\pi_{\boldsymbol{\theta}_{\text{old}}}},a\sim\pi_{\boldsymbol{\theta}_{\text{old}}}}\left[\frac{\pi_{\boldsymbol{\theta}}(a\mid s)}{\pi_{\boldsymbol{\theta}_{\text{old}}}(a\mid s)}\hat{A}_{\boldsymbol{\theta}_{\text{old}}}(s,a)\right] \tag{7-99}$$

$$\text{s.t.}\quad \mathbb{E}_{s\sim\rho^{\pi_{\boldsymbol{\theta}_{\text{old}}}}}\left[D_{\text{KL}}\left(\pi_{\boldsymbol{\theta}_{\text{old}}}(\cdot\mid s)\,\|\,\pi_{\boldsymbol{\theta}}(\cdot\mid s)\right)\right]\leqslant\delta \tag{7-100}$$

式 (7-99) 把式 (7-98) 中的行为策略 β 换成旧策略 $\pi_{\boldsymbol{\theta}_{\text{old}}}$；式 (7-100) 的信赖域约束要求新旧策略之间的 KL 散度期望值小于阈值 δ，确保策略更新落在信赖域内。

- 使用估计的优势函数 $\hat{A}_{\boldsymbol{\theta}_{\text{old}}}(s,a)$ 替代真实优势 $A(s,a)$，因为真实奖励未知。
- 估计的优势函数采用 GAE，通过减少方差提升稳定性（见下页）。
- KL 约束把“一步走多远”变成可以显式控制的量，这是 TRPO 稳定性的来源。

代价是求解复杂：带约束的优化需要二阶信息或共轭梯度，实现成本高。下一节 PPO 用裁剪把同一件事做得更简单。

广义优势估计（GAE）

广义优势估计（GAE）是一种基于时序差分误差的优势函数估计方法：利用旧策略的价值函数 V 计算 TD 误差，再通过 λ-加权回溯得到每个时刻的优势估计。

$$A(S_t, A_t) = q_\pi(S_t, A_t) - v_\pi(S_t) \tag{7-101}$$

$$\delta_t = R_t + \gamma v_\pi(S_{t+1}) - v_\pi(S_t) \tag{7-102}$$

$$A_t^{\mathrm{GAE}} = \sum_{l=0}^{\infty} (\gamma\lambda)^l \delta_{t+l} \tag{7-103}$$

$$A_t^{\mathrm{GAE}} = \delta_t + (\gamma\lambda)\delta_{t+1} + (\gamma\lambda)^2\delta_{t+2} + \dots \tag{7-104}$$

式 (7-101) 是优势函数的定义；式 (7-102) 把它等价表示为 TD 误差的形式；式 (7-103) 对无穷多步 TD 误差做指数衰减加权。

式 (7-104) 只是把求和展开写开，便于看出权重是一个等比数列：δ_t 的系数为 1，δ_{t+1} 的系数为 $\gamma\lambda$，依此类推。

GAE 的递推形式

$$A_t^{\mathrm{GAE}} = \delta_t + \gamma\lambda\left(\delta_{t+1} + \gamma\lambda\delta_{t+2} + \dots\right) \tag{7-105}$$

$$A_t^{\mathrm{GAE}} = \delta_t + \gamma\lambda A_{t+1}^{\mathrm{GAE}} \tag{7-106}$$

式 (7-105) 从式 (7-104) 提出公因子 $\gamma\lambda$；括号内正是 A_{t+1}^{GAE} 的定义。$\lambda \in [0,1]$ 是 GAE 的超参数，控制不同步长 TD 误差的权重。

$\lambda = 0$

$\hat{A}_t^{\mathrm{GAE}} = \delta_t$，退化为单步 TD 误差。

高偏差、低方差。

$\lambda = 1$

退化为蒙特卡洛估计 $\hat{A}_t^{\mathrm{GAE}} = \sum_{l=0}^{\infty}\gamma^l\left(R_{t+l} + \gamma V(s_{t+l+1}) - V(s_{t+l})\right)$。

低偏差、高方差。

参数 λ 通过指数衰减加权机制，在不同步长 TD 误差的贡献之间取得平衡；它用于更新价值函数，目标是最小化新价值函数与 GAE 的均方误差。

依据 《大语言模型：训练、精调与对齐》第 7.7.2 节（式 (7-105)、(7-106)）

PPO 算法

TRPO 通过 KL 散度约束策略更新幅度；近端策略优化（PPO）采用目标函数裁剪机制实现相似的约束效果。核心思想是通过限制策略更新幅度稳定训练，裁剪操作可有效约束策略参数的变化范围。

$$r_t(\boldsymbol{\theta}) = \frac{\pi_{\boldsymbol{\theta}}(a_t \mid s_t)}{\pi_{\boldsymbol{\theta}_{\text{old}}}(a_t \mid s_t)} \tag{7-107}$$

新旧策略的比率：$r_t = 1$ 表示策略未变；r_t 偏离 1 越远，说明这一步更新越大。

$$J^{\text{TRPO}}(\boldsymbol{\theta}) = \mathbb{E}_{s \sim \rho^{\pi_{\boldsymbol{\theta}_{\text{old}}}}, a \sim \pi_{\boldsymbol{\theta}_{\text{old}}}} \left[r_t(\boldsymbol{\theta}) \hat{A}_{\boldsymbol{\theta}_{\text{old}}}(s, a) \right] \tag{7-108}$$

TRPO 的优化目标。若直接最大化它而无约束，策略比率 $r_t(\boldsymbol{\theta})$ 可能出现极端值，导致参数更新不稳定。

依据 《大语言模型：训练、精调与对齐》第 7.7.3 节（式 (7-107)、(7-108)）

PPO 的裁剪目标

$$J^{\mathrm{CLIP}}(\boldsymbol{\theta}) = \mathbb{E}\left[\min\left(r_t(\boldsymbol{\theta})\hat{A}_{\boldsymbol{\theta}_{\mathrm{old}}}(s,a),\ \mathtt{clip}\left(r_t(\boldsymbol{\theta}), 1-\epsilon, 1+\epsilon\right)\hat{A}_{\boldsymbol{\theta}_{\mathrm{old}}}(s,a)\right)\right] \tag{7-109}$$

裁剪函数把比率限制在 $[1-\epsilon, 1+\epsilon]$ 内，ϵ 为超参数；外层取原始值与截断值的**最小值**。

$\hat{A} > 0$

目标函数限制策略改进的**上限**：比率超过 $1+\epsilon$ 后收益不再增加。

$\hat{A} < 0$

目标函数限制策略恶化的**下限**：比率低于 $1-\epsilon$ 后惩罚不再加重。

取最小值的效果：策略朝好的方向走，超过信赖域就不再给奖励；朝坏的方向走，超过界限也不再额外惩罚。于是更新被“夹”在一个小区间内。

裁剪机制的作用

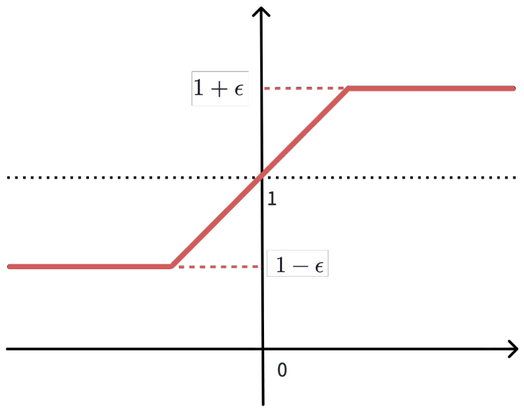


图 7.17　PPO 目标函数裁剪机制示意图

- 横轴是策略比率 r_t，纵轴是目标函数中的那一项。
- $\hat{A} > 0$ 时，$r_t > 1+\epsilon$ 后曲线转为水平：再增大比率也不会提高目标。
- $\hat{A} < 0$ 时，$r_t < 1-\epsilon$ 后曲线同样转为水平：再减小比率也不会降低目标。
- 通过取原始值与截断值的最小值，PPO 避免了因过度追求高回报而导致的策略突变。

图 《大语言模型：训练、精调与对齐》图 7.17

算法 12　PPO-Clip 算法

算法 12 PPO-Clip 算法

输入: 初始策略参数 $\boldsymbol{\theta}$，价值函数参数 $\boldsymbol{W}$，裁剪参数 ϵ，折扣因子 γ，GAE 参数 λ，策略更新轮次 K，小批量大小 M，目标 KL 散度 δ，策略学习率 $\beta^{\boldsymbol{\theta}}$，价值学习率 $\beta^{\boldsymbol{W}}$，熵系数 c_2

输出: 优化后的策略参数 $\boldsymbol{\theta}_*$，价值函数参数 $\boldsymbol{W}_*$

for 迭代 $i = 0, 1, 2, \cdots$ **do**
  用策略 $\pi_{\boldsymbol{\theta}}$ 收集轨迹集 $\mathcal{D}_i = \{(S_t, A_t, R_t, S_{t+1})\}$
  使用当前价值网络计算：$V_{\text{old}}(S_t) \leftarrow V(S_t; \boldsymbol{W})$　▷ 保存旧价值函数快照
  若 S_t 为终止状态, 则令 $V_{\text{old}}(S_t) \leftarrow 0$
  初始化 $\hat{A}_T = 0$
  for $t = T-1, T-2, \cdots, 0$ **do**　▷ GAE 计算
    $\delta_t \leftarrow R_t + \gamma V_{\text{old}}(S_{t+1}) - V_{\text{old}}(S_t)$
    $\hat{A}_t \leftarrow \delta_t + \gamma\lambda\hat{A}_{t+1}$
  end for
  $\boldsymbol{\theta}_{\text{old}} \leftarrow \boldsymbol{\theta}$　▷ 保存旧策略参数
  for 更新轮次 $k = 1$ **to** K **do**　▷ 多轮策略更新
    将 $\mathcal{D}_i$ 随机划分为小批量 $\{\mathcal{D}'_1, \mathcal{D}'_2, \cdots\}$
    for 每个小批量 $\mathcal{D}'_m$ **do**
      计算概率比：$r_t(\boldsymbol{\theta}) = \frac{\pi_{\boldsymbol{\theta}}(A_t|S_t)}{\pi_{\boldsymbol{\theta}_{\text{old}}}(A_t|S_t)}$
      计算裁剪目标：$\mathcal{L}_t^{\text{CLIP}} = \min\left(r_t(\boldsymbol{\theta})\hat{A}_t, \texttt{clip}(r_t(\boldsymbol{\theta}), 1-\epsilon, 1+\epsilon)\hat{A}_t\right)$
      计算目标回报：$\hat{R}_t \leftarrow \hat{A}_t + V_{\text{old}}(s_t)$　▷ 固定目标值
      计算价值损失：$\mathcal{L}_t^{\text{VF}} = \left(V(S_t; \boldsymbol{W}) - \hat{R}_t\right)^2$
      计算策略熵：$\mathcal{H}_t = -\sum_a \pi_{\boldsymbol{\theta}}(a|S_t)\log\pi_{\boldsymbol{\theta}}(a|S_t)$
      计算小批量平均梯度并更新策略和价值网络参数
      更新策略：$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \beta^{\boldsymbol{\theta}}\nabla_{\boldsymbol{\theta}}\mathbb{E}[\mathcal{L}_t^{\text{CLIP}} + c_2\mathcal{H}_t]$
      更新价值函数：$\boldsymbol{W} \leftarrow \boldsymbol{W} - \beta^{\boldsymbol{W}}\nabla_{\boldsymbol{W}}\mathbb{E}[\mathcal{L}_t^{\text{VF}}]$
    end for
    if $\text{KL}[\pi_{\boldsymbol{\theta}_{\text{old}}} || \pi_{\boldsymbol{\theta}}] > 1.5\delta$ **then**
      break
    end if
  end for
end for

PPO 的三个设计要点

要点一

多轮策略更新

对同一批经验执行多次更新（通常 $K = 3 \sim 10$ 次），显著提升样本利用效率，并确保训练稳定。

多次小幅更新能控制策略变化幅度，避免参数剧烈跳变导致策略崩溃。

要点二

熵正则项

$\mathcal{H}_t = -\sum_a \pi_{\boldsymbol{\theta}}(a \mid S_t) \log \pi_{\boldsymbol{\theta}}(a \mid S_t)$ 是策略分布的香农熵。

以系数 $c_2 \approx 0.01$ 正向激励，防止策略过早收敛到局部最优，维持探索能力。

要点三

价值函数损失

目标回报 $\hat{R}_t = \hat{A}_t + v_{\pi_{\text{old}}}(s; \boldsymbol{W})$：旧价值提供稳定基准，GAE 优势给出修正。

价值网络通过最小化 $\mathcal{L}_t^{\text{VF}} = (v_\pi(s; \boldsymbol{W}) - \hat{R}_t)^2$ 逼近真实价值。

三项设计分别对应“用足数据”“别停止探索”“给演员一个稳定的参照系”。再配合裁剪与提前停止，构成 PPO 的稳定性组合。

熵正则与价值损失

熵正则项

策略趋于确定性（某动作概率 $\to 1$）时熵值趋近 0；均匀分布时熵值最大。

主动增加随机性，驱使智能体持续探索潜在的高回报动作；训练初期尤其能避免陷入动作空间死角。

同时抑制策略网络输出过度尖锐的概率分布，维持动作选择的灵活性。

价值函数损失

$\hat{R}_t$ 实质是状态-动作对 (S_t, A_t) 的折扣累积回报估计值，作为 $v(\boldsymbol{s}; \boldsymbol{W})$ 的学习目标。

右侧 $v_{\pi_{\text{old}}}(\boldsymbol{s}; \boldsymbol{W})$ 是旧策略下状态 $\boldsymbol{s}_t$ 的基准价值估计，提供稳定预期。

左侧 $\hat{A}_t$ 是 GAE 算出的修正优势，量化特定动作相对平均水平的超额收益。

> **配套** 价值函数逐步逼近真实状态价值后，反过来为策略更新提供低方差的优势估计基准——这正是 PPO 中“评论家”的作用。

策略梯度框架的小结

策略梯度方法在连续状态问题中具有天然优势，且支持策略直接优化，在机器人控制、优化决策等领域应用广泛。其推导把状态转移概率内化至状态稳态分布，规避了随机转移建模的复杂性。

价值估计

基线、AC 评论家、GAE

策略更新

$\nabla_{\theta} \ln \pi \cdot \hat{A}$

稳定性控制

重要性采样、clip、KL

稳定训练

演员-评论家架构

- 采用无偏低方差的 GAE 优化价值估计。
- 在策略梯度中引入重要性采样与 `clip` 等技巧提升稳定性。
- 在演员-评论家架构中，价值估计方法始终发挥核心作用。

依据 《大语言模型：训练、精调与对齐》第 7.7.4 节

7.8

大语言模型的 MDP 描述

本节内容

7.8　大语言模型的 MDP 描述

把语言模型看成策略智能体：状态是已生成的前缀，动作是下一个词元，转移由拼接确定。

语言模型的 MDP 描述

大语言模型的环境可建模为 MDP，于是可以利用强化学习方法训练。四个要素与语言模型的生成过程一一对应。

状态 $S_t \in \mathcal{S}$

离散词元序列 $\boldsymbol{x}_{:t} = (x_1, x_2, \cdots, x_t)$，即已生成的前缀。

动作 $A_t \in \mathcal{A}$

$\mathcal{A} = \mathcal{V}$（$\mathcal{V}$ 为词表空间），即选择下一个词元。

状态转移

确定性的：拼接 $\boldsymbol{x}_{:t}$ 与 A_t 得 $S_{t+1} \leftarrow (\boldsymbol{x}_{:t}, A_t)$，序列长度变为 $t+1$。

奖励 R_t

由环境任务决定。在 RLHF 中，R_t 仅在终局状态 <EOS> 输出非零奖励分数，其他时刻 $R_t = 0$。

因此这是一棵“确定转移、稀疏终点奖励”的树：每个状态的分支数等于词表大小，只有走到结尾才结算。

语言模型作为策略模型

$$A_t \sim \pi_{\boldsymbol{\theta}}(\cdot \mid S_t) = \pi_{\boldsymbol{\theta}}(\cdot \mid \boldsymbol{x}_{:t})$$

$$S_{t+1} \leftarrow (\boldsymbol{x}_{:t},\, A_t) = \boldsymbol{x}_{:t+1}$$

状态 S_t 就是已生成的词元前缀 $\boldsymbol{x}_{:t}$；策略输出下一个词元的分布，采样得到 A_t，再把它拼到序列尾部，得到确定的下一个状态 S_{t+1}。

MDP 要素	语言模型中的对应物
状态 S_t	词元前缀 $\boldsymbol{x}_{:t} = (x_1, \ldots, x_t)$
动作 A_t	下一个词元，$\mathcal{A} = \mathcal{V}$
策略 $\pi_{\boldsymbol{\theta}}$	Softmax 输出的下一个词元分布
转移 $p(s' \mid s, a)$	确定性的拼接，$p = 1$
奖励 R_t	仅 $t = T$ 时由任务给出，其余为 0

一步生成：以「今天天气」为前缀，采样出「真」。

$$\pi_{\boldsymbol{\theta}}(\cdot \mid \text{今天天气}) = \big[\text{真} : 0.42,\ \text{不} : 0.31,\ \text{很} : 0.18,\ \cdots\big]$$

$$A_t = \text{真} \quad (\text{按 } 0.42 \text{ 采样})$$

$$S_{t+1} = (\text{今天天气},\ \text{真})$$

分布是策略，采样是执行动作，拼接是转移。$|\mathcal{A}|$ 等于词表大小，通常三万到十几万。

要点 动作空间等于词表、转移完全确定、奖励只在终止处——这三点决定了语言模型上的强化学习是“大树 + 稀疏终点奖励”。

动作空间极大

$|\mathcal{A}|$ 等于词表大小，$\arg\max$ 与全动作求和都不可行，只能采样。

转移完全确定

环境模型 $p(s' \mid s, a)$ 已知且为 1，难点全在策略与奖励，不在探索环境。

奖励稀疏

只有生成到终止符才有分数，G_t 要靠整条序列算出来，天然适合策略梯度。

依据 《大语言模型：训练、精调与对齐》第 7.8 节

从本章到第 8 章

范式一

基于人类反馈的强化学习

用人类偏好训练奖励模型，再以 PPO 等算法优化语言模型策略。

对应本章 7.6、7.7 的策略梯度与演员-评论家方法。

范式二

基于推理的强化学习

以可验证的答案正确性等信号作为奖励，强化模型的推理过程。

奖励稀疏、序列长，对采样效率与稳定性要求更高。

本章解决“算法是什么”，第 8 章解决“怎么用到语言模型上”。本章的 MDP 描述是两章之间的接口。

再往后看：指令微调中的 PPO（如 Instruct-GPT）正是把 7.7.3 节的裁剪目标直接作用在语言模型的词元分布上。

7.9

小结

本节内容

7.9　全章回顾

强化学习在 MDP 框架下定义问题，以最大化累积奖励为目标；价值方法、策略梯度与演员-评论家构成完整的求解体系。

本章结构

问题定义

MDP 与贝尔曼方程

状态、动作、转移、奖励、折扣构成五元组；贝尔曼方程把长期回报拆成“一步 + 下一状态价值”的递归。

7.1

基于价值

DP、MC、TD

模型已知用 DP；模型未知时 MC 用完整幕回报，TD 用一步奖励加自举；GPI 贯穿评估与改进。

7.3–7.5

基于策略

策略梯度与 AC

直接优化参数化策略；策略梯度定理绕开转移概率，GAE 降方差，TRPO 与 PPO 控制更新幅度。

7.6–7.7

- 表格型场景下，策略评估与策略改进交替进行，可用动态规划、蒙特卡洛估计与时序差分方法做策略优化。
- 模型未知或状态空间复杂时，用参数化模型（如 DQN）估计价值函数。
- 策略梯度定理支持通过梯度上升直接更新参数化策略；REINFORCE、演员-评论家、TRPO 与 PPO 都围绕稳定性设计。

依据 《大语言模型：训练、精调与对齐》第 7.9 节

语言模型作为策略智能体

语言模型可以在 MDP 框架下建模为一个策略智能体：通过调整其预测分布（即策略）来生成动作（词元），从而在特定任务场景中学习以获取更高的累积奖励。

前缀 $\boldsymbol{x}_{:t}$

状态

下一个词元

动作，概率由 $\pi_{\boldsymbol{\theta}}$ 给出

拼接

确定转移

终局奖励

整段输出的评分

> **实例** 在大语言模型领域，Instruct-GPT 利用 PPO 算法对语言模型进行微调，显著提升了模型在指令理解、安全性以及自然语言处理能力等方面的表现。这充分表明强化学习已成为优化语言模型的重要手段。

下一章将展开两类范式：基于人类反馈的强化学习，与基于推理的强化学习。

思考题与实践题

1 说明马尔可夫性质的含义，并解释为什么它能把序贯决策问题的历史压缩为当前状态。

2 从回报的递归式 $G_t = R_{t+1} + \gamma G_{t+1}$ 出发，推导贝尔曼期望方程，并指出"自举"在哪一步出现。

3 比较蒙特卡洛与时序差分：二者分别需要多少数据才能更新一次价值估计，偏差与方差各有什么特点。

4 写出 SARSA 与 Q 学习的更新式，说明同轨策略与离轨策略的差别，并解释为什么 Q 学习能收敛到 q_*。

5 DQN 的经验回放与目标网络分别解决了什么不稳定问题？若去掉其中之一，训练会出现什么现象？

6 推导 REINFORCE 的样本梯度，说明 $\nabla_{\boldsymbol{\theta}} \ln \pi_{\boldsymbol{\theta}}$ 的作用，以及基线为何不改变梯度的期望。

7 比较 TRPO 的 KL 约束与 PPO 的裁剪目标：二者都在限制策略更新幅度，实现方式与代价有何不同。

8 把语言模型的生成过程写成 MDP，指出状态、动作、转移与奖励，并说明 RLHF 中奖励为何只在 <EOS> 处非零。

依据 《大语言模型：训练、精调与对齐》第 7 章

本章算法的代码实现

每个算法一个文件、一个类，3×3 网格世界讲表格型方法，CartPole-v1 讲需要神经网络的方法。

文件	算法	教材位置	环境
dp.py	策略评估、策略改进、策略迭代、值迭代	7.3 节	网格（已知模型）
mc.py	首次访问 MC 估计、试探性出发 MC 控制	7.4 节	网格
td.py	表格型 TD(0) 策略评估	7.5.1 节	网格
sarsa.py	SARSA、期望 SARSA	7.5.2 节	网格
q_learning.py	Q 学习	7.5.3 节	网格
td_lambda.py	n 步回报、λ-回报、TD(λ)	7.5.4 节	网格
dqn.py	DQN：经验回放 + 目标网络	7.5.5 节	CartPole-v1
pg.py	REINFORCE、带基线、离轨策略	7.6.3 节	CartPole-v1
actor_critic.py	演员-评论家	7.7.1 节	CartPole-v1
gae.py	广义优势估计（纯函数，讲计算过程）	7.8.2 节	—
ppo.py	PPO-Clip，内部实现 GAE	7.7.3 节	CartPole-v1

配套 envs/grid_world.py 提供 deterministic / slip / wind 三种转移场景，bellman.py、transition.py、why_v_is_harder.py 给出本章各式的数值实例。每个文件都可 python 文件名.py 独立运行。